

Từ nền tảng đến ứng dụng: Cải thiện mô hình VLA trong thực tế

Nguy Ngô*, Fangjing Wang*, Fan Lu, He Sun, Shi Liu, Yunnan Wang, Yibin Yan, Yong Wang, Shuailei Ma, Xinyang Wang, Yibin Liu, Shuai Yang, Tianxiang Chu, Kejia Zhang, Lei Chu, Cheng Su, Nan Xue, Bin Tan, Han Zhang, Youchao Zhang, Fei Liao, Xing Zhu, Yujun Shen, Kechen Zheng†

*Đóng góp bình đẳng †Trưởng dự án

Bất chấp những tiến bộ gần đây của các mô hình nền tảng VLA, sự khác biệt giữa điều kiện phòng thí nghiệm và ứng dụng trong thế giới thực vẫn tiếp tục cản trở việc triển khai thực tế của chúng. Để thu hẹp khoảng cách này, chúng tôi giới thiệu LingBot-VLA 2.0, cải tiến LingBot-VLA thông qua các cải tiến trong ba lĩnh vực chức năng. (1) *Khái quát hóa* qua các nhiệm vụ và phương án. So với phiên bản trước, chúng tôi cải tiến quy trình xử lý dữ liệu và quản lý khoảng 60.000 giờ dữ liệu để đào tạo trước, bao gồm 50.000 giờ quỹ đạo của rô-bốt trải rộng trên 20 cấu hình rô-bốt và 10.000 giờ video về con người lấy cái tôi làm trung tâm. (2) *Không gian hành động mở rộng* bên cạnh nền tảng phần cứng hai cánh tay. Đặc biệt, hệ thống của chúng tôi cung cấp mức độ tự do cho đầu, thắt lưng, để di động và bàn tay khéo léo, từ đó trao quyền cho rô-bốt giải quyết các nhiệm vụ phức tạp hơn trong các tình huống thực tế. (3) *Mô hình động lực học dự đoán* để cải thiện lý luận về thời gian. Cụ thể, chúng tôi xây dựng dự đoán trong tương lai dưới dạng một nhiệm vụ ủy nhiệm, được hỗ trợ bởi mô hình trình bày video cho các ưu tiên ngữ nghĩa và mô hình ước tính độ sâu cho các tín hiệu hình học. Các đánh giá dựa trên tiêu chuẩn GM-100, được thực hiện trong bối cảnh tổng quát, xác nhận tác động có lợi của những sửa đổi được đề xuất này. Hơn nữa, được hưởng lợi từ dữ liệu huấn luyện trước mở rộng bao gồm các mức độ tự do của toàn bộ cơ thể, LingBot-VLA-2.0 thể hiện khả năng thao tác di động trong tầm nhìn dài, đa phương án mạnh mẽ trên hai nền tảng robot.

Trang web: <https://technology.robbyant.com/lingbot-vla-v2>

Github: <https://github.com/robbyant/lingbot-vla-v2>


Điểm kiểm tra: <https://huggingface.co/collections/robbyant/lingbot-vla-v2>

Robbyant

1 Giới thiệu

Các mô hình tầm nhìn-ngôn ngữ-hành động (VLA) [4–6, 16] gần đây đã nổi lên như một mô hình đầy hứa hẹn để xây dựng các chính sách tổng quát về robot. Ưu điểm chính của mô hình này là các mô hình ngôn ngữ tầm nhìn được đào tạo trước cung cấp sự liên kết đa phương thức và biểu diễn ngữ nghĩa phong phú, cho phép các mô hình VLA hiểu rõ hơn các cảnh phức tạp và khái quát hóa qua các nhiệm vụ đa dạng. Ngoài các ưu tiên ở cấp độ mô hình như vậy, những tiến bộ gần đây [5, 31] còn cho thấy rằng việc mở rộng quy mô dữ liệu robot cả về số lượng và tính đa dạng có thể cải thiện đáng kể khả năng của hệ thống VLA. Cùng với nhau, những bước phát triển này đã thiết lập VLA như một nền tảng hấp dẫn cho việc học tập của robot.

Tuy nhiên, bất chấp tiến bộ nhanh chóng này, vẫn còn một khoảng cách đáng kể giữa các tiêu chuẩn trong phòng thí nghiệm và việc triển khai trong thế giới thực. Trong thực tế, robot dự kiến sẽ hoạt động với sự đa dạng về phương án rộng hơn, không gian hành động phong phú hơn và môi trường năng động hơn so với những môi trường được xem xét trong nhiều cài đặt VLA hiện có. Đầu tiên, khái quát hóa trong thực tế không chỉ là chuyển giao giữa các nhiệm vụ mà còn là xử lý các cấu hình và nguồn dữ liệu robot không đồng nhất. Một điểm khác là nhiều nền tảng trong thế giới thực có nhiều mức độ tự do hơn đáng kể so với các thiết lập thao tác hai cánh tay tiêu chuẩn, bao gồm chuyển động đầu, thắt lưng, điều khiển để di động và bàn tay khéo léo. Sau đó, việc thực hiện trong thế giới thực thường đòi hỏi phải dự đoán diễn biến của cảnh trong tương lai và hậu quả hành động, thay vì chỉ phản ứng với những quan sát hiện tại. Những thách thức này nói chung hạn chế tiện ích thực tế của các mô hình nền tảng VLA hiện tại.




Hình 1. Tổng quan về LingBot-VLA 2.0. Chúng tôi cải tiến quy trình xử lý dữ liệu và quản lý 60.000 giờ dữ liệu đào tạo trước, bao gồm 50.000 giờ quỹ đạo của rô-bốt trên 20 cấu hình rô-bốt và 10.000 giờ video về con người lấy cái tôi làm trung tâm. Hơn nữa, mô hình của chúng tôi hỗ trợ bậc tự do cho đầu, thắt lưng, để di động và bàn tay khéo léo, cho phép robot xử lý các nhiệm vụ phức tạp hơn trong thế giới thực. Chúng tôi xây dựng dự đoán trong tương lai dưới dạng một nhiệm vụ ủy quyền, tận dụng mô hình biểu diễn video cho các ưu tiên ngữ nghĩa và mô hình ước tính độ sâu cho các tín hiệu hình học.

Ngày càng nhiều công việc đã bắt đầu giải quyết những vấn đề này từ những góc độ khác nhau. Một số phương pháp tiếp cận [21, 31, 38] mở rộng quy mô dữ liệu huấn luyện trước robot để cải thiện độ mạnh mẽ của nhiều tác vụ và nhiều phương án. Những người khác kết hợp các thiết kế kiến trúc nhận biết được phương án [13] để xử lý tốt hơn các robot không đồng nhất. Một dòng nghiên cứu khác tăng cường các mô hình VLA bằng mô hình hành động tiềm ẩn [11, 23] để cải thiện việc ra quyết định trong môi trường năng động. Trong khi đó, những nỗ lực hướng đến hệ thống gần đây đã nhấn mạnh rằng việc triển khai VLA trên thực tế không chỉ phụ thuộc vào quy mô mô hình mà còn phụ thuộc vào chất lượng dữ liệu, phạm vi hành động và mục tiêu đào tạo để điều chỉnh tốt hơn việc đào tạo trước với quá trình thực hiện tiếp theo. Những xu hướng này chỉ ra rằng việc cải thiện các mô hình VLA trong thực tế đòi hỏi phải xử lý dữ liệu, phương án và khả năng dự đoán một cách phối hợp.

Trong công việc này, chúng tôi xây dựng dựa trên quan điểm này và giới thiệu LingBot-VLA 2.0, một phiên bản cải tiến của LingBot-VLA nhằm mục đích kết nối các khả năng VLA cấp nền tảng với việc triển khai robot thực tế. Thay vì tập trung vào một cải tiến duy nhất, LingBot-VLA 2.0 cải tiến hệ thống dọc theo ba miền chức năng mà chúng tôi thấy đặc biệt quan trọng đối với việc triển khai trong thế giới thực. Đầu tiên, để cải thiện *khả năng khái quát hóa* giữa các nhiệm vụ và phương án, chúng tôi thiết kế lại quy trình xử lý dữ liệu và tuyển chọn kho dữ liệu đào tạo trước quy mô lớn với khoảng 60.000 giờ, bao gồm 50.000 giờ quỹ đạo của rô-bốt trải dài trên 20 cấu hình rô-bốt và 10.000 giờ video về con người lấy cái tôi làm trung tâm. Thiết kế này nhằm mục đích cung cấp phạm vi bao quát rộng hơn cho cả mẫu phương án và kịch bản tương tác. Thứ hai, để hỗ trợ nhiều loại robot thực tế hơn, chúng tôi mở rộng mô hình này sang *không gian hành động mở rộng* ngoài nền tảng hai cánh tay tiêu chuẩn, cho phép điều khiển trên đầu, thắt lưng, để di động và bàn tay khéo léo. Giao diện điều khiển mở rộng này cho phép hệ thống giải quyết các nhiệm vụ phức tạp hơn đòi hỏi sự tương tác phối hợp toàn bộ cơ thể. Thứ ba, để cải thiện lý luận tạm thời trong môi trường động, như trong Hình 1, chúng tôi giới thiệu *mô hình động lực học dự đoán* như một mục tiêu đại diện. Cụ thể, chúng tôi xây dựng dự đoán trong tương lai bằng cách sử dụng mô hình trình bày video để cung cấp các ưu tiên ngữ nghĩa và mô hình ước tính độ sâu để cung cấp các tín hiệu hình học, khuyến khích mô hình VLA suy luận về diễn biến cảnh trong tương lai và hậu quả hành động. Giả thuyết trọng tâm của chúng tôi là các hệ thống VLA thực tế không chỉ mở rộng quy mô mô hình và dữ liệu mà còn trở nên phù hợp hơn với nhu cầu của robot trong thế giới thực: hỗ trợ phương án rộng hơn, không gian hành động có thể kiểm soát phong phú hơn và hiểu biết dự đoán mạnh mẽ hơn về các cảnh động. Theo quan điểm này, LingBot-VLA 2.0 được dự định là một bước đi từ khả năng ở cấp độ nền tảng tới khả năng sử dụng theo định hướng ứng dụng.

Chúng tôi đánh giá LingBot-VLA 2.0 trong cài đặt tổng quát trên chín tác vụ từ tiêu chuẩn thao tác hai cánh tay GM-100 [36], cũng như trên hai tác vụ thao tác di động tầm xa. Kết quả cho thấy các sửa đổi được đề xuất luôn cải thiện khả năng thực tế, xác nhận tầm quan trọng của việc cùng nhau tăng cường khái quát hóa, bao phủ không gian hành động và mô hình động lực học dự đoán. Nhìn chung, công việc của chúng tôi nêu bật một hướng đi thực tế nhằm thúc đẩy các mô hình nền tảng VLA từ thành công trong phòng thí nghiệm đến khả năng ứng dụng trong thế giới thực.




Hình 2. Trực quan hóa tập dữ liệu đào tạo trước được LingBot-VLA-2.0 sử dụng. Bộ dữ liệu bao gồm 20 phương án robot với tư do ở cánh tay, đầu, thắt lưng, để di động và bàn tay khéo léo.

2 Công việc liên quan

2.1 Chính sách điều khiển robot tổng quát

Các mô hình tầm nhìn-ngôn ngữ-hành động (VLA) gần đây [4–8, 10, 14, 30, 32–34, 39, 41, 42, 47] đã thiết lập mô hình VLA nền tảng như một mô hình đầy hứa hẹn cho điều khiển robot tổng quát. Những nỗ lực hiện tại đã cải thiện hệ thống VLA theo một số hướng bổ sung, bao gồm mở rộng quy mô dữ liệu robot không đồng nhất và các công thức đào tạo trước thống nhất để khái quát hóa giữa các nhiệm vụ và phương án [34, 43, 46, 47], tận dụng dữ liệu lấy con người làm trung tâm như video lấy con người làm trung tâm và chuyển động tay để tìm hiểu các ưu tiên được thể hiện có thể chuyển nhượng [20–22], giới thiệu kiến trúc nhận biết theo phương án hoặc không gian hành động hợp nhất để hỗ trợ tốt hơn cho việc chuyển giao đa nền tảng [18] và kết hợp các tính năng dự đoán hoặc mục tiêu mô hình hóa thể giới để cải thiện lý luận tạm thời và ra quyết định nhận thức về tương lai [11, 23]. Các công trình khác nâng cao hơn nữa các mô hình VLA thông qua giám sát nhận thức hình học [49], thống nhất hành động-lý luận tự hồi quy [13] hoặc thiết kế hệ thống hướng triển khai để thực thi trong thế giới thực [15, 47]. Cùng với nhau, những nghiên cứu này chứng minh sự tiến bộ nhanh chóng của các mô hình VLA nền tảng, đồng thời nhấn mạnh rằng việc triển khai thực tế vẫn đòi hỏi phải cùng nhau giải quyết vấn đề khái quát hóa quy mô lớn, phương án phong phú hơn và hỗ trợ không gian hành động.



Hình 3. Đường dẫn xử lý dữ liệu.

2.2 Mô hình hành động-ngôn ngữ-tầm nhìn kết hợp giữa các chuyên gia

Hỗn hợp các chuyên gia (MoE) đã nổi lên như một cơ chế then chốt để mở rộng năng lực mô hình hóa hành động trong các hệ thống VLA. Đối với thao tác giàu tiếp xúc, ForceVLA [45] và ForceVLA2 [17] giới thiệu các mô-đun MoE nhận biết lực để hợp nhất phản hồi lực thừa thớt nhưng quan trọng với các biểu diễn ngôn ngữ hình ảnh, trong khi MoDE-VLA [29] khai thác thêm các tín hiệu lực và xúc giác để thao tác bằng tay khéo léo. Đối với các nhiệm vụ có tầm nhìn dài, AtomicVLA [48] cấu trúc các chuyên gia xung quanh các kỹ năng nguyên tử để giảm thiểu nhiễu giữa các giai đoạn, trong khi SAMoE-VLA [44] tạo điều kiện cho việc định tuyến của chuyên gia trên các biểu diễn cấp cảnh thay vì chỉ các tính năng cấp mã thông báo. Các công trình khác [3, 12, 21] giới thiệu các cấu trúc MoE để giải quyết vấn đề chuyên môn hóa bộ phận cơ thể hình người và pha chuyển động cũng như tính không đồng nhất ở cấp độ phương án. Trong quá trình đào tạo trước VLA quy mô lớn, các biểu diễn hành động được định hình chung bởi nhiều yếu tố phức tạp, bao gồm động lực học theo phương án cụ thể, logic điều khiển phụ thuộc vào nhiệm vụ và tính đa dạng của kịch bản triển khai. Thay vì quy định ngữ nghĩa chuyên gia dựa trên bất kỳ chiều biến thể đơn lẻ nào, chúng tôi khởi tạo các lớp MoE thừa thớt ở cấp độ mã thông báo trong chuyên gia hành động, cho phép mỗi mã thông báo hành động lựa chọn chuyên gia một cách thích ứng dựa trên các tính năng nội tại của nó. Hơn nữa, chúng tôi áp dụng cơ chế cân bằng tải không mất phụ trợ [19] nhằm thúc đẩy việc sử dụng chuyên gia một cách cân bằng thông qua các sai lệch hiệu chỉnh định tuyến, loại bỏ nhu cầu đưa tồn thất cân bằng tải rõ ràng vào mục tiêu học tập hành động chính.

3 Bộ dữ liệu huấn luyện trước

Để cải thiện các mô hình VLA nhằm mang lại khả năng khái quát hóa và thực tiễn mạnh mẽ trên các phương án và môi trường động đa dạng, chúng tôi thiết kế lại quy trình xử lý dữ liệu và quản lý tập dữ liệu huấn luyện trước quy mô lớn với khoảng 60.000 giờ, như được minh họa trong Hình 2. Quy trình xử lý dữ liệu được thiết kế lại được hiển thị trong Hình 3.

3.1 Quản lý và xử lý trước dữ liệu

3.1.1 Dữ liệu robot

Chúng tôi thu thập khoảng 90.000 giờ dữ liệu từ 20 phương án, bao gồm các nền tảng robot một cánh tay, hai cánh tay và di động được trang bị bàn tay hoặc dụng cụ kẹp khéo léo. Dựa trên dữ liệu được thu thập, chúng tôi sử dụng quy trình xử lý dữ liệu được thiết kế lại để lọc các mẫu nhiễu, mang lại 50.000 giờ dữ liệu robot chất lượng cao.

Trước tiên, chúng tôi tính toán sai phân hữu hạn bậc ba (độ giật) của tín hiệu hành động và trạng thái, cùng với điểm Z của

Table 1. Statistical overview of robot manipulation data in LingBot-VLA-2.0.

Robot Type	EE type	Hand/Gripper DoF	Arm DoF	Body DoF*	Total DoF	Policy Frequency
Single-Arm Robots						
Franka	Grppier	1	7	0	8	30
Flexiv Rizon 4	Grppier	1	7	0	8	30
Dual-Arm Robots						
AgileX	Grppier	2	12	0	14	30
ARX Lift2	Grppier	2	12	0	14	30
UR7e	Grppier	2	12	0	14	30
Half-Humanoid						
AgiBot G1	Grppier	2	14	4	20	30
Galbot G1	Grppier	2	14	6	22	30
Moz1	Grppier	2	14	0	16	30
Realman Rs-02	Grppier	2	14	1	17	30
Galaxea R1Pro	Grppier	2	14	7	23	15
Galaxea R1Lite	Grppier	2	12	3	17	15
Astribot S1	Grppier	2	14	9	25	30
Zerith H1	Grppier	2	14	7	23	30
Humanoid						
Leju KUAVO 4 Pro	Grppier/Hand	2/12	14	5	21/31	30
Tienkung	Grppier	2	14	0	16	30
QingLong	Grppier	2	14	0	16	30
MagicBot Gen1	Grppier	2	14	4	20	30
Unitree G1	Hand	12	14	0	26	30
Fourier GR-2	Hand	12	14	6	32	30
AgiBot A2	Hand	12	14	2	28	30
Humanoid						
Ego	-	-	14	-	14	30~60
Total: 20 embodiments						60000h


* The total number of body DoF used for model training.

their first-order derivatives (velocity) and second-order derivatives (acceleration), to assess trajectory smoothness. An episode is discarded if either the jerk or any derivative Z-score exceeds a predefined threshold. These thresholds are set separately for each embodiment. Moreover, we measure the duration within an episode during which all state and action signals exhibit only small variations or remain unchanged. If this duration accounts for more than 95% of the entire episode, the episode is also discarded.

To verify consistency between the videos and state signals, we project the robot onto the image plane using the corresponding URDF and replay the recorded states. Human annotators are employed to identify discrepancies between the projected robot and the videos to ensure that the state signals and videos are correctly recorded, and samples with such misalignment are removed. Meanwhile, videos with blur, severe occlusions, dropped frames, or misalignment across multiple views are filtered out by human annotators during the annotation process.

3.1.2 Egocentric Data

We construct an egocentric human video pool of approximately 20,000 hours and retain around 10,000 hours of high-quality training data after filtering, reconstruction, standardization, and quality control. We first apply a unified video-level VLM pre-filter to all candidate videos, regardless of source. This step removes videos that do not satisfy the egocentric manipulation assumption, such as third-person observation videos, scene-walking videos, videos without clear hand-object interaction, or videos without manipulable objects. We also filter out videos where non-operator hands appear prominently, since such clips can break the association between the camera wearer’s observation and the corresponding hand motion. Applying this VLM filtering stage before downstream processing reduces unnecessary annotation and reconstruction cost, especially for action-free videos that would otherwise require SLAM and hand pose



Hình 4. Biểu diễn hành động thống nhất. Chúng tôi ánh xạ các điều khiển phương án không đồng nhất thành các vector hành động nhỏ gọn bao gồm các thành phần bộ phận cơ thể dùng chung.

ước tính.

Sau khi lọc trước VLM, chúng tôi xử lý dữ liệu còn lại tùy theo nhãn hành động hoặc quỹ đạo tay có sẵn hay không. Đối với dữ liệu có nhãn hành động hoặc quỹ đạo tay hiện có, bao gồm bộ dữ liệu nguồn mở được gắn nhãn hành động và dữ liệu nội bộ, chúng tôi thực hiện tổ chức siêu dữ liệu, căn chỉnh dấu thời gian, chuyển đổi tọa độ và kiểm tra tính hoàn chỉnh của quỹ đạo, chuyển đổi tất cả các mẫu sang định dạng quỹ đạo tay được tiêu chuẩn hóa. Đối với các video có con người lấy cái tôi làm trung tâm mà không cần hành động, chúng tôi chạy SLAM lấy cái tôi làm trung tâm để ước tính các thông số bên trong của máy ảnh và các thông số bên ngoài của máy ảnh trên mỗi khung hình, sau đó áp dụng ước tính tư thế bàn tay để khôi phục các tham số MANO trong khung tọa độ của máy ảnh. Bằng cách kết hợp các tư thế bàn tay ước tính với tư thế máy ảnh, chúng tôi đưa chuyển động của tay vào khung tọa độ thế giới và thu được quỹ đạo tay liên tục theo thời gian.

Sau đó, chúng tôi áp dụng kiểm soát chất lượng ở cấp độ quỹ đạo cho dữ liệu được xây dựng lại và chuẩn hóa. Chúng tôi lọc ra những video có phạm vi bao phủ tư thế bàn tay không đủ hợp lệ, sử dụng tỷ lệ khung hình hợp lệ 20% làm ngưỡng tối thiểu. Chúng tôi cũng xóa các clip có quỹ đạo SLAM không ổn định, được xác định bằng những thay đổi bất thường ở bậc hai trong chuyển động ước tính của camera, chẳng hạn như gia tốc tịnh tiến hoặc gia tốc quay đột ngột. Ngoài ra, chúng tôi từ chối các quỹ đạo tay có sự gián đoạn đột ngột, dịch chuyển, vận tốc, gia tốc hoặc giật bất thường cũng như các mẫu vi phạm các giới hạn sinh lý của con người, chẳng hạn như vị trí tay, khoảng cách giữa các bàn tay, phạm vi chuyển động hoặc tư thế không hợp lý.

Cuối cùng, tất cả các mẫu hợp lệ sẽ được lưu trữ dưới dạng quỹ đạo kim tay trong khung tọa độ thế giới. Trong quá trình đào tạo, khi một khung được lấy mẫu làm quan sát hiện tại, chúng tôi sẽ chuyển đổi quỹ đạo của kim tương lai từ khung tọa độ thế giới sang khung tọa độ máy ảnh hiện tại bằng cách sử dụng camera bên ngoài của khung đó:

$$\mathbf{p}_{\tau}^{C_t} = \mathbf{T}_{C_t \leftarrow W} \mathbf{p}_{\tau}^W. \quad (1)$$

Ở đây, $\mathbf{p}_{\tau}^W$ biểu thị quỹ đạo bàn tay trong khung tọa độ thế giới và $\mathbf{T}_{C_t \leftarrow W}$ biểu thị sự chuyển đổi từ khung tọa độ thế giới sang khung tọa độ camera của khung được lấy mẫu t . Với thiết kế này, khung tọa độ thế giới đóng vai trò là không gian lưu trữ quỹ đạo thống nhất, trong khi khung tọa độ camera hiện tại đóng vai trò là biểu diễn hành động trong thời gian huấn luyện. Điều này thống nhất các định dạng quỹ đạo trên các video nguồn mở và video con người lấy tự nhiên làm trung tâm, đồng thời tách chuyển động của tay khỏi chuyển động của máy ảnh lấy tự nhiên trong quá trình đào tạo.

3.1.3 Đại diện hành động thống nhất

Để cùng tìm hiểu các cách biểu diễn trạng thái và hành động từ dữ liệu tự nhiên và dữ liệu robot được thu thập trên nhiều phương án, chúng tôi sử dụng biểu diễn vector chuẩn 55 chiều cho cả trạng thái và hành động. Biểu diễn này bao gồm 14 chiều cho vị trí khớp cánh tay, 14 chiều cho tư thế tác động cuối, 2 chiều cho vị trí kẹp, 12 chiều cho vị trí khớp tay, 4 chiều cho vị trí thắt lưng, 2 chiều cho vị trí đầu và 3 chiều cho tín hiệu di chuyển, như trong Hình 4. 4 chiều còn lại được bảo lưu. Các trường vị trí khớp cánh tay và tư thế tác động cuối được xác định để phù hợp với kích thước tối đa của phương án hai cánh tay. Cụ thể, tư thế tác động cuối của mỗi cánh tay được biểu thị bằng tọa độ XYZ và một tứ phương xoay, tạo ra 7 chiều cho mỗi cánh tay. Đối với dữ liệu một cánh tay, chỉ 6 hoặc 7 chiều được sử dụng cho các vị trí khớp cánh tay và 7 chiều cho tư thế tác động cuối, trong khi các kích thước liên quan đến cánh tay còn lại được đệm. Tương tự, đối với các phương án robot không bao gồm các bộ phận cơ thể cụ thể hoặc có tín hiệu chiều thấp hơn, các kích thước tương ứng cũng được đệm. Các cấu hình kích thước cho từng phương án được hiển thị trong Tab. 1.

Bảng 2. Từ vựng đóng cho chú thích nhiệm vụ con. Từ vựng bao gồm 15 hành động thao tác cơ bản và ba nhân phụ: chuyển động cho chuyển động tay không, nhân rồi cho cánh tay đứng yên và nhân khác cho các hành động ngoài từ vựng.

hành động	Mô tả	hành động	Mô tả
Các thao tác nguyên thủy di chuyển Di chuyển một đối tượng			
đổ	Nghiêng một thùng chứa để phân phối nội dung	gấp lại	Thu nhỏ vật liệu linh hoạt
đẩy	Trượt một vật thể không được giữ	mở ra	Mở rộng vật liệu linh hoạt
kéo	Về một vật thể lại gần hơn	lau	Di chuyển một công cụ trên một bề mặt
xoay	Xoay một vật vào đúng vị trí	khuấy động	Di chuyển một công cụ theo vòng tròn trong một thùng chứa
mở	Mở một đối tượng có bản lề hoặc khớp nối	cắt	Cắt đứt mục tiêu bằng lưỡi kiếm
đóng	Đóng một đối tượng có bản lề hoặc khớp nối	nhấn	Nhấn nút, công tắc hoặc bề mặt
tách ra	Loại bỏ hoặc ngắt kết nối một vật thể khỏi khớp nối	đỉnh kèm	Chèn hoặc kết nối một đối tượng với một khớp nối
Vận chuyển nhân phụ trợ Di chuyển kẹp mà không cần tương tác với vật thể			
		nhân rồi	Giữ cánh tay cố định
hành động khác ngoài từ vựng			

3.2 Chú thích dữ liệu

Việc đào tạo trước VLA được hưởng lợi từ các video thao tác kết hợp với giám sát ngôn ngữ được căn chỉnh theo thời gian ở cả cấp độ nhiệm vụ và nhiệm vụ phụ. Chúng tôi tạo các chú thích này bằng một quy trình hoàn toàn tự động được xây dựng trên mô hình ngôn ngữ tầm nhìn và áp dụng quy trình này trên tập dữ liệu huấn luyện trước.

Cụ thể, chúng tôi sử dụng Qwen3.6-27B [25] để phân đoạn từng video thao tác thành một chuỗi các nhiệm vụ con liên kế theo thời gian và để tạo ra các hướng dẫn ngôn ngữ tương ứng. Đối với các nền tảng robot có nhiều camera, chế độ xem từ trên cao và cổ tay được xử lý chung để phân biệt các tương tác giữa vật thể và vật kẹp. Mỗi nhiệm vụ phụ được gán một hành động cơ bản từ vốn từ vựng đóng gồm 18 danh mục (Bảng 2), cùng với đối tượng tương tác chính và hướng dẫn ngắn gọn. Ngoài ra, một hướng dẫn ở cấp độ video sẽ tóm tắt nhiệm vụ tổng thể. Các đối tượng được chú thích tạo thành một vốn từ vựng mở, đa dạng, như được hiển thị trong Hình 6.

Để duy trì mức độ chi tiết của phân đoạn nhất quán, mô hình nhóm các giai đoạn nắm, mang và giải phóng của một tương tác thành một nhiệm vụ phụ và chỉ đưa ra ranh giới tạm thời khi đối tượng bị thao tác thay đổi, loại hành động thay đổi hoặc tạm dừng liên tục đánh dấu sự chuyển đổi sang mục tiêu phụ mới. Như được tóm tắt trong Hình 5, *di chuyển* và *vận chuyển* chiếm ưu thế về tần suất, trong khi các thao tác chi tiết như *cắt*, *gấp* và *khuấy* rất hiếm nhưng có thời lượng trung bình dài hơn đáng kể.

4 Phương pháp

4.1 Mô hình VLA dựa trên MoE

Các mô hình Tầm nhìn-Ngôn ngữ-Hành động (VLA) được huấn luyện trước trên dữ liệu robot đa phương án trong thế giới thực phải học hỏi từ các quỹ đạo không đồng nhất được đặc trưng bởi các không gian hành động bị lệch, động lực của phương án khác nhau và sự phân bổ nhiệm vụ. Mặc dù cơ chế Hỗn hợp các chuyên gia (MoE) cung cấp một cách tự nhiên để mở rộng năng lực mô hình, nhưng những lý do cơ bản về tính hiệu quả của nó trong việc đào tạo trước VLA vẫn chưa được hiểu rõ. Trong báo cáo này, chúng tôi giới thiệu kiến trúc MoE không mất mát ở cấp độ mã thông báo để đào tạo trước VLA đa phương án quy mô lớn. Bằng cách tách cân bằng tải chuyên gia khỏi mục tiêu học hành động chính và sử dụng độ tin cậy định tuyến dựa trên sigmoid để cho phép mỗi mã thông báo kích hoạt độc lập nhiều chuyên gia, thiết kế của chúng tôi cho phép các chuyên gia thừa thớt nắm bắt các biểu diễn chung và logic điều khiển được chia sẻ trên các phương án.

Kiến trúc MoE thừa thớt. Để tạo điều kiện cho sự hội tụ trong quá trình đào tạo trước nhiều phương án, chúng tôi khởi tạo các lớp MoE thừa thớt bên trong chuyên gia hành động, thay thế mạng chuyển tiếp nguồn cấp dữ liệu (FFN) trong chuyên gia hành động. Trong cấu hình mặc định của chúng tôi, tất cả các khối biến áp chuyên nghiệp hành động đều được trang bị MoE FFN. Hơn nữa, chúng tôi áp dụng phân đoạn chuyên gia chi tiết và cách ly chuyên gia được chia sẻ, trong đó một chuyên gia được chia sẻ nhẹ sẽ duy trì các ưu tiên phổ quát, trong khi một tập hợp các chuyên gia được định tuyến cung cấp khả năng lập mô hình chuyên biệt.

trong đó $e_{\ell,j}$ là phần nhúng bộ định tuyến có thể học được của chuyên gia định tuyến thứ j . Để tránh sự cạnh tranh mạnh mẽ giữa các chuyên gia do chuẩn hóa softmax gây ra, chúng tôi áp dụng chức năng kích hoạt sigmoid cho nhật ký bộ định tuyến theo DeepSeek-V3 [19], mối quan hệ giữa mã thông báo với chuyên gia được xác định là

$$s_{\ell,j}(u_{\ell,t}) = \text{Sigmoid}(z_{\ell,j}(u_{\ell,t})). \quad (5)$$

Để duy trì mục tiêu chính của việc học kiểm soát hành động trong các mô hình VLA, chúng tôi áp dụng chiến lược không mất mát phụ trợ lấy cảm hứng từ DeepSeek-V3 [19] để thúc đẩy cân bằng tải trong kiến trúc MoE. Trong phương pháp cân bằng không mất mát phụ trợ, mỗi chuyên gia duy trì độ lệch hiệu chỉnh định tuyến $b_{\ell,j}$. Trọng lượng hỗn hợp thực tế vẫn được tính toán từ các mối quan hệ không thiên vị ban đầu:

$$g_{\ell,j}(u_{\ell,t}) = \frac{s_{\ell,j}(u_{\ell,t})}{\sum_{k \in \mathcal{R}(u_{\ell,t})} s_{\ell,k}(u_{\ell,t})}, \quad j \in \mathcal{R}(u_{\ell,t}), \quad (6)$$

trong khi tập chuyên gia định tuyến được chọn được xác định bởi các mối quan hệ sai lệch:


$$\mathcal{R}(u_{\ell,t}) = \text{TopK}_j(s_{\ell,j}(u_{\ell,t}) + b_{\ell,j}, K). \quad (7)$$

Cơ chế cân bằng dựa trên thành kiến này tách rời việc phân công chuyên gia khởi định tuyến chuyên gia. Cụ thể, độ lệch hiệu chỉnh được sử dụng để thúc đẩy cân bằng tải, trong khi độ tin cậy định tuyến vẫn được tính bằng điểm số ái lực không thiên vị ban đầu của mô hình. Trong quá trình đào tạo, chúng tôi tích lũy số lượng mã thông báo được chỉ định cho từng chuyên gia qua các cấp bậc vi mô và phân bổ. Tại mỗi lần cập nhật cân bằng tải, độ lệch hiệu chỉnh được điều chỉnh theo dấu của độ lệch so với tải chuyên gia trung bình:

$$b_{\ell,j} \leftarrow b_{\ell,j} - \gamma \cdot \text{sign} \left(n_{\ell,j} - \frac{1}{N_r} \sum_{k=1}^{N_r} n_{\ell,k} \right), \quad (8)$$

trong đó $n_{\ell,j}$ là tải tích lũy của chuyên gia j trong lớp ℓ , và γ là tốc độ cập nhật thiên vị. Tùy chọn, vectơ thiên vị được căn giữa sau mỗi lần cập nhật để ngăn chặn sự trôi tích lũy. Sau đó, đầu ra MoE được đưa trở lại qua nhánh dư FFN ban đầu của máy biến áp chuyên dụng hành động.

Thí nghiệm mở rộng quy mô. Để xác thực tính hiệu quả của kiến trúc thừa thớt trong phạm vi điện toán giống hệt nhau, chúng tôi tiến hành so sánh toàn diện giữa các mô hình MoE và Mật độ với số lượng tham số hoạt động được khớp chính xác. Kết quả thử nghiệm được hiển thị trong Hình 7 chỉ ra rằng MoE luôn đạt được mức mất mát đào tạo và lỗi xác thực thấp hơn so với đối tác dày đặc của nó. Ưu điểm này được quan sát thấy trên cả số liệu tối ưu hóa và tổng quát hóa, cho thấy rằng mức tăng hiệu suất của MoE không chỉ phát sinh từ tổng số tham số tăng lên mà còn từ việc phân bổ công suất mô hình hiệu quả hơn thông qua kích hoạt thừa thớt. Những kết quả này chứng minh rằng, với ngân sách điện toán cố định, kiến trúc MoE thừa thớt đạt được quy mô hiệu quả hơn với việc giảm thiểu đào tạo và lỗi xác thực, biến nó thành một chiến lược mở rộng quy mô hiệu quả hơn cho đào tạo trước VLA.



Hình 7. So sánh tỷ lệ tham số hoạt động có thể so sánh giữa mô hình Mật độ dày đặc và mô hình MoE bằng cách sử dụng tổn thất đào tạo trên dữ liệu đào tạo trước và lỗi hành động xác thực trên các nhiệm vụ GM-100.

4.2 VLA nhận biết không gian theo thời gian thông qua quá trình chất lọc truy vấn kép

Để nâng cao cả nhận thức về hình học và hiểu biết về thời gian theo nguyên nhân trong LingBot-VLA 2.0, chúng tôi áp dụng khung chất lọc truy vấn kép lấy cảm hứng từ các công trình gần đây [35], trong đó LingBot-Depth và DINO-Video nhận biết robot của chúng tôi

đóng vai trò là giáo viên hỗ trợ. Cụ thể, chúng tôi nối thêm hai truy vấn có thể học được, $[\mathbf{Q}_t, \mathbf{Q}_{t+T}]$, vào các mã thông báo bằng hình ảnh và văn bản, trong đó $\mathbf{Q}_t$ nhắm mục tiêu quan sát hiện tại và $\mathbf{Q}_{t+T}$ nhắm mục tiêu quan sát trong tương lai ở đường chân trời T (tức là, kích thước khối hành động). Sau đó, các trạng thái truy vấn theo ngữ cảnh này được chất lọc từ hai giáo viên bổ sung: giáo viên chuyên sâu, LingBot-Depth [28], cung cấp khả năng giám sát hình học rõ ràng và giáo viên video nhân quả, DINO-Video, cung cấp các biểu diễn trực quan dựa trên thời gian.

LingBot-Depth để giám sát hình học. Để đưa các ưu tiên về không gian và hình học rõ ràng vào LingBot-VLA 2.0, chúng tôi căn chỉnh các trạng thái truy vấn kép với các mã thông báo độ sâu được trích xuất từ LingBot-Depth. Cụ thể, các truy vấn hiện tại và tương lai, $[\mathbf{Q}_t, \mathbf{Q}_{t+T}]$, được đào tạo để dự đoán các biểu diễn độ sâu tương ứng $[\mathbf{D}_t, \mathbf{D}_{t+T}]$ từ các khung thao tác hiện tại và tương lai. Mục tiêu chung cắt độ sâu là

$$\mathcal{L}_{depth} = \mathbb{E} \left[\|\text{Proj}_{depth}(\mathbf{Q}_t) - \mathbf{D}_t\|_1 + \|\text{Proj}_{depth}(\mathbf{Q}_{t+T}) - \mathbf{D}_{t+T}\|_1 \right], \quad (9)$$

trong đó $\text{Proj}_{depth}(\cdot)$ biểu thị một mô-đun chiếu có sự chú ý chéo đến việc căn chỉnh các chiều. Trong kiến trúc VLM nhân quả, $\mathbf{Q}_t$ ghi lại hình dạng cảnh ngay lập tức, trong khi $\mathbf{Q}_{t+T}$ học cách dự đoán các cấu trúc hình học trong tương lai có liên quan đến thao tác sắp tới.

DINO-Video nhân quả để giám sát tạm thời. Mặc dù giám sát độ sâu cung cấp cấu trúc hình học nhưng nó không nắm bắt được động lực học thời gian nhân quả cần thiết cho việc điều khiển robot. Được thúc đẩy bởi sự thành công của các biểu diễn trực quan tiềm ẩn trên một loạt các ứng dụng hành động và robot [9, 11, 22–24, 27], chúng tôi giới thiệu DINO-Video, một mô hình biểu diễn video nhận biết robot được xây dựng dựa trên xương sống hình ảnh DINOv3 [26]. Không giống như các tính năng ở cấp độ hình ảnh được trích xuất độc lập cho từng khung hình, DINO-Video tạo ra các biểu diễn trực quan nhận biết chuyển động với sự chú ý về thời gian theo nguyên nhân, sao cho tính năng ở mỗi bước thời gian chỉ phụ thuộc vào các quan sát hiện tại và quá khứ. Với các trạng thái truy vấn được ngữ cảnh hóa $[\mathbf{Q}_t, \mathbf{Q}_{t+T}]$, truy vấn hiện tại được đào tạo để dự đoán tính năng DINO-Video của khung hình hiện tại, trong khi truy vấn trong tương lai được đào tạo để dự đoán tính năng của khung hình tương lai ở đường chân trời T . Biểu thị mục tiêu của giáo viên là $[\mathbf{Z}_t, \mathbf{Z}_{t+T}]$, được trích từ một lần chuyển tiếp nhân quả duy nhất của DINO-Video qua clip quan sát tương ứng, mục tiêu chất lọc video là

$$\mathcal{L}_{video} = \mathbb{E} \left[\|\text{Proj}_{video}(\mathbf{Q}_t) - \mathbf{Z}_t\|_F^2 + \|\text{Proj}_{video}(\mathbf{Q}_{t+T}) - \mathbf{Z}_{t+T}\|_F^2 \right], \quad (10)$$

trong đó $\text{Proj}_{video}(\cdot)$ ánh xạ các trạng thái truy vấn vào không gian tính năng cấp bản vá của DINO-Video. Mục tiêu này khuyến khích LingBot-VLA 2.0 khôi phục cả biểu diễn nhận biết chuyển động hiện tại và phiên bản tương lai của nó, bổ sung cho khả năng giám sát hình học từ quá trình chung cắt độ sâu.

Thông tin chi tiết về DINO-Video nhận biết robot. Chúng tôi khởi tạo DINO-Video từ DINOv3 và mở rộng nó với sự chú ý thời gian nhân quả theo khối và nhúng vị trí quay 3D (3D-RoPE) [37], cho phép lập mô hình video nhân quả trong khi vẫn bảo tồn ngữ nghĩa không gian và các ưu tiên hình học được kế thừa từ DINOv3. Chúng tôi đào tạo DINO-Video trên các video clip 5 triệu bao gồm dữ liệu Internet, dữ liệu tự nhiên và robot, sử dụng các mục tiêu tự chất lọc DINO và iBOT được điều chỉnh bằng video [40]. Đối với mỗi mẫu, chúng tôi lấy mẫu thống nhất 16 khung hình và chỉ định mã hóa thời gian tuyệt đối dựa trên tốc độ khung hình hiệu quả để phân biệt các clip có khoảng thời gian thực khác nhau [1]. Trên LARYBench [24] (xem Tab. 3), DINO-Video đạt được hiệu suất tốt nhất trên ba trong bốn điểm chuẩn, hỗ trợ tính hiệu quả của nó với tư cách là một giáo viên tạm thời nhận biết về robot.

Bảng 3. Lại kết quả của DINO-Video về Phân loại và hồi quy LARYBench E định giá.

Model	Params(M)	Classification		Regression	
		<i>Composite Human</i> ↑	<i>Composite Robot</i> ↑	<i>RoboCOIN</i> ↓	<i>AgiBotWorld-Beta</i> ↓
V-JEPA 2 [2]	303.89	80.35	70.43	0.32	0.33
DINOv3 [26]	303.13	76.19	69.06	0.22	0.24
DINO-Video	303.13	80.21	71.97	0.20	0.19

Bảng 4. Tiêu chí chấm điểm cho phần nhiệm vụ benchmark GM-100.

ID nhiệm vụ	Nhiệm vụ	Tiêu chí chấm điểm
BM-19	Sắp xếp khối	1. Lấy khối lớn nhất trên bàn (16). 2. Đặt khối lớn nhất ở phía bên trái (12). 3. Lấy khối lớn thứ hai trên bàn (12). 4. Đặt khối lớn thứ hai ở bên phải khối lớn nhất (12). 5. Lấy khối lớn thứ ba trên bàn (12). 6. Đặt khối lớn thứ ba ở bên phải khối lớn thứ hai (12). 7. Nhặt khối nhỏ nhất trên bàn (12). 8. Đặt khối nhỏ nhất ở ngoài cùng bên phải (12).
BM-20	Truy xuất chuỗi khóa	1. Kéo mở ngăn kéo (25). 2. Nằm móc khóa (25). 3. Di chuyển móc khóa ra phía trước ngăn kéo (25). 4. Đặt móc khóa xuống (25).
BM-25	Mức com	1. Nhấc thìa bằng tay phải (20). 2. Dùng thìa mức com từ bát (30). 3. Đổ gạo vào cốc (30). 4. Đặt thìa trở lại đĩa (20).
BM-39	Thay cuộn giấy	1. Tháo lõi cuộn giấy trống (22). 2. Đặt lõi lên khay (22). 3. Nhấc cuộn giấy mới lên (22). 4. Lắp cuộn giấy mới vào ngăn chứa (34).
BM-45	Sắp xếp đồ ăn nhẹ	1. Chọn loại đồ ăn nhẹ đầu tiên (18). 2. Đặt nó vào hộp chứa tương ứng (16). 3. Chọn loại đồ ăn nhẹ thứ hai (17). 4. Đặt nó vào hộp chứa tương ứng (16). 5. Chọn loại đồ ăn nhẹ thứ ba (17). 6. Đặt nó vào hộp chứa tương ứng (16).
BM-47	gói trứng	1. Nhặt quả trứng đầu tiên (16). 2. Đặt quả trứng vào khe khay (12). 3. Nhặt quả trứng thứ hai (12). 4. Đặt quả trứng vào khe khay (12). 5. Nhặt quả trứng thứ ba (12). 6. Đặt quả trứng vào khe khay (12). 7. Nhặt quả trứng thứ tư (12). 8. Đặt quả trứng vào khe khay (12).
BM-69	Chọn xương đồ chơi	1. Nhặt xương đồ chơi đầu tiên (25). 2. Lấy xương ra khỏi đĩa (25). 3. Nhặt xương đồ chơi thứ hai (25). 4. Lấy xương ra khỏi đĩa (25).
BM-75	Đẩy bóng vào hộp	1. Đẩy bóng về phía hộp (30). 2. Đẩy bóng vào hộp (70).
BM-82	nước sốt cà chua ép	1. Nhấc chai nước sốt cà chua bằng tay trái và giữ nó phía trên đĩa (25). 2. Nghiêng chai sao cho vòi hướng về phía đĩa (25). 3. Bóp chai bằng cả hai tay để lấy sốt cà chua (25). 4. Đặt chai nước sốt cà chua xuống (25).
BM-97	Lấy bát ra khỏi lò vi sóng	1. Mở cửa lò vi sóng (25). 2. Đặt bát vào trong lò vi sóng (25). 3. Di chuyển bát lên bàn và đặt nó xuống (25). 4. Đóng cửa lò vi sóng (25).
BM-105	Đóng gói công cụ	1. Nhấc băng dính lên và đặt nó vào hộp dụng cụ (20). 2. Nhấc thước dây lên và đặt vào hộp dụng cụ (20). 3. Nhấc tuốc nơ vít lên và đặt vào hộp dụng cụ (20). 4. Nhấc dao cắt và đặt nó vào hộp dụng cụ (20). 5. Đóng hộp công cụ (20).
BM-107	Quét mã vạch	1. Nhấc hộp thuốc lên và cầm lên bằng tay trái (20). 2. Nhấc máy quét mã vạch bằng tay phải (20). 3. Quét mã vạch trên hộp thuốc bằng máy quét (20). 4. Đặt máy quét mã vạch xuống (20). 5. Đặt hộp thuốc xuống (20).

5 thí nghiệm

5.1 Cài đặt thử nghiệm

Tiêu chí chấm điểm. Bảng 4 tóm tắt các tiêu chí chấm điểm cho một tập hợp con các nhiệm vụ chuẩn GM-100. Mỗi nhiệm vụ được phân tách thành một chuỗi các bước thao tác chi tiết và điểm từng phần được ấn định cho mỗi bước theo

hoàn thành nhiệm vụ. Các tiêu chí này bao gồm các khả năng đa dạng của hai tay, bao gồm phân loại, truy xuất, xúc, thay thế, đóng gói, đẩy, ép và phối hợp xử lý đồ vật. Các chú thích từng bước như vậy cho phép đánh giá chi tiết hơn so với chỉ thành công nhị phân, nắm bắt được một phần tiến trình trong các nhiệm vụ thao tác trong thời gian dài.

5.2 Kết quả thí nghiệm thao tác bằng tay

Bảng 5. Hiệu suất trên tiêu chuẩn GM-100 hai tay trong cài đặt chung. Chúng tôi báo cáo điểm tiến độ (Prog., %) và tỷ lệ thành công (Succ., %) cho mỗi nhiệm vụ. Hàng bóng mờ trong mỗi khối nền tảng báo cáo mức trung bình của chín nhiệm vụ.

Task	GR00T N1.7		$\pi_{0.5}$		LingBot-VLA-1.0		LingBot-VLA-2.0	
	Prog.	Succ.	Prog.	Succ.	Prog.	Succ.	Prog.	Succ.
Agilex Cobot Magic								
Overall average	36.3	17.8	59.1	32.2	58.2	30.0	66.2	34.4
Block sorting	40.0	10.0	90.4	60.0	59.2	10.0	56.8	0.0
Retrieve keychain	12.5	10.0	20.0	20.0	67.5	60.0	100.0	100.0
Replace paper roll	52.8	0.0	62.8	10.0	59.6	20.0	55.2	20.0
Sort snacks	91.9	70.0	82.4	30.0	74.4	10.0	66.2	10.0
Pack eggs	14.4	0.0	72.4	20.0	42.4	10.0	44.4	0.0
Pick out toy bone	70.0	60.0	100.0	100.0	77.5	70.0	95.0	90.0
Push ball into box	18.0	0.0	38.0	20.0	6.0	0.0	41.0	20.0
Take bowl out of microwave	15.0	10.0	0.0	0.0	77.5	70.0	77.5	70.0
Tool packing	12.0	0.0	66.0	30.0	60.0	20.0	60.0	0.0
Galaxea R1 Pro								
Overall average	16.4	5.6	27.4	8.9	32.7	15.6	34.6	15.6
Block sorting	8.4	0.0	12.4	0.0	28.0	0.0	33.2	0.0
Retrieve keychain	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
Replace paper roll	6.6	0.0	72.0	50.0	44.0	0.0	57.6	40.0
Sort snacks	31.3	0.0	28.1	0.0	10.6	0.0	26.1	0.0
Pack eggs	1.6	0.0	6.7	0.0	19.2	0.0	4.4	0.0
Pick out toy bone	77.5	50.0	72.5	30.0	62.5	40.0	87.5	70.0
Push ball into box	9.0	0.0	21.0	0.0	3.0	0.0	18.0	0.0
Take bowl out of microwave	7.5	0.0	7.5	0.0	97.5	100.0	65.0	30.0
Tool packing	6.0	0.0	26.0	0.0	30.0	0.0	20.0	0.0

Cài đặt thử nghiệm. Chúng tôi đánh giá thao tác hai tay trên chín nhiệm vụ từ điểm chuẩn GM-100 trong môi trường đào tạo hỗn hợp tổng quát. Không giống như đào tạo theo nhiệm vụ cụ thể, một chính sách duy nhất được đào tạo chung về tất cả các nhiệm vụ cho từng phương án, yêu cầu mô hình chia sẻ các nguyên tắc thao tác thông qua các kỹ năng hai tay khác nhau, bao gồm sắp xếp, truy xuất, đóng gói, đẩy và tương tác đối tượng khớp nối. Chúng tôi báo cáo điểm tiến độ và tỷ lệ thành công cho từng nhiệm vụ.

Phân tích kết quả. Như được hiển thị trong Tab. 5, LingBot-VLA-2.0 đạt được hiệu suất tổng thể tốt nhất trong cài đặt chung. Trên Agilex Cobot Magic, nó đạt 66,2/34,4 điểm tiến độ/tỷ lệ thành công, vượt qua LingBot-VLA-1.0 8,0/4,4 điểm và $\pi_{0.5}$ 7,1/2,2 điểm. Trên Galaxea R1 Pro đạt 34,6/15,6, vượt trội $\pi_{0.5}$ 7,2/6,7 điểm. Những kết quả này chứng minh rằng LingBot-VLA-2.0 được hưởng lợi từ việc đào tạo nhiệm vụ hỗn hợp và có được các hành vi thao tác bằng tay tổng quát hơn.

Những cải tiến này được thể hiện rõ nhất ở các nhiệm vụ đòi hỏi phải có nền tảng đối tượng chính xác và thực hiện hành động hướng đến mục tiêu. Chẳng hạn, trên Agilex *Truy xuất móc khóa*, LingBot-VLA-2.0 cải thiện hơn LingBot-VLA-1.0 từ 67,5/60,0 lên 100,0/100,0 và trên Agilex *Nhặt xương đồ chơi*, từ 77,5/70,0 lên 95,0/90,0. Mức tăng tương tự cũng được quan sát thấy trong nhiệm vụ *Nhặt xương đồ chơi* của Galaxea, trong đó hiệu suất tăng từ 62,5 / 40,0 lên 87,5 / 70,0. Những cải tiến này phù hợp tốt với thiết kế của LingBot-VLA-2.0, sử dụng nền tảng VLM mạnh hơn với khả năng nổi bật nâng cao và điều kiện dự đoán hành động về thông tin trong tương lai, cùng nhau cho phép thao tác tập trung vào đối tượng hơn và nhất quán với mục tiêu hơn.

Tuy nhiên, mức tăng không đồng đều giữa các nhiệm vụ. Một số nhiệm vụ vẫn còn có khoảng cách đáng kể giữa tiến độ




Figure 8. Per-subtask performance on the long-horizon mobile manipulation benchmark. Bars report the mean subtask completion score (%) across 15 trials under both in-domain (ID) and out-of-distribution (OOD) settings.

score and success rate, indicating that the model often makes partial progress but fails at the final precise placement, release, or completion step. Moreover, the performance disparity between Agilex Cobot Magic and Galaxea R1 Pro suggests that embodiment-specific factors, such as kinematics, camera viewpoints, and action-space alignment, remain challenging. Overall, LingBot-VLA-2.0 delivers consistent improvements in generalist bimanual manipulation, particularly on tasks requiring strong visual grounding and future-aware action planning.

5.3 Long-Horizon Mobile Manipulation Experiment Results

Table 6. Long-horizon mobile manipulation benchmark results, reported as progress score / success rate (%).

Embodiment	Task	Setting	LingBot-VLA-2.0	$\pi_{0.5}$
Astribot S1	Sort objects into refrigerator	In-domain	77.1 / 60.0	65.3 / 46.7
		Out-of-distribution	37.0 / 13.3	30.3 / 6.7
Cobot Magic-ARX X5	Stove cleaning	In-domain	84.3 / 66.7	79.9 / 60.0
		Out-of-distribution	67.5 / 40.0	62.5 / 33.3


Experiment settings. We evaluate long-horizon mobile manipulation performance on two robotic embodiments, as illustrated in Fig. 9. Each embodiment is associated with one representative task: Astribot S1 is evaluated on the object sorting task, where objects are collected and placed into a refrigerator, while Cobot Magic-ARX X5 is evaluated on the stove cleaning task. The detailed sub-task decomposition and corresponding scoring criteria for each task are listed in Tab. 7. For each task, we evaluate each model under two settings: in-domain (ID) and out-of-distribution (OOD).

Mỗi cặp thiết lập nhiệm vụ được đánh giá bằng 15 thử nghiệm độc lập. Trong cài đặt trong miền, cả vị trí ban đầu của robot và các đối tượng được điều khiển đều được rút ra từ phân bố huấn luyện. Trong cài đặt ngoài phân phối, vị trí ban đầu của robot bị xáo trộn trong vòng ± 10 cm dọc theo các hướng tiến, lùi, trái và phải xung quanh vị trí ban đầu danh nghĩa. Ngoài ra, đối với nhiệm vụ phân loại tủ lạnh, hai loại trái cây và chai nước đặt vào tủ lạnh được thay thế bằng các loại vật thể không nhìn thấy được. Cài đặt này được thiết kế để đánh giá khả năng khái quát hóa của mô hình trong các điều kiện vị trí và đối tượng không nhìn thấy.

Phân tích kết quả. Như được hiển thị trong Tab. 6, LingBot-VLA-2.0 luôn hoạt động tốt hơn $\pi_{0.5}$ trên cả phương án robot và cả cài đặt đánh giá. Trong cài đặt trong miền, LingBot-VLA-2.0 đạt điểm tiến bộ/tỷ lệ thành công là 77,1/60,0 ở nhiệm vụ phân loại tủ lạnh và 84,3/66,7 ở nhiệm vụ vệ sinh bếp, cải thiện hơn $\pi_{0.5}$ lần lượt là 11,8/13,3 và 4,4/6,7 điểm. Những kết quả này chỉ ra rằng LingBot-VLA-2.0 có thể thực hiện tốt hơn các chuỗi nhiệm vụ tầm xa đòi hỏi sự di chuyển cơ sở phối hợp, thao tác đối tượng và tương tác với các đối tượng được khớp nối. Trong cài đặt OOD, cả hai mô hình đều thể hiện sự suy giảm hiệu suất, phản ánh độ khó ngày càng tăng do các tư thế robot ban đầu bị xáo trộn và các vật thể bị thao tác không nhìn thấy được. Tuy nhiên, LingBot-VLA-2.0 vẫn duy trì lợi thế rõ ràng so với $\pi_{0.5}$, đạt 37,0/13,3 ở nhiệm vụ phân loại tủ lạnh và 67,5/40,0 ở nhiệm vụ vệ sinh bếp. So với $\pi_{0.5}$, điều này tương ứng với mức cải thiện lần lượt là 6,7/6,6 và 5,0/6,7 điểm. Khoảng cách về hiệu suất đặc biệt có ý nghĩa về mặt tỷ lệ thành công, cho thấy LingBot-VLA-2.0 mạnh mẽ hơn trong việc hoàn thành toàn bộ quỹ đạo nhiệm vụ thay vì chỉ đạt được tiến bộ một phần. Tác vụ sắp xếp tủ lạnh cho thấy mức giảm lớn hơn từ cài đặt trong miền đến cài đặt ngoài phân phối so với tác vụ làm sạch bếp. Điều này được mong đợi vì cài đặt tủ lạnh ngoài phân phối đồng thời thay đổi cả tư thế robot ban đầu và các danh mục đối tượng bị thao tác, đòi hỏi khả năng khái quát hóa ở cấp độ đối tượng mạnh hơn và khả năng phục hồi đường chân trời dài chính xác hơn. Ngược lại, nhiệm vụ làm sạch bếp chủ yếu đánh giá độ bền đối với các nhiễu loạn gây ra ban đầu trong khi vẫn bảo toàn các đối tượng nhiệm vụ và cấu trúc cảnh. Nhìn chung, kết quả chứng minh rằng LingBot-VLA-2.0 đạt được khả năng thao tác di động tầm xa mạnh mẽ hơn và khái quát hóa tốt hơn $\pi_{0.5}$ trên cả hai phương án.

Bảng 7. Tiêu chí chấm điểm cho các nhiệm vụ thử nghiệm thao tác di động trong thời gian dài.

Nhiệm vụ	Tiêu chí chấm điểm
Sắp xếp đồ vật vào tủ lạnh	1. Di chuyển từ vị trí ban đầu đến đảo bếp (6). 2. Lấy đồ uống trên bàn và đặt vào giỏ (9). 3. Nhặt quả đầu tiên trên bàn và đặt vào giỏ (9). 4. Nhặt quả thứ hai trên bàn và đặt vào giỏ (11). 5. Nhấc và nâng giỏ lên (8). 6. Di chuyển đến phía trước tủ lạnh (10). 7. Mở cửa tủ lạnh đủ rộng để đặt đồ vào bên trong (12). 8. Nhặt quả đầu tiên và cho vào tủ lạnh (9). 9. Nhặt quả thứ hai và cho vào tủ lạnh (11). 10. Lấy đồ uống ra và cho vào tủ lạnh (9). 11. Đóng cửa tủ lạnh (6).
Stove Cleaning	1. Di chuyển từ vị trí ban đầu ra phía trước bếp (8). 2. Nhấc giá đựng nồi màu đen lên và đặt nó ở phía bên trái của bàn (16). 3. Nhặt miếng bọt biển lên (12). 4. Wipe off the white foam on the stove using the sponge (18). 5. Transfer the sponge and place it on the right side of the stove (16). 6. Pick up the black rack and place it back on the stove (16). 7. Pick up the black pot and place it on the left burner of the stove (14).



Hình 9. Minh họa nền tảng thử nghiệm thao tác di động có tầm nhìn xa.


6 Nghiên cứu cắt bỏ

6.1 Không gian hành động

Mục tiêu hành động. Đối với mục tiêu hành động, các hành động chung tương đối về cơ bản hoạt động tốt hơn các hành động chung tuyệt đối, cải thiện tỷ lệ thành công trung bình từ 33.7 lên 55.0. Điều này được hỗ trợ bởi số liệu thống kê hành động trong Hình 12A. Trong bốn nhiệm vụ, độ lệch chuẩn của relQpos chỉ bằng 31%–37% so với absQpos; trên phân phối gộp, độ lệch chuẩn hành động giảm từ khoảng 0.80 đối với absQpos xuống 0.28 đối với relQpos. Do đó, các hành động tương đối sẽ chuyển đổi mục tiêu dự đoán từ hồi quy cấu hình khớp tổng thể sang hồi quy chuyển động cục bộ, tạo ra các mục tiêu tập trung hơn và có phương sai thấp hơn.



Hình 10. Kết quả của bốn nhiệm vụ trên robot thật GM-100.




Hình 11. Phân phối hành động chuẩn hóa trung bình theo chiều cho các không gian hành động chung và EEF. Cột đầu tiên hiển thị mức phân bố gộp cho cả bốn nhiệm vụ, trong khi các cột còn lại hiển thị mức phân bố theo từng nhiệm vụ cụ thể. Khoảng cách đo lường sự liên kết phân phối giữa các nhiệm vụ được gộp lại dựa trên sự khác biệt trung bình theo chiều và IQR.

Không gian hành động. Đối với không gian hành động, EEF và các hành động chung có tỷ lệ thành công trung bình tương tự nhau, lần lượt là 56.0 và 55.0, nhưng hiển thị các ưu tiên cấp nhiệm vụ khác nhau. Để phân tích điều này, Hình 11 so sánh phân phối hành động chuẩn hóa MeanStd theo chiều của từng nhiệm vụ với phân phối gộp trên tất cả bốn nhiệm vụ. Ngoài ra, chúng tôi còn báo cáo khoảng cách liên kết-phân phối, được tính toán từ sự khác biệt trung bình theo chiều và IQR giữa từng nhiệm vụ và phân phối gộp; khoảng cách nhỏ hơn cho thấy rằng phân bố hành động theo nhiệm vụ cụ thể gần với phân bố tổng thể hơn.

Kết quả cho thấy rằng việc căn chỉnh phân phối giải thích được một phần, nhưng không phải tất cả, về hành vi của không gian hành động. Đối với Quét mã vạch, các hành động chung gần với phân phối gộp hơn nhiều so với các hành động EEF, với khoảng cách 0.68 so với 1.73, phù hợp với lợi thế hiệu suất lớn của các hành động chung (58.7 so với 24.0). Đối với Squeeze Ketchup, xu hướng ngược lại xuất hiện: Các hành động EEF có khoảng cách nhỏ hơn so với các hành động chung (0.96 so với 1.59) và đạt được thành công cao hơn nhiều (81.7 so với 41.7),

gợi ý rằng các chuyển động điểm cuối giàu tiếp xúc được thể hiện tốt hơn trong không gian EEf của Descartes. Tuy nhiên, đối với Scoop Rice, các hành động EEf hoạt động tốt hơn các hành động chung mặc dù khoảng cách phân phối lớn hơn, cho thấy rằng tính đều đặn của chuyển động Descartes có thể vượt trội hơn sự liên kết phân phối thuần túy. Đối với Take Bowl from lò vi sóng, hai khoảng trông gần như giống nhau (0.71–0.72), trong khi các hành động chung vẫn hoạt động tốt hơn, cho thấy rằng tư thế, khả năng tiếp cận và các hạn chế phụ thuộc vào cấu hình quan trọng hơn thống kê hành động cận biên. Nhìn chung, không gian hành động tốt nhất phụ thuộc vào cả sự liên kết phân bố và cấu trúc vật lý của nhiệm vụ.



Hình 12. Mục tiêu hành động và thống kê chuẩn hóa cho bốn nhiệm vụ GM-100. Bên trái: relQpos giảm đáng kể thang đo hành động so với absQpos. Phải: quá trình chuẩn hóa thay đổi phạm vi động hiệu quả của relQpos được chuẩn hóa MeanStd; Q01–Q99 được hiển thị trong cài đặt chưa được cắt xén thực tế.

Bình thường hóa. Để chuẩn hóa, Hình 12B hiển thị phân bố relQpos đã chuẩn hóa theo ba sơ đồ. MinMax nén hầu hết các mẫu vào một phạm vi hẹp: độ lệch chuẩn chuẩn hóa của nó chỉ là 0.15 và khoảng phân vị thứ 1–99 là khoảng $[-0.42, 0.40]$. Khả năng nén mạnh này làm giảm độ phân giải hiệu quả của các mục tiêu hành động, điều này giải thích tỷ lệ thành công trung bình thấp hơn là 47.5.


Q01–Q99 tăng độ lệch chuẩn chuẩn hóa lên 0.32 và mở rộng khối trung tâm lên khoảng $[-0.96, 1.01]$. Điều quan trọng là việc triển khai thực tế được sử dụng ở đây không bị cắt bớt; chỉ có khoảng 0.2% giá trị nằm ngoài $[-1.5, 1.5]$. Do đó, điểm yếu của nó không phải là mất thông tin do cắt bớt mà là các mục tiêu chuẩn hóa vẫn bị nén nhiều hơn so với MeanStd. Điều này giải thích tại sao Q01–Q99 cải thiện dải động trung tâm so với MinMax nhưng vẫn đạt được tỷ lệ thành công trung bình tương tự là 47.4.

MeanStd cung cấp phạm vi động hiệu quả lớn nhất, với độ lệch chuẩn chuẩn hóa 0.95 và khoảng phân vị thứ 1–99 xấp xỉ $[-3.22, 3.30]$. Khoảng 10.0% mẫu nằm bên ngoài $|x| > 1.5$, phản ánh cấu trúc đuôi dài của phân bố hành động tương đối hơn là cắt bớt. Bằng cách duy trì những chuyển động điều chỉnh lớn hơn này, MeanStd đạt được tỷ lệ thành công trung bình tốt nhất là 55.0.

Chức năng mất mát. Đối với hàm mất mát, L2 đạt hiệu suất trung bình tốt nhất, cải thiện so với L1 từ 46.4 lên 55.0. Vì hầu hết các mục tiêu relQpos đều là những điều chỉnh nhỏ liên tục quanh mức 0, nên L2 phù hợp hơn với vùng mật độ cao của phân bố hành động và khuyến khích hồi quy chính xác. L1 hoạt động tốt hơn trên Squeeze Ketchup, phù hợp với độ bền của nó đối với các chuyển động có nhiều tiếp xúc hoặc có đuôi nặng, nhưng hoạt động kém hơn ở ba nhiệm vụ còn lại.

6.2 Kết quả cảm nhận của quá trình chất lọc truy vấn kép

Chúng tôi sử dụng LingBot-Depth và DINO-Video làm mô hình giáo viên trực quan để đào tạo về chung cất. Mặc dù kết quả nhận thức không cần thiết cho việc tạo hành động, việc tích hợp các truy vấn tác vụ cụ thể cho phép VLA thu được kết quả nhận thức trực quan trong quá trình suy luận nhân quả. Như được hiển thị trong Hình 13, chúng tôi trình bày kết quả nhận thức nhân quả của LingBot-VLA 2.0, xác nhận tính hiệu quả của mô hình của chúng tôi trong việc chất lọc các tiên nghiệm ngữ nghĩa và tín hiệu hình học.



Hình 13. Kết quả nhận thức nhân quả của LingBot-VLA 2.0 dưới sự chất lọc trực quan. Bên trái: độ sâu/sự thật nền tảng DINO-Video-PCA và dự đoán cho hình ảnh hiện tại. Phải: độ sâu/sự thật nền tảng DINO-Video-PCA và dự đoán cho hình ảnh trong tương lai.

7 Kết luận

LingBot-VLA 2.0 thu hẹp khoảng cách giữa các mô hình nền tảng VLA và việc triển khai robot trong thế giới thực bằng cách cải thiện khả năng khái quát hóa, mở rộng mô hình hành động toàn cơ thể và tăng cường lý luận về thời gian thông qua động lực dự đoán. Với robot quy mô lớn và dữ liệu đào tạo trước lấy bản chất làm trung tâm, LingBot-VLA 2.0 đạt được hiệu suất được cải thiện trên tiêu chuẩn GM-100 và thể hiện khả năng thao tác di động tâm xa mạnh mẽ trên nhiều nền tảng robot.

Sự thừa nhận. Chúng tôi cảm ơn Fangyi Xu, Ningyuan Huang, Haotian Liu, Jialiang Zheng, Liping Zhang, Weilun Yao, Shuai Wang, Linyu Su, Fan Fan, Bo Jiang, Jingmei Zhao, Shuai Zhou, Yinghao Xu và Haiwei Liang đã trợ giúp về dữ liệu, thí nghiệm đánh giá, cơ sở hạ tầng đào tạo, phần cứng robot và phần mềm robot. Chúng tôi cũng xin chân thành cảm ơn Phòng thí nghiệm Phedca của Ant Digital Technologies và Công ty TNHH Genrobot.ai vì đã cung cấp dữ liệu lấy cái tôi làm trung tâm.

Tài liệu tham khảo

- [1] Niket Agarwal, Arslan Ali, Jon Allen, Martin Antolini, Adeline Aubame, Alisson Azzolini, Junjie Bai, Maciej Bala, Yogesh Balaji, Josh Bapst, và những người khác. Cosmos 3: Mô hình thế giới đa phương thức cho ai vật lý. *arXiv bản in trước arXiv:2606.02800*, 2026.
- [2] Mahmoud Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, Artem Zhoulis, Sergio Arnaud, Abha Gejji, Ada Martin, Francois Robert Hogan, Daniel Dugas, Piotr Bojanowski, Vasil Khalidov, Patrick Labatut, Francisco Massa, Marc Szafraniec, Kapil Krishnakumar, Yong Li, Xiaodong Ma, Sarath Chandar, Franziska Meier, Yann LeCun, Michael Rabbat và Nicolas Ballas. V-jepa 2: Mô hình video tự giám sát cho phép hiểu, dự đoán và lập kế hoạch. *arXiv preprint arXiv:2506.09985*, 2025.
- [3] Shuanghao Bai, Meng Li, Xinyuan Lv, Jiawei Wang, Tân Hoa Xã, Fei Liao, Chengkai Hou, Langzhe Gu, Wanqi Zhou, Kun Wu, Ziluo Ding, Zhiyuan Xu, Lei Sun, Shanghang Zhang, Zhengping Che, Jian Tang, và Badong Chen. HEX: Các chuyên gia phù hợp với hình người để thao tác toàn bộ cơ thể theo phương án chéo. *arXiv preprint arXiv:2604.07993*, 2026.
- [4] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, và những người khác. GR00T N1: Mô hình nền tảng mở cho robot hình người tổng quát. *arXiv preprint arXiv:2503.14734*, 2025.
- [5] Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Robert Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, brian ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vương, Homer Walke, Anna

Walling, Haohuan Wang, Lili Yu, và Ury Zhilinsky. $\pi_{0.5}$: Một mô hình tầm nhìn-ngôn ngữ-hành động với tính khái quát hóa thể giới mở. Trong *Hội nghị về học tập bằng robot*, 2025.

[6] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, James Tanner, Quân Vương, Anna Walling, Haohuan Wang, và Ury Zhilinsky. π_0 : Mô hình luồng hành động-ngôn ngữ-tầm nhìn để điều khiển robot nói chung. Trong *Kỷ yếu về Robot: Khoa học và Hệ thống*, 2025.

[7] Rui Cai, Jun Guo, Xinze He, Piaopiao Jin, Jie Li, Bingxuan Lin, Futeng Liu, Wei Liu, Fei Ma, Kun Ma, Feng Qiu, Heng Qu, Yifei Su, Qiao Sun, Dong Wang, Donghao Wang, YunHong Wang, Rujie Wu, Diyun Xiang, Yu Yang, Hangjun Ye, Yuan Zhang và Quanyun Chu. Xiaomi-robotics-0: Một mô hình hành động ngôn ngữ tầm nhìn có nguồn mở với khả năng thực thi theo thời gian thực. *arXiv preprint arXiv:2602.12684*, 2026.

[8] Chilam Cheang, Sijin Chen, Zhongren Cui, Yingdong Hu, Liqun Huang, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Xiao Ma, et al. Báo cáo kỹ thuật GR-3. *bản in trước arXiv arXiv:2507.15493*, 2025.

[9] Jialei Chen, Kai Wang, Kang Chen, Shuaihang Chen, Feng Gao, Wenhao Tang, Zhiyuan Li, Weilin Liu, Zhuyu Yao, Boxun Li, và những người khác. Lawam: Các mô hình hành động tiềm ẩn trên thể giới cho các chính sách robot nhận biết động lực học hiệu quả. *arXiv preprint arXiv:2606.15768*, 2026.

[10] Ronghan Chen, Yandan Yang, Zuojin Tang, Dongjie Huo, Tong Lin, Haoning Wu, Haoyun Liu, Yuzhi Chen, Lulu Zheng, Botai Yuan, Tianlun Li, Mingxin Wang, Dekang Qi, Bin Hu, Wei Mei, Yuze Xu, Haolong Yang, Yanqing Zhu, Mu Xu, Zhiheng Ma và Xinyuan Chang. Abot-m0.5: Mô hình hành động thể giới về di chuyển và thao tác thống nhất. *arXiv bản in trước arXiv:2607.00678*, 2026.

[11] Nhóm AI vật lý của DexForce AI. Dexworldmodel: Mô hình hóa thể giới tiềm ẩn nhân quả hướng tới việc học tự động các nhiệm vụ được thể hiện, năm 2026. Báo cáo kỹ thuật.

[12] Zhiying Du, Bei Liu, Yaobo Liang, Yichao Shen, Haidong Cao, Xiangyu Zheng, Zhiyuan Feng, Zuxuan Wu, Jiaolong Yang và Yu-Gang Jiang. HiMoE-VLA: Sự kết hợp các chuyên gia theo cấp bậc cho các chính sách hành động ngôn ngữ-tầm nhìn tổng quát. *arXiv preprint arXiv:2512.05693*, 2025.

[13] Đội Galaxea. Báo cáo kỹ thuật Galaxea g0.5, 2026. Báo cáo kỹ thuật.

[14] Tao Jiang, Tianyuan Yuan, Yi Cheng Liu, Chenhao Lu, Jianning Cui, Xiao Liu, Shuiqi Cheng, Jiyang Gao, Huazhe Xu và Hang Zhao. Tập dữ liệu thể giới mở Galaxea và mô hình vla hệ thống kép G0. *arXiv bản in trước arXiv:2509.00576*, 2025.

[15] Dongyoung Kim, Huiwon Jang, Myungkyu Koo, Suhyeok Jang, Taeyoung Kim, Beomjun Kim, Byungjun Yoon, Changsung Jang, Daewon Choi, Dongsu Han, Donguk Lee, Heeseung Kwon, Hojin Jeon, Jaehyun Kang, Jaekyoung Bae, Jihyuk Lee, Jimin Lee, John Won, Joonwoo Ahn, Junhyeong Park, Junyoung Sung, Kyungmin Lee, Minseong Han, Minsung Yoon, Sejun Joo, Seonil Son, Seungcheol Park, Seunggeun Cho, Seungjun Moon, Seungku Kim, Yonghoon Dong, Yongjin Cho, Youngchan Kim, v.v. Báo cáo kỹ thuật RLDX-1. *bản in trước arXiv arXiv:2605.03269*, 2026.

[16] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quân Vương, và những người khác. OpenVLA: Một mô hình hành động-ngôn ngữ-tầm nhìn nguồn mở. Trong *Hội nghị về học tập bằng robot*, 2025.

[17] Yang Li, Zhaxizhuoma, Hongru Jiang, Junjie Xia, Hongquan Zhang, Jinda Du, Yunsong Chu, Jia Zeng, Ce Hao, Jieji Ren, Qiaojun Yu, Cewu Lu, Yu Qiao và Jiangmiao Pang. ForceVLA2: Giải phóng khả năng kiểm soát lực-vị trí kết hợp với nhận thức về lực để thao tác nhiều tiếp xúc. *arXiv bản in trước arXiv:2603.15169*, 2026.

[18] Xuewu Lin, Tianwei Lin, Yun Du, Hongyu Xie, Yiwei Jin, Jiawei Li, Shijie Wu, Qingze Wang, Mengdi Li, Mengao Zhao, Ziang Li, Chaodong Huang, Hongzhe Bi, Lichao Huang và Zhizhong Su. Báo cáo kỹ thuật Holobrain-0. *bản in trước arXiv arXiv:2602.12062*, 2026.

[19] Aixin Liu, Bei Feng, Bing Xue, Bingxuan Wang, Bochao Wu, Chengda Lu, Chenggang Zhao, Chengqi Deng, Chenyu Zhang, Chong Ruan, et al. Báo cáo kỹ thuật Deepseek-v3. *arXiv bản in trước arXiv:2412.19437*, 2024.

[20] Hao Luo, Yi Cheng Feng, Wanpeng Zhang, Sipeng Zheng, Ye Wang, Haoqi Yuan, Jiazheng Liu, Chaoyi Xu, Qin Jin và Zongqing Lu. Being-h0: Huấn luyện trước hành động-ngôn ngữ-thị giác từ các video con người quy mô lớn. *arXiv preprint arXiv:2507.15597*, 2025.

[21] Hao Luo, Ye Wang, Wanpeng Zhang, Sipeng Zheng, Ziheng Xi, Chaoyi Xu, Haiweng Xu, Haoqi Yuan, Chi Zhang, Yiqing Wang, Yi Cheng Feng và Zongqing Lu. Being-h0.5: Mở rộng quy mô học tập của robot lấy con người làm trung tâm để khái quát hóa đa phương án. *arXiv preprint arXiv:2601.12993*, 2026.

[22] Hao Luo, Wanpeng Zhang, Yi Cheng Feng, Sipeng Zheng, Haiweng Xu, Chaoyi Xu, Ziheng Xi, Yuhui Fu và Zongqing Lu. Being-h0.7: Một mô hình hành động thể giới tiềm ẩn từ các video ích kỷ. *arXiv preprint arXiv:2605.00078*, 2026.

- [23] Jiangran Lyu, Kai Liu, Xuheng Zhang, Haoran Liao, Yusen Feng, Wenxuan Zhu, Tingrui Shen, Jiayi Chen, Jiazhao Zhang, Yifei Dong, Wenbo Cui, Senmao Qi, Shuo Wang, Yixin Zheng, Mi Yan, Xuesong Shi, Haoran Li, Dongbin Zhao, Ming-Yu Liu, Zhizheng Zhang, Li Yi, Yizhou Wang, and He Wang. LDA-1b: Scaling latent dynamics action model via universal embodied data ingestion. *arXiv preprint arXiv:2602.12215*, 2026.
- [24] Dujun Nie, Fengjiao Chen, Qi Lv, Jun Kuang, Xiaoyu Li, Xuezhi Cao, and Xunliang Cai. Lary: A latent action representation yielding benchmark for generalizable vision-to-action alignment. *arXiv preprint arXiv:2604.11689*, 2026.
- [25] Qwen Team. Qwen3.6-27B: Flagship-level coding in a 27B dense model, April 2026.
- [26] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer, Federico Baldassarre, Maxime Oquab, Cijo Jose, Vasil Khalidov, Marc Szafraniec, Seungeun Yi, Michaël Ramamonjisoa, Francisco Massa, Daniel Haziza, Luca Wehrstedt, Jianyuan Wang, Timothée Darcet, Théo Moutakanni, Leonel Sentana, Claire Roberts, Andrea Vedaldi, Jamie Tolan, John Brandt, Camille Couprie, Julien Mairal, Hervé Jégou, Patrick Labatut, and Piotr Bojanowski. DINOv3, 2025.
- [27] Yue Su, Sijin Chen, Haixin Shi, Mingyu Liu, Zhengshen Zhang, Ningyuan Huang, Weiheng Zhong, Zhengbang Zhu, Yuxiao Liu, and Xihui Liu. World guidance: World modeling in condition space for action generation. In *ICML*, 2026.
- [28] Bin Tan, Changjian Sun, Xiage Qin, Hanat Adai, Zelin Fu, Tianxiang Zhou, Han Zhang, Yinghao Xu, Xing Zhu, Yujun Shen, and Nan Xue. Masked depth modeling for spatial perception. <https://technology.robbyant.com/lingbot-depth>, 2026.
- [29] Tutian Tang, Xingyu Ji, Wanli Xing, Ce Hao, Wenqiang Xu, Lin Shao, Cewu Lu, Qiaojun Yu, Jiangmiao Pang, and Kaifeng Zhang. Towards human-like manipulation through RL-augmented teleoperation and mixture-of-dexterous-experts VLA. *arXiv preprint arXiv:2603.08122*, 2026.
- [30] Gemini Robotics Team, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, et al. Gemini Robotics: Bringing AI into the physical world. *arXiv preprint arXiv:2503.20020*, 2025.
- [31] Generalist Team. Gen-1: Scaling embodied foundation models to mastery. *Generalist AI Blog*, 2026. <https://generalistai.com/blog/gen-1>.
- [32] NVIDIA GEAR Team. GR00T N1.6: An improved open foundation model for generalist humanoid robots. https://research.nvidia.com/labs/gear/gr00t-n1_6/, 2025.
- [33] Qwen Team. Qwen-robotmanip technical report: Alignment unlocks scale for robotic manipulation foundation models. 2026.
- [34] Qiuyue Wang, Mingsheng Li, Jian Guan, Jinhui Ye, Sicheng Xie, Yitao Liu, Junhao Chen, Zhixuan Liang, Jie Zhang, Xintong Hu, Xuhong Huang, Pei Lin, Junyang Lin, Dayiheng Liu, Shuai Bai, Jingren Zhou, Jiazhao Zhang, Haoqi Yuan, Gengze Zhou, Hang Yin, Ye Wang, Yiyang Huang, Zixing Lei, Wujian Peng, Delin Chen, et al. Qwen-VLA: Unifying vision-language-action modeling across tasks, environments, and robot embodiments. *arXiv preprint arXiv:2605.30280*, 2026.
- [35] Yunnan Wang, Fan Lu, Kecheng Zheng, Ziyuan Huang, Ziqiang Li, Wenjun Zeng, and Xin Jin. Vision-centric activation and coordination for multimodal large language models. *arXiv preprint arXiv:2510.14349*, 2025.
- [36] Ziyu Wang, Chenyuan Liu, Yushun Xiang, Runhao Zhang, Qingbo Hao, Hongliang Lu, Houyu Chen, Zhizhong Feng, Kaiyue Zheng, Dehao Ye, Xianchao Zeng, Xinyu Zhou, Boran Wen, Jiaxin Li, Mingyu Zhang, Kecheng Zheng, Qian Zhu, Ran Cheng, and Yong-Lu Li. The Great March 100: 100 detail-oriented tasks for evaluating embodied ai agents, 2026.
- [37] Xilin Wei, Xiaoran Liu, Yuhang Zang, Xiaoyi Dong, Pan Zhang, Yuhang Cao, Jian Tong, Haodong Duan, Qipeng Guo, Jiaqi Wang, et al. Videorope: What makes for good video rotary position embedding? In *Int. Conf. Mach. Learn.*, 2025.
- [38] Wei Wu, Fan Lu, Yunnan Wang, Shuai Yang, Shi Liu, Fangjing Wang, Shuailei Ma, He Sun, Yong Wang, Zhenqi Qiu, Houlong Xiong, Ziyu Wang, Shuai Zhou, Yiyu Ren, Kejia Zhang, Hui Yu, Jingmei Zhao, Qian Zhu, Ran Cheng, Yong-Lu Li, Yongtao Huang, Xing Zhu, Yujun Shen, and Kecheng Zheng. A pragmatic vla foundation model. *arXiv preprint arXiv:2601.18692v1*, 2026.
- [39] Tencent Robotics X and HY Vision Team. Hy-embodied-0.5-x: An enhanced embodied foundation model for real-world agents. 2026.
- [40] Yibin Yan, Jilan Xu, Shangzhe Di, Haoning Wu, and Weidi Xie. Omnistream: Mastering perception, reconstruction and action in continuous streams. *arXiv preprint arXiv:2603.12265*, 2026.
- [41] Jianwei Yang, Reuben Tan, Qianhui Wu, Ruijie Zheng, Baolin Peng, Yongyuan Liang, Yu Gu, Mu Cai, Seonghyeon Ye, Joel Jang, et al. Magma: A foundation model for multimodal AI agents. In *IEEE Conf. Comput. Vis. Pattern Recog.*, pages 14203–14214, 2025.

- [42] Yandan Yang, Shuang Zeng, Tong Lin, Xinyuan Chang, Dekang Qi, Junjin Xiao, Haoyun Liu, Ronghan Chen, Yuzhi Chen, Dongjie Huo, et al. Abot-m0: Mô hình nền tảng VLA cho thao tác robot với học tập đa dạng hành động. *arXiv preprint arXiv:2602.11236*, 2026.
- [43] Jinhui Ye, Ning Gao, Senqiao Yang, Jinliang Zheng, Zixuan Wang, Yuxin Chen, Pengguang Chen, Yilun Chen, Shu Liu và Jiaya Jia. Starvla-
alpha: Giảm độ phức tạp trong các hệ thống hành động-ngôn ngữ-tầm nhìn. *arXiv preprint arXiv:2604.11757*, 2026.
- [44] Zihan You, Hongwei Liu, Chenxu Đặng, Zhe Wang, Sining Ang, Aoqi Wang và Yan Wang. SAMoE-VLA: Mô hình hành động-ngôn ngữ-tầm nhìn kết hợp giữa các chuyên gia thích ứng theo bối cảnh dành cho xe tự lái. *arXiv preprint arXiv:2603.08113*, 2026.
- [45] Jiawen Yu, Hairuo Liu, Qiaojun Yu, Jieji Ren, Ce Hao, Haitong Ding, Quangyu Huang, Guofan Huang, Yan Song, Panpan Cai, Cewu Lu và Wenqiang Zhang. ForceVLA: Cải tiến các mô hình VLA bằng MoE nhận biết lực để thao tác nhiều điểm tiếp xúc. *arXiv preprint arXiv:2505.22159*, 2025.
- [46] Ryan Yu, Pushi Zhang, Starrick Liu, Brae Liu, Miracle Kang, Shalfun Li, Lights Shi, Ellie Ma, Ping Yang, Chris Pan, Jerry Chen, Dongxiu Liu, Rain Sun, Miles Guo, Byron Zhang, Hugo Chu, Zach Xu, Vincent Chen, Harrison Huang, James Wang, Dance Kuzi, Andy Zhai, Hang Su, Roy Gan, Lucy Liang, Hao Wang và Qian Wang. Báo cáo kỹ thuật Wall-oss-0.5. *arXiv bản in trước arXiv:2605.30877*, 2026.
- [47] Andy Zhai, Brae Liu, Bruno Fang, Chalse Cai, Ellie Ma, Ethan Yin, Hao Wang, Hugo Zhou, James Wang, Lights Shi, và những người khác. Kích hoạt các VLM về phía không gian hiện thân. *arXiv in trước arXiv:2509.11766*, 2025.
- [48] Likui Zhang, Tao Tang, Zhihao Zhan, Xiuwei Chen, Zisheng Chen, Jianhua Han, Jiangtong Zhu, Pei Xu, Hang Xu, Hefeng Wu, Liang Lin và Xiaodan Liang. AtomicVLA: Khai phá tiềm năng học kỹ năng nguyên tử trong robot. *arXiv preprint arXiv:2603.07648*, 2026.
- [49] Ruowen Zhao, Bangguo Li, Zuyan Liu, Yinan Liang, Junliang Ye, Fangfu Liu, Diankun Wu, Zhengyi Wang, Xumin Yu, Yongming Rao, Han Hu và Jun Zhu. GEM: Giám sát sáng tạo giúp thể hiện trí thông minh. *arXiv preprint arXiv:2605.28548*, 2026.