

Qwen-VLA: Thống nhất mô hình hóa hành động-ngôn ngữ-tầm nhìn giữa các nhiệm vụ, môi trường và các phương án robot

Nhóm Qwen




<https://qwen.ai/blog?id=qwenvla>



<https://github.com/QwenLM/Qwen-VLA>

Tóm tắt

Trí thông minh thể hiện thường được nghiên cứu thông qua các mô hình chuyên biệt, mỗi mô hình được thiết kế cho một kịch bản hoặc nhiệm vụ duy nhất, chẳng hạn như thao tác và điều hướng, dẫn đến khả năng bị phân mảnh và khả năng khái quát hóa hạn chế giữa các nhiệm vụ, môi trường và phương án robot đa dạng. Trong nghiên cứu này, chúng tôi điều tra xem liệu những vấn đề ra quyết định được thể hiện không đồng nhất này có thể được thống nhất trong một mô hình hành động-ngôn ngữ-tầm nhìn duy nhất hay không. Chúng tôi trình bày Qwen-VLA, một mô hình nền tảng thể hiện thống nhất giúp mở rộng mô hình ngôn ngữ tầm nhìn của Qwen từ nhận thức, hiểu biết và lý luận đến hành động liên tục và tạo quỹ đạo thông qua bộ giải mã hành động dựa trên DiT. Cách tiếp cận của chúng tôi áp dụng công thức huấn luyện trước chung quy mô lớn trên nhiều nguồn dữ liệu khác nhau, bao gồm quỹ đạo thao tác robot, minh họa lấy con người làm trung tâm, dữ liệu mô phỏng tổng hợp, dữ liệu điều hướng tầm nhìn và ngôn ngữ, giám sát lấy quỹ đạo làm trung tâm và dữ liệu ngôn ngữ thị giác phụ trợ. Để hỗ trợ nhiều nền tảng robot trong một mô hình dùng chung, chúng tôi giới thiệu điều kiện nhanh chóng nhận biết phương án, trong đó các mô tả văn bản dành riêng cho robot được thêm vào trước để chỉ định phương án hiện tại và quy ước điều khiển. Chúng tôi tiếp tục đưa các thao tác, điều hướng và dự đoán quỹ đạo vào một khung dự đoán hành động và quỹ đạo thống nhất, cho phép tiếp xúc trực quan, suy luận không gian và tạo hành động liên tục trên các hình thái robot, nhóm nhiệm vụ và môi trường. Các thử nghiệm về thao tác, điều hướng và điểm chuẩn lấy quỹ đạo làm trung tâm cho thấy Qwen-VLA hỗ trợ điều khiển thể hiện trên các nhóm nhiệm vụ và các phương án robot, với hiệu suất đa nhiệm nhất quán và khả năng tổng quát hóa ngoài phân phối trên các biến thể về bố cục cảnh, nền, ánh sáng, cấu hình đối tượng và phương án robot. Là một chính sách tổng quát thống nhất, Qwen-VLA-Instruct đồng thời đạt được 97,9% trên LIBERO, 73,7% trên Simpler-WidowX, 86,1/87,2% trên RoboTwin-Easy/Hard, 69,0% OSR trên R2R và 59,6% SR trên RxR, đồng thời đạt được thành công OOD trung bình 76,9% trong các thử nghiệm ALOHA trong thế giới thực và Tỷ lệ bản không thành công 26,6% khi thao tác động DOMINO.



Hình 1: Tổng quan về Qwen-VLA, một mô hình thể hiện thống nhất được đào tạo về dữ liệu hiểu ngôn ngữ, điều hướng và thao tác hỗn hợp để tạo ra cả hành động của robot và phản hồi bằng văn bản.

1 Giới thiệu

Trí thông minh thể hiện (Zitkovich và cộng sự, 2023; O'Neill và cộng sự, 2024) nhằm mục đích xây dựng các tác nhân có thể nhận thức thế giới vật chất, hiểu hướng dẫn bằng ngôn ngữ tự nhiên, suy luận về bối cảnh không gian và thời gian cũng như thực hiện các hành động để hoàn thành mục tiêu. Những tiến bộ gần đây trong các mô hình ngôn ngữ thị giác (VLM) (Wang và cộng sự, 2024; Bai và cộng sự, 2025b; Team và cộng sự, 2025; Bai và cộng sự, 2025a; Team, 2026) đã cải thiện đáng kể sự hiểu biết về hình ảnh và nền tảng ngôn ngữ trong thế giới mở, trong khi các chính sách dựa trên sự lan tỏa hoặc dòng chảy (Black et al., 2024; 2025; Intelligence et al., 2026) đã cho thấy tiềm năng mạnh mẽ trong việc mô hình hóa các hoạt động liên tục, có chiều cao của robot. Tuy nhiên, hầu hết các hệ thống hiện có (NVIDIA và cộng sự, 2025; Luo và cộng sự, 2025; Yang và cộng sự, 2026) vẫn chuyên biệt cho một nhóm nhiệm vụ hẹp, phương án robot hoặc cài đặt đánh giá. Các mô hình thao tác (Intelligence và cộng sự, 2026) thường được đào tạo để điều khiển trên bàn hoặc điều khiển khéo léo, và các mô hình điều hướng (Zhang và cộng sự, 2024; 2025b; Cheng và cộng sự, 2025) được thiết kế xung quanh điểm tham chiếu hoặc dự đoán hành động trong môi trường trong nhà. Sự phân mảnh này hạn chế việc chuyển giao giữa các nhiệm vụ, môi trường và phương án, đồng thời gây khó khăn cho việc mở rộng quy mô học tập thể hiện theo cách tương tự như đào tạo trước ngôn ngữ thị giác cho mục đích chung.

Một thách thức trọng tâm là các vấn đề ra quyết định thể hiện ở bề ngoài có vẻ không đồng nhất. Thao tác với robot có thể yêu cầu dự đoán các tư thế của tác nhân cuối (Black và cộng sự, 2024; Zheng và cộng sự, 2025; Zhang và cộng sự, 2026), các vị trí khớp (Fu và cộng sự, 2024; NVIDIA và cộng sự, 2025), trạng thái tay kẹp hoặc cấu hình bàn tay khéo léo (Luo và cộng sự, 2025); điều hướng có thể yêu cầu dự đoán các điểm tham chiếu hoặc các quyết định di chuyển riêng biệt (Zhang và cộng sự, 2025a; Wang và cộng sự, 2025a; Wei và cộng sự, 2025); Các cuộc biểu tình lấy con người làm trung tâm có thể cung cấp quỹ đạo của cô tay và bàn tay hơn là tín hiệu điều khiển robot. Các nhiệm vụ này cũng khác nhau về định dạng quan sát, tần suất kiểm soát, phạm vi dự đoán, chiều hướng hành động và giao thức đánh giá. Tuy nhiên, chúng có chung cấu trúc tính toán: tác nhân được thể hiện phải dựa trên các quan sát trực quan, hướng dẫn ngôn ngữ và các ràng buộc cụ thể của phương án, sau đó dự đoán các hành động hoặc quỹ đạo trong tương lai phù hợp về mặt vật lý và ngữ nghĩa với nhiệm vụ. Quan sát này thúc đẩy một công thức thống nhất cho mô hình thể hiện. Chúng tôi tận dụng thông tin chi tiết này để thiết kế một khuôn khổ đào tạo trước chung nhằm hấp thụ các thao tác, điều hướng, minh họa con người lấy cái tôi làm trung tâm và lập luận ngôn ngữ tầm nhìn vào một mô hình hành động-ngôn ngữ-tầm nhìn duy nhất. Mô hình kết quả khái quát hóa theo các phương án và cài đặt nhiệm vụ.

Trong công việc này, chúng tôi trình bày **Qwen-VLA**, một mô hình hành động-ngôn ngữ-tầm nhìn thống nhất để đưa ra quyết định được thể hiện không đồng nhất. Qwen-VLA được xây dựng dựa trên Qwen3.5-4B, một xương sống đa phương thức nguyên bản của dòng Qwen đã chứng tỏ hiệu suất tiên tiến trên nhiều tiêu chuẩn ngôn ngữ thị giác. Nền tảng mang lại nhận thức trực quan chi tiết mạnh mẽ, nền tảng tham chiếu mạnh mẽ, hướng dẫn đa ngôn ngữ và khả năng lý luận có cấu trúc, rất quan trọng đối với các nhiệm vụ được thể hiện yêu cầu diễn giải các mối quan hệ không gian, xác định các đối tượng được tham chiếu và làm theo các hướng dẫn nhiều bước phức tạp. Ở phía trên xương sống, chúng tôi gắn bộ giải mã hành động khớp luồng dựa trên DiT chuyên tạo ra hành động liên tục chi tiết. Thay vì thiết kế các đầu ra riêng biệt hoặc kiến trúc dành riêng cho nhiệm vụ cho các phương án khác nhau, Qwen-VLA thể hiện các hành động thao túng, điểm định hướng và chuyển động tự nhiên của con người trong không gian dự đoán hành động và quỹ đạo chung. Thiết kế này cho phép một mô hình duy nhất tiếp thu sự giám sát từ các bộ dữ liệu được thể hiện đa dạng trong khi vẫn duy trì giao diện suy luận thống nhất.

Một thành phần quan trọng của Qwen-VLA là đào tạo trước chung trên quy mô lớn về dữ liệu ngôn ngữ hình ảnh và thể hiện đa dạng. Hỗn hợp đào tạo trước của chúng tôi bao gồm quỹ đạo thao tác robot, trình diễn lấy con người làm trung tâm, quỹ đạo mô phỏng tổng hợp, dữ liệu điều hướng ngôn ngữ và tầm nhìn, dữ liệu nền tảng không gian, VQA lái xe tự động, chú thích hành động được thể hiện chi tiết và dữ liệu ngôn ngữ tầm nhìn chung. Hỗn hợp này được thiết kế để bao gồm cả các ưu tiên vận động cấp thấp và lý luận ngữ nghĩa cấp cao. Quỹ đạo của rô-bốt cung cấp khả năng giám sát hành động trực tiếp, dữ liệu con người lấy cái tôi làm trung tâm cung cấp các ưu tiên thao tác trong thế giới thực có thể mở rộng, dữ liệu điều hướng giới thiệu hướng dẫn theo dõi và khám phá trong thời gian dài, mô phỏng tổng hợp cải thiện khả năng kiểm soát và phạm vi phân phối ngoài phạm vi phân phối, cũng như dữ liệu ngôn ngữ thị giác, tức là được lấy mẫu có chọn lọc cho các khả năng liên quan được thể hiện như lý luận không gian, nền tảng tham chiếu và hướng dẫn theo sau, duy trì và củng cố nền tảng nhận thức và lý luận của xương sống cho các nhiệm vụ được thể hiện ở phía dưới.

Để cho phép học tập theo nhiều phương án, chúng tôi giới thiệu **điều kiện hóa nhanh chóng nhận thức được phương án**. Mỗi ví dụ đào tạo được thêm vào trước một mô tả bằng văn bản về phương án hiện tại, bao gồm nền tảng robot, cấu hình cánh tay, quy ước điều khiển, tần số điều khiển và phạm vi dự đoán. Lời nhắc đóng vai trò là giao diện duy nhất mà qua đó mô hình được thông báo về ngữ nghĩa điều khiển theo phương án cụ thể. Kết hợp với biểu diễn hành động thống nhất, điều này cho phép cùng một bộ giải mã hành động xử lý các chế độ điều khiển, kích thước hành động và phạm vi thời gian khác nhau mà không thay đổi kiến trúc mô hình. Do đó, Qwen-VLA có thể tìm hiểu các khả năng lý luận không gian và nền tảng trực quan được chia sẻ trên các phương án không đồng nhất trong khi vẫn tôn trọng các quy ước hành động dành riêng cho nền tảng.

Việc đào tạo một mô hình như vậy không hề đơn giản vì xương sống VLM và bộ giải mã hành động được tối ưu hóa ở trạng thái bất đối xứng: xương sống đã sở hữu các biểu diễn ngôn ngữ tầm nhìn cho mục đích chung từ quá trình đào tạo trước quy mô lớn, trong khi bộ giải mã hành động DiT được khởi tạo ngẫu nhiên. Việc khởi động đào tạo chung đa phương thức một cách ngây thơ từ thời điểm này có thể lãng phí tính toán trong quá trình học bộ giải mã độc lập với tầm nhìn và làm mất ổn định các biểu diễn được đào tạo trước. Do đó, chúng tôi áp dụng công thức đào tạo theo giai đoạn dựa trên quan điểm nén về học tập hành động. Hướng dẫn bằng ngôn ngữ chẳng hạn như “nhắc chiếc cốc màu đỏ” cùng với lời nhắc phương án sẽ mã hóa ngắn gọn ý định nhiệm vụ trong một số mã thông báo, tuy nhiên quỹ đạo hành động tương ứng có thể trải rộng trên hàng trăm giá trị vị trí khớp nhiều chiều. Việc thu hẹp khoảng cách về chiều này là một vấn đề giải nén có cấu trúc và giai đoạn đào tạo đầu tiên của chúng tôi, tức là **đào tạo trước DiT chuyển văn bản thành hành động (T2A)**, dạy bộ giải mã hoạt động như một bộ giải nén hành động có điều kiện ngôn ngữ trước khi đưa bất kỳ đầu vào trực quan nào vào. Sau khi hành động nén trước này được áp dụng, quá trình đào tạo tiếp theo sẽ căn cứ vào các quan sát trực quan, tinh chỉnh có giám sát để chuyên môn hóa hành động đó cho các nhiệm vụ tiếp theo và học tăng cường sẽ tối ưu hóa thành công của nhiệm vụ vòng kín. Công thức này tách quá trình nén trước hành động, nền tảng trực quan, chuyên môn hóa nhiệm vụ và sàng lọc hướng đến thành công thành các giai đoạn riêng biệt.

Chúng tôi đánh giá Qwen-VLA trên nhiều cài đặt được thể hiện, bao gồm thao tác robot, điều hướng bằng hình ảnh và ngôn ngữ, khái quát hóa ngoài phân phối và chuyển giao giữa các phương án. Đánh giá này được thiết kế không chỉ để đo lường mức độ thành công của nhiệm vụ trong miền mà còn để kiểm tra xem liệu một mô hình hợp nhất có thể khái quát hóa dưới những thay đổi về bố cục đối tượng, ánh sáng, nền, hướng dẫn ngôn ngữ, tiếng ồn cảm biến và phương án robot hay không. Về mặt thực nghiệm, kết quả của chúng tôi cho thấy rằng việc huấn luyện trước chung trên quy mô lớn dựa trên dữ liệu được thể hiện không đồng nhất mang lại hiệu suất đa tác vụ mạnh mẽ và cải thiện tính mạnh mẽ ngoài việc đào tạo chuyên môn hẹp. Những phát hiện này ủng hộ quan điểm rằng các nhiệm vụ thao tác, điều hướng và tập trung vào quỹ đạo có thể được coi là những biểu hiện khác nhau của một vấn đề dự đoán hành động và quỹ đạo chung.

Những đóng góp của chúng tôi được tóm tắt như sau:

- Chúng tôi giới thiệu **Qwen-VLA**, một mô hình hành động-ngôn ngữ-tầm nhìn thống nhất hình thành mô hình thao tác, điều hướng và hành động lấy cái tôi làm trung tâm trong một không gian hành động và quỹ đạo chung. Được xây dựng trên nền tảng ngôn ngữ tầm nhìn Qwen3.5-4B với phần chính sách khớp luồng dựa trên DiT, Qwen-VLA hỗ trợ khả năng kiểm soát thể hiện trên nhiều nền tảng robot và nhóm nhiệm vụ.
- Chúng tôi xây dựng một hỗn hợp huấn luyện trước chung quy mô lớn trên các nguồn dữ liệu không đồng nhất, bao gồm quỹ đạo thao tác từ nhiều robot, các cuộc biểu tình lấy con người làm trung tâm, mô phỏng tổng hợp, điều hướng và dữ liệu ngôn ngữ thị giác được quản lý. Chúng tôi tiếp tục đề xuất điều kiện kịp thời nhận biết phương án để thống nhất các nền tảng rô-bốt đa dạng, quy ước điều khiển và phạm vi dự đoán trong một mô hình mà không có chính sách riêng cho từng phương án.
- Chúng tôi thiết kế một công thức đào tạo tiến bộ bao gồm đào tạo trước hành động, đào tạo trước liên tục đa phương thức, tinh chỉnh có giám sát và học tăng cường để xây dựng mô hình chính sách mạnh mẽ giúp thu hẹp khoảng cách giữa các mã thông báo ngôn ngữ tầm nhìn rời rạc và quỹ đạo hành động liên tục, cải thiện cả sự ổn định trong đào tạo và chuyển giao xuôi dòng.
- Chúng tôi đánh giá Qwen-VLA dựa trên các tiêu chuẩn về thao tác, điều hướng, độ bền ngoài phân phối và điểm chuẩn tổng quát hóa nhiều phương án. Kết quả cho thấy rằng việc đồng đào tạo và học tập tiến bộ cải thiện hiệu suất đa nhiệm trong các thay đổi về cảnh, đối tượng, ánh sáng và phương án.

2 Mô hình thể hiện thống nhất

2.1 Hình thành vấn đề

Chúng tôi nghiên cứu một nhóm lớn các nhiệm vụ ra quyết định được thể hiện, bao gồm thao tác robot, điều hướng bằng ngôn ngữ và tầm nhìn, dự đoán quỹ đạo và mô hình hóa hành động lấy con người làm trung tâm. Chúng tôi đề xuất giải quyết các nhiệm vụ này trong một mô hình được thể hiện thống nhất, được thúc đẩy bởi cấu trúc tính toán chung của chúng: mặc dù có sự khác biệt về định dạng đầu ra và giao thức đánh giá, tất cả các nhiệm vụ đều yêu cầu một tác nhân sử dụng ngôn ngữ nền tảng trong các quan sát trực quan, suy luận về bối cảnh không gian và thời gian cũng như dự đoán các hành động hoặc quỹ đạo trong tương lai.

Chúng tôi xây dựng tất cả các nhiệm vụ trong một khung dự đoán có điều kiện thống nhất. Tại bước thời gian t , mô hình nhận được ngữ cảnh trực quan o_t , hướng dẫn ngôn ngữ x , mô tả phương án e và mã nhận dạng tác vụ tùy chọn z . Ở đây, o_t có thể bao gồm một hoặc nhiều khung hình ảnh, quan sát video hoặc cửa sổ lịch sử; x chỉ định hướng dẫn nhiệm vụ; e là lời nhắc bằng văn bản mô tả nền tảng robot hiện tại và quy ước điều khiển; và z xác định nhóm nhiệm vụ khi cần thiết. Mô hình được đào tạo để dự đoán chuỗi mục tiêu $y_{t:t+H-1}$ trên một chân trời dự đoán H :

$$p_{\theta}(y_{t:t+H-1} \mid o_t, x, e, z).$$

Chuỗi mục tiêu $y_{t:t+H-1}$ phụ thuộc vào nhiệm vụ nhưng được thể hiện trong một không gian hành động và quỹ đạo thống nhất.

Đối với các nhiệm vụ thao tác, nó tương ứng với các hành động của robot trong tương lai như vị trí của người thực hiện cuối cùng; đối với các nhiệm vụ điều hướng, nó thể hiện các quyết định điều hướng hoặc các điểm tham chiếu; đối với các nhiệm vụ lấy quỹ đạo làm trung tâm như lái xe tự động hoặc dự báo chuyển động, nó biểu thị quỹ đạo không gian chính xác trong tương lai của tác nhân hoặc các thực thể xung quanh trong không gian tọa độ liên tục; và đối với dữ liệu thể hiện cái tôi là trung tâm, nó ghi lại quỹ đạo chuyển động của cơ thể hoặc bàn tay con người được thể hiện trong các không gian tư thế có cấu trúc như MANO (Romero và cộng sự, 2017) hoặc các chuỗi khớp xương. Công thức thống nhất này cho phép tối ưu hóa chung trên các bộ dữ liệu được thể hiện không đồng nhất trong một mô hình duy nhất, tạo điều kiện thuận lợi cho nền tảng trực quan, lý luận không gian và tạo hành động giữa các nhóm nhiệm vụ có thể chuyển đổi. Công thức này cũng có thể mở rộng dọc theo cả trục đầu vào và đầu ra: về mặt đầu vào, việc tăng cường bối cảnh điều hòa o_t với bộ nhớ phân đoạn hoặc trạng thái liên tục sẽ cho phép lập kế hoạch dài hạn và khắc phục lỗi; về phía đầu ra, việc đồng dự đoán các trạng thái trực quan trong tương lai cùng với các hành động sẽ thống nhất việc tạo hành động với mô hình hóa thể giới, cho phép tác nhân dự đoán hậu quả của các hành động của mình.

2.2 Kiến trúc mô hình

Mô hình của chúng tôi bao gồm nền tảng ngôn ngữ tầm nhìn để hiểu và lý luận ở cấp độ cao cũng như chuyên gia hành động phù hợp với dòng chảy để tạo ra hành động chi tiết.

Xương sống ngôn ngữ tầm nhìn. Chúng tôi sử dụng Qwen3.5 (Nhóm, 2026) làm xương sống. Qwen3.5 là một mô hình đa phương thức nguyên bản được đào tạo bằng cách kết hợp ngôn ngữ tầm nhìn sớm: mã thông báo hình ảnh do ViT tạo ra với sự hợp nhất không gian được xen kẽ trực tiếp vào luồng mã thông báo văn bản, cho phép xử lý thống nhất hình ảnh, video và ngôn ngữ trong một biến áp duy nhất. Thiết kế chú ý kết hợp của nó kết hợp chú ý tuyến tính có kiểm soát trong phần lớn các lớp với chú ý softmax truy vấn nhóm theo khoảng thời gian đều đặn, cho phép mã hóa hiệu quả các chuỗi đa phương thức dài trong khi vẫn duy trì lý luận tổng thể chính xác hoàn toàn khi cần.

Chuyên gia hành động. Chúng tôi đính kèm chính sách đối sánh luồng kiểu DiT (Essex và cộng sự, 2024) đơn dòng với tư cách là một chuyên gia hành động để dự đoán các hành động chính xác trên cả dữ liệu do robot và con người thực hiện (Janner và cộng sự, 2022; Chi và cộng sự, 2023; Liang và cộng sự, 2023; Black và cộng sự, 2024). Chuyên gia hành động ghép các trạng thái ẩn VLM với một đoạn hành động ồn ào thành một chuỗi và xử lý chúng thông qua khả năng tự chú ý chung bằng điều hòa đầu thời gian AdaLN (Peebles & Xie, 2023) và RoPE nhiều phần được căn chỉnh với xương sống. Thiết kế tách rời này cho phép chuyên gia hành động chuyên môn hóa vào việc tạo hành động chi tiết và xử lý một cách tự nhiên động lực đa phương thức và tần số cao của các phân bố hành động được thể hiện, đồng thời duy trì các khả năng được huấn luyện trước của xương sống. Chuyên gia được đào tạo với mục tiêu khớp luồng (Lipman và cộng sự, 2023) và tạo ra các chuỗi hành động thông qua một số bước tích hợp Euler khi suy luận, cho phép kiểm soát thời gian thực có độ trễ thấp. Tổng cộng, chuyên gia hành động của chúng tôi chứa khoảng 1,15B tham số: 16 khối DiT chiếm số lượng lớn (mỗi khối 70,8M, kết hợp 1,13B), với các tham số còn lại được phân bổ giữa các MLP chiếu hành động ánh xạ giữa thứ nguyên hành động thô và không gian tiềm ẩn DiT (4,9M), một lớp tuyến tính biến đổi trạng thái ẩn VLM thành thứ nguyên kênh DiT (3,9M), những đầu thời gian (2,8M) và điều chế AdaLN đầu ra (4,7 triệu).

2.3 Điều hòa nhanh chóng nhận thức được phương án

Để hỗ trợ nhiều phương án rô-bốt trong một mô hình dùng chung, chúng tôi thêm lời nhắc bằng văn bản dành riêng cho rô-bốt vào mỗi ví dụ đào tạo mô tả nền tảng hiện tại, cấu hình cánh tay và quy ước điều khiển. Lời nhắc theo mẫu:

```
The robot is {robot_tag} with {single arm / dual arms}[, waist][, and mobile base]. The control frequency is {FPS} Hz. Please predict the next {chunk_size} control actions to execute the following task: {ori_instruction}.
```

Thẻ robot và các công cụ sửa đổi tùy chọn (*eo, để di động*) được đặt cho mỗi phương án; FPS và chunk_size phản ánh tần suất kiểm soát ban đầu và phạm vi dự đoán của tập dữ liệu. Bảng 2 trong Phần 3.2 tóm tắt các nền tảng robot đại diện được đề cập trong kho dữ liệu huấn luyện trước của chúng tôi cùng với cấu hình cánh tay và loại hành động của chúng.

2.4 Biểu diễn quỹ đạo và hành động thống nhất

Chúng tôi thống nhất giao diện tensor và sơ đồ mặt nạ, nhưng không ép buộc tất cả các phương án vào một không gian ngữ nghĩa hành động vật lý duy nhất. Mỗi tập dữ liệu duy trì quy ước kiểm soát gốc của nó, được chỉ định thông qua lời nhắc phương án và chuẩn hóa dành riêng cho tập dữ liệu. Cụ thể, mỗi mẫu đào tạo đều đóng gói

một tenxơ mục tiêu $\mathbf{Y} \in \mathbb{R}^{H \times K}$, trong đó H là chân trời dự đoán cố định và K là kích thước kênh cố định được chia sẻ trên tất cả các chế độ điều khiển.

Các loại tín hiệu điều khiển. Chúng tôi đề cập đến hai họ tín hiệu điều khiển liên tục. *Tín hiệu thao tác* bao gồm vị trí tác động cuối delta ($\Delta x, \Delta y, \Delta z$), xoay bộ tác động cuối được biểu thị dưới dạng góc Euler hoặc bậc bốn, vị trí khớp tuyệt đối, khẩu độ kẹp và góc khớp tay khéo léo. *Tín hiệu quỹ đạo điều hướng* tuân theo quy ước VLN và được biểu diễn dưới dạng ($\Delta x, \Delta y, \Delta \theta$) trên mỗi điểm tham chiếu, mã hóa chuyển vị tương đối và thay đổi hướng trong mặt phẳng mặt đất. Mặc dù có ngữ nghĩa vật lý khác nhau, cả hai họ đều là chuỗi các vectơ có giá trị thực được dự đoán trên một chân trời và do đó được chuyên gia hành động xử lý giống hệt nhau.

Bổ cục kênh. Một chế độ điều khiển nhất định sử dụng các kênh $c \leq K$. Các giá trị c liên quan đến nhiệm vụ này được đặt trong các kích thước c dẫn đầu của $\mathbf{Y}$ và các kích thước $K - c$ còn lại không được đếm. Mật độ nhị phân trên mỗi kênh $\mathbf{M} \in \{0, 1\}^{H \times K}$ ghi lại những kênh nào mang tín hiệu hợp lệ: $M_{h,k} = 1$ nếu và chỉ khi kênh $k < c$ và bước thời gian h nằm trong phạm vi nhiệm vụ chiều dài đoạn $H_{\text{task}} \leq H$. Sơ đồ này không yêu cầu các đầu ra theo phương án cụ thể; một bộ tham số DiT duy nhất xử lý tất cả các chế độ điều khiển, với mật độ ngăn các mục được đếm ảnh hưởng đến độ dốc.

Điều hòa nhận biết nhiệm vụ. Mỗi mẫu đào tạo đều có lời nhắc nhận biết phương án được mô tả trong Phần 2.3, trong đó chỉ định nền tảng robot, cấu hình cánh tay, tần số điều khiển và phạm vi dự đoán. Đối với các mẫu VLN, lời nhắc nêu tương tự quy ước điều hướng và đường chân trời điểm tham chiếu. Các mã thông báo nhắc này được xử lý bởi xương sống VLM và các trạng thái ẩn của chúng được nối với đoạn hành động ồn ào làm đầu vào cho DiT, do đó, chuyên gia hành động luôn được điều chỉnh theo thông số điều khiển chính xác của mẫu hiện tại mà không có bất kỳ thay đổi kiến trúc nào.

2.5 Mục tiêu đào tạo

Chúng tôi đào tạo toàn bộ mô hình từ đầu đến cuối với tổng trọng số của hai mục tiêu bao gồm việc tạo hành động liên tục và hiểu ngôn ngữ tầm nhìn.

Tổn thất hành động phù hợp với dòng chảy. Đối với tất cả các mẫu có mục tiêu kiểm soát liên tục (thao tác, điểm tham chiếu quỹ đạo VLN và dữ liệu lấy cái tôi làm trung tâm của con người sau khi căn chỉnh hành động), chúng tôi giám sát chuyên gia hành động bằng mục tiêu phù hợp với dòng chảy có điều kiện (Lipman và cộng sự, 2023). Cho mục tiêu rõ ràng $\mathbf{Y}_0 \in \mathbb{R}^{H \times K}$ và nhiễu $\mathbf{Y}_1 \sim \mathcal{N}(0, \mathbf{I})$, ta tạo thành nội suy tuyến tính $\mathbf{Y}_\tau = (1 - \tau)\mathbf{Y}_0 + \tau\mathbf{Y}_1$ với $\tau \in [0, 1]$ và đào tạo chuyên gia v_θ để dự đoán trường vận tốc có điều kiện. Để tránh độ dốc bị chi phối bởi phân phối, chúng tôi áp dụng tổn thất *trên mỗi kênh, trên mỗi bước* với hai mức trung bình. Đối với mẫu có chế độ điều khiển kích hoạt c kênh và H_{task} bước thời gian, hãy để $\mathbf{M} \in \{0, 1\}^{H \times K}$ là mật độ hợp lệ được xác định trong Phần 2.4. Trước tiên, chúng tôi tính sai số bình phương trung bình cho từng kênh đang hoạt động $k < c$:

$$\ell_k = \frac{\sum_{h=1}^H M_{h,k} \left\| (v_\theta(\mathbf{Y}_\tau, \tau \mid o_{1:t}, x, e, z) - (\mathbf{Y}_1 - \mathbf{Y}_0))_{h,k} \right\|_2^2}{\sum_{h=1}^H M_{h,k}}, \quad (1)$$

và sau đó tính trung bình đồng đều trên c kênh đang hoạt động:


$$\mathcal{L}_{\text{act}} = \mathbb{E}_{\tau, \mathbf{Y}_0, \mathbf{Y}_1} \left[\frac{1}{c} \sum_{k=0}^{c-1} \ell_k \right]. \quad (2)$$

Tính trung bình hai cấp độ này đảm bảo rằng mỗi thứ nguyên điều khiển đóng góp như nhau vào độ dốc bất kể phương án nhất định sử dụng bao nhiêu kênh và các vị trí đệm được loại trừ hoàn toàn. Khi suy luận, các khối hành động được tạo ra bằng một vài bước tích hợp Euler từ $\tau = 1$ đến $\tau = 0$.

Mất ngôn ngữ tầm nhìn. Để duy trì và tăng cường khả năng đa phương thức của xương sống, chúng tôi duy trì mức mất dự đoán mã thông báo tiếp theo tiêu chuẩn trên dữ liệu ngôn ngữ tầm nhìn phụ trợ, chú thích hành động được thể hiện chi tiết, VQA lái xe tự động và tập đoàn đào tạo trước VL chung:

$$\mathcal{L}_{\text{vl}} = - \sum_i \log p_\theta(w_i \mid w_{<i}, o_{1:t}), \quad (3)$$

trong đó w_i là mã thông báo văn bản. Mục tiêu này ổn định nền tảng ngôn ngữ trong quá trình đào tạo đồng thời chặt chẽ và ngăn ngừa tình trạng quên lãng nghiêm trọng các kỹ năng nhận thức và lý luận.



Hình 2: Công thức huấn luyện của Qwen-VLA. Giai đoạn I (T2A) huấn luyện bộ giải mã hành động DiT để tái tạo lại các hành động chỉ từ văn bản, xây dựng hành động có cấu trúc trước đó mà không cần đầu vào trực quan. Giai đoạn II (CPT) giải phóng cả hai mô-đun để làm nền tảng cho việc này trước khi quan sát trực quan. Giai đoạn III (SFT) phân nhánh thành các đường đua đa nhiệm và robot thực, còn Giai đoạn IV (RL) tối ưu hóa thành công của nhiệm vụ vòng kín thông qua phần thưởng môi trường.

Mục tiêu chung. Tồn thất tập luyện tổng thể là sự kết hợp có trọng số

$$\mathcal{L} = \lambda_{\text{act}} \mathcal{L}_{\text{act}} + \lambda_{\text{vl}} \mathcal{L}_{\text{vl}}, \quad (4)$$

trong đó các trọng số λ_{act} , λ_{vl} được điều chỉnh để cân bằng độ lớn độ dốc của hai mục tiêu. Trong mỗi lô nhỏ, chúng tôi trộn các mẫu từ tất cả các nhóm nhiệm vụ theo tỷ lệ lấy mẫu cố định để mỗi bước tối ưu hóa cùng cập nhật xương sống và chuyên gia hành động với các thao tác, quỹ đạo VLN và tín hiệu ngôn ngữ thị giác.

3 Huấn luyện trước khớp quy mô lớn

3.1 Công thức đào tạo

Một mô hình VLA có thể sử dụng được đòi hỏi phải có sự đồng đào tạo của xương sống nhận thức và bộ giải mã vận động, sự phân công lao động tương tự như vai trò bổ sung của não và tiểu não trong điều khiển vận động sinh học. Tuy nhiên, trên thực tế, hai mô-đun này được huấn luyện ở trạng thái bất đối xứng sâu: xương sống VLM đã được huấn luyện trước một cách mạnh mẽ, trong khi bộ giải mã hành động DiT được khởi tạo ngẫu nhiên. Việc đào tạo chung một cách ngây thơ ngay từ điểm xuất phát này là không hiệu quả và không ổn định. Bộ giải mã phải học một số điều cùng một lúc: hình dạng của phân phối hành động, cách điều kiện ngôn ngữ và phương án, động lực phù hợp với dòng chảy của tham số hóa của chính nó và cách đặt hành động trong tầm nhìn. Đồng thời, mỗi bước đều phải trả chi phí mã hóa hình ảnh. Trong khi đó, độ dốc nhiều từ bộ giải mã mới có thể làm nhiễu loạn đường trục được huấn luyện trước trước khi bộ giải mã học được cấu trúc hành động hữu ích.

Công thức dàn dựng của chúng tôi được thúc đẩy bởi quan điểm *nén* về học tập qua hành động. Các quỹ đạo hành động thô dày đặc, tần số cao và phụ thuộc vào phương án: một giai đoạn thao tác duy nhất có thể chứa hàng nghìn giá trị vị trí chung trải rộng trên hàng chục bậc tự do. Tuy nhiên, ý định cơ bản của nhiệm vụ được nắm bắt một cách ngắn gọn bằng hướng dẫn ngôn ngữ (“nhấc chiếc cốc màu đỏ”) và lời nhắc về phương án chỉ định nền tảng rô-bốt và quy ước điều khiển. Mô tả này phù hợp với một số mã thông báo. Tồn tại một khoảng cách lớn về chiều giữa mô tả nhiệm vụ nén này và tín hiệu hành động đầy đủ; bắc cầu nó là một vấn đề *giải nén* có cấu trúc.

Chúng tôi sử dụng T2A để tìm hiểu bản đồ giải nén này. Bằng cách giữ lại hình ảnh và đào tạo DiT chỉ dựa trên dự đoán hành động có điều kiện bằng ngôn ngữ, chúng tôi buộc bộ giải mã phải có được cấu trúc trước không gian hành động được lập chỉ mục hoàn toàn theo ngôn ngữ. Đây không chỉ là một khởi đầu khởi đầu: bộ giải mã tìm hiểu cách các mô tả ngôn ngữ khác nhau chọn các vùng khác nhau của phân bố hành động, cách các lời nhắc trong phương án điều chỉnh cùng một ý định nhiệm vụ vào các chương trình vận động dành riêng cho nền tảng cũng như tính mạch lạc và thành phần theo thời gian của các quỹ đạo hành động đầy đủ ở cấp độ trình tự, chỉ sử dụng mô tả được nén. Với hành động được lập chỉ mục theo ngôn ngữ này được áp dụng trước, quá trình đào tạo đa phương thức tiếp theo có thể tập trung năng lực vào việc đặt cơ sở cho hành động trước đó bằng các quan sát trực quan cụ thể thay vì học cách tạo ra hành động từ đầu.

Dựa trên nguyên tắc này, chúng tôi áp dụng công thức đào tạo gồm bốn giai đoạn trên nền tảng Qwen3.5 VLM đã được huấn luyện trước: (I) **huấn luyện trước DiT chuyển văn bản thành hành động (T2A)**, (II) **tiếp tục huấn luyện trước (CPT)**, (III) **được giám sát**

tình chỉnh (SFT) theo hai nhánh song song và (IV) **học tăng cường (RL)**. Mỗi giai đoạn được xác định bởi khoảng trống mà nó thu hẹp ở giai đoạn trước đó.

Giai đoạn I: Huấn luyện trước DiT chuyển văn bản thành hành động (T2A). Chúng tôi đóng băng VLM và chỉ huấn luyện DiT, điều chỉnh nó dựa trên văn bản và lời nhắc phương án e (Phần 2.3), nhưng cố tình giữ lại hình ảnh. Do đó, bộ giải mã hoạt động như một bộ giải nén ngôn ngữ thành hành động thuần túy: nó phải tái cấu trúc các phân phối hành động chiều cao chỉ từ mã hóa ngôn ngữ nhỏ gọn mà không có bất kỳ phím tắt trực quan nào. Khi làm như vậy, T2A cài đặt trước một hành động có cấu trúc trong đó ngôn ngữ sẽ chọn vùng không gian hành động, lời nhắc phương án chỉ định tham số hóa động cơ dành riêng cho nền tảng và động lực khớp luồng sẽ chi phối quá trình tổng hợp trước khi bất kỳ hình ảnh nào được đưa vào.

Giai đoạn II: Tiếp tục đào tạo trước (CPT). Với bộ giải mã được khởi động ấm, CPT tập trung năng lực đa phương thức của mình vào chính xác văn bản mà T2A không thể giải quyết: các hành động nền tảng trong quan sát trực quan và điều chỉnh xương sống cho phù hợp với nhận thức thể hiện. Chúng tôi giải phóng cả hai mô-đun và đào tạo về hỗn hợp không đồng nhất của Phần 3.2, trong đó có chủ ý kết hợp quỹ đạo mô phỏng và quỹ đạo của robot thực để điểm kiểm tra kết quả đã nhìn thấy cả hai miền. Thuộc tính này rất quan trọng đối với các giai đoạn sau đào tạo được mô tả bên dưới: SFT và RL có thể chuyên về một trong hai miền.

Giai đoạn III: Tình chỉnh có giám sát (SFT). Trong khi CPT cung cấp phạm vi bao quát rộng rãi giữa nhiều phương án và nhiều nhiệm vụ, thì việc triển khai ở hạ nguồn sẽ được hưởng lợi từ việc điều chỉnh mô hình với các bản trình diễn chất lượng cao, được tuyển chọn được rút ra từ quá trình phân phối nhiệm vụ mục tiêu. Chúng tôi phân nhánh SFT thành hai tuyến song song từ điểm kiểm tra CPT. Tuyến đầu tiên thực hiện SFT đa tác vụ để cùng tình chỉnh mô hình đối với các tác vụ không đồng nhất, bao gồm trả lời câu hỏi trực quan, nói đất không gian, thao tác và điều hướng, theo lấy mẫu cân bằng theo phương án và cân bằng tác vụ. Đường thứ hai tình chỉnh từ điểm kiểm tra CPT trên dữ liệu điều hành từ xa nội bộ để triển khai robot trong thế giới thực, kiểm tra xem các ưu tiên miền chéo của CPT có chuyển sang phần cứng vật lý hay không.

Giai đoạn IV: Học tăng cường (RL). SFT tối ưu hóa khả năng xảy ra trong các buổi biểu diễn; điều quan trọng cuối cùng là sự thành công của nhiệm vụ vòng kín, một đặc tính của các quỹ đạo được thực hiện mà không mục tiêu mô phỏng nào có thể trực tiếp tối ưu hóa. Bắt đầu từ điểm kiểm tra SFT đa tác vụ, RL tình chỉnh chính sách với các phần thưởng thành công nhị phân thừa thớt được thu thập riêng trong một môi trường mô phỏng duy nhất (SimplerEnv), tạo ra mô hình cuối cùng Qwen-VLA-Instruct. Việc thiết lập RL thu hẹp có chủ ý này sẽ kiểm tra xem các cải tiến thành công của nhiệm vụ thu được trong một môi trường mô phỏng có thể chuyển sang các môi trường ngoài phân phối khác hay không.

3.2 Dữ liệu huấn luyện trước

Chất lượng và tính đa dạng của kho ngữ liệu huấn luyện trước trực tiếp xác định mức độ thích ứng của bộ giải mã vận động và xương sống nhận thức giữa các phương án và nhóm nhiệm vụ. Chúng tôi xây dựng một hỗn hợp huấn luyện trước lớn và không đồng nhất để trang bị cho mô hình khả năng nhận thức, lý luận không gian và tạo ra hành động được thể hiện rộng rãi. Hỗn hợp này bao gồm năm họ dữ liệu: quỹ đạo thao tác của robot, minh họa lấy con người làm trung tâm, dữ liệu mô phỏng tổng hợp, dữ liệu điều hướng và tập trung vào quỹ đạo cũng như dữ liệu ngôn ngữ thị giác phụ trợ. Bảng 1 tóm tắt thành phần và trọng số lấy mẫu của từng nguồn.

Bảng 1: Thành phần hỗn hợp dữ liệu tiền huấn luyện.

Nguồn dữ liệu	Tỷ lệ (%)
Quỹ đạo thao tác của robot	74.2
Quỹ đạo ích kỷ của con người	6.0
Quỹ đạo điều hướng	7.5
Quỹ đạo mô phỏng tổng hợp (của chúng tôi)	3.7
Dữ liệu ngôn ngữ tầm nhìn chung	3.4
Nói đất không gian (2D)	2.5
Lái xe tự động VQA	2.4
Chú thích hành động thể hiện chi tiết	0.2
Tổng cộng	100.0

3.2.1 Quỹ đạo điều khiển robot

Các quỹ đạo thao tác robot thực và mô phỏng tạo thành cốt lõi của kho dữ liệu huấn luyện trước của chúng tôi, chiếm khoảng 74,2% trong tổng số hỗn hợp huấn luyện trước. Dữ liệu bao gồm thao tác trên bàn, thao tác trên thiết bị di động, tác vụ hai tay và điều khiển bằng tay khéo léo trên một tập hợp các phương án robot đa dạng.

Các tập dữ liệu công cộng. Để cải thiện quy mô, tính đa dạng và tổng quát hóa nhiều phương án, chúng tôi đào tạo trên một tập hợp rộng rãi các tập dữ liệu robot thực có sẵn công khai, bao gồm RobotSet (Bharadhwaj và cộng sự, 2023), Galaxea (Jiang và cộng sự, 2025), AgiBot World (AgiBot-World-Contributors và cộng sự, 2025), RoboCOIN (Wu et al. cộng sự, 2025b), RoboMIND V1/V2 (Wu và cộng sự, 2025a; Hou và cộng sự, 2025), RDT-1B (Liu và cộng sự, 2025a), DROID (Khaz-atsky và cộng sự, 2024), BridgeData V2 (Walke và cộng sự, 2024), RH20T (Fang và cộng sự, 2024), RT-1 (Brohan và cộng sự, 2022) và BC-Z (Jang và cộng sự, 2022). Các bộ dữ liệu này bao gồm các cài đặt robot đa dạng, bao gồm thao tác trên bàn, thao tác trên thiết bị di động, thao tác bằng hai tay, điều khiển bằng tay khéo léo và thực hiện nhiệm vụ trong tự nhiên, lên tới hơn 10.000 giờ dữ liệu tương tác trên các phương án và kịch bản nhiệm vụ không đồng nhất. Hỗn hợp quy mô lớn này cung cấp khả năng giám sát bổ sung đối với hình thái robot, góc nhìn của camera, danh mục đối tượng, nền, hướng dẫn ngôn ngữ và phân bổ hành động, từ đó giảm việc trang bị quá mức cho bất kỳ phương án hoặc môi trường đơn lẻ nào và cải thiện tính ổn định khi thay đổi phân phối.

Ngoài dữ liệu robot thực, chúng tôi còn bao gồm các quỹ đạo thao tác dựa trên mô phỏng từ InternData-A1 (Tian và cộng sự, 2025) và GR00T-X-Embodiment-Sim (NVIDIA và cộng sự, 2025), được tạo ra thông qua lập kế hoạch chuyển động trong các môi trường ảo đa dạng. Những quỹ đạo mô phỏng này làm tăng tính đa dạng của cảnh và đối tượng, đặc biệt đối với cấu hình đối tượng đuôi dài và bố cục nhiệm vụ. Trước khi đào tạo, tất cả các tập dữ liệu thực và mô phỏng đều được quản lý và chuyển đổi thành định dạng hành động quan sát thống nhất trong khi vẫn giữ nguyên ngữ nghĩa nhiệm vụ ban đầu, cho phép đào tạo có thể mở rộng qua trải nghiệm robot không đồng nhất.

Bộ dữ liệu độc quyền. Chúng tôi bổ sung hơn 1.000 giờ quỹ đạo của rô-bốt thực được thu thập nội bộ bao gồm nhiều nhiệm vụ thao tác và nền tảng rô-bốt khác nhau, cùng đóng góp khoảng 20% tổng hỗn hợp đào tạo trước. Ngoài ra, chúng tôi tạo ra hơn 8 triệu quỹ đạo mô phỏng tổng hợp bằng cách sử dụng quy trình mô phỏng có thể mở rộng được minh họa trong Phần 3.2.3, đóng góp thêm 3,7% hỗn hợp và mở rộng đáng kể tính đa dạng của cảnh, vật thể và cấu hình nhiệm vụ ngoài những gì hoạt động từ xa của robot thực có thể thực hiện được.

Điều hòa lời nhắc nhận biết phương án. Như được mô tả trong Phần 2.3, mỗi ví dụ đào tạo đều được thêm vào trước một lời nhắc dành riêng cho robot chỉ định nền tảng hiện tại, cấu hình cánh tay và quy ước điều khiển. Bảng 2 liệt kê các phương án đại diện trong kho dữ liệu huấn luyện trước của chúng tôi cùng với cấu hình cánh tay và kiểu hành động của chúng.

Bảng 2: Các phương án robot đại diện trong kho dữ liệu huấn luyện trước. tư thế tác động cuối “EEF”=; “Khớp”=góc khớp; “Δ” = lệnh delta (tương đối); “Abs” = lệnh tuyệt đối; kẹp “G”=; “DH”= bàn tay khéo léo.

Robot	Cánh tay	Loại hành động
góa phụX	Độc thân	ΔEEF+G
Robot Google	Độc thân	ΔEEF+G
Franka Panda	Đơn / Kép	ΔEEF+G; Khớp cơ bụng+G
ARX5	kép	ΔEEF+G
Fourier GR-1	kép	ΔEEF+G
ALOHA di động	kép	ΔEEF+G; Khớp cơ bụng+G
AgiBot A2-D	kép	Cơ bụng +G; Cơ bụng +DH
Galaxea R1	kép	Khớp cơ bụng+G
AIRBOT MMK2	kép	Cơ bụng +DH
TiếnKung	kép	Khớp cơ bụng+G; Cơ bụng +DH
Con người thật	kép	ΔEEF (từ MANO)

Biểu diễn hành động. Các bộ dữ liệu khác nhau áp dụng các quy ước hành động khác nhau: một số cung cấp các tư thế tác động cuối tuyệt đối trong không gian Descartes (Xie và cộng sự, 2026), một số khác cung cấp các lệnh tác động cuối delta và một số khác sử dụng các tín hiệu điều khiển không gian khớp tuyệt đối hoặc tương đối. Chúng tôi giữ nguyên định dạng hành động ban đầu của mỗi tập dữ liệu thay vì chuyển đổi sang dạng biểu diễn dùng chung, dựa vào điều kiện kịp thời nhận biết phương án để thông báo cho mô hình về quy ước kiểm soát hiện tại. Tất cả các thứ nguyên hành động được chuẩn hóa cho mỗi tập dữ liệu bằng cách sử dụng số liệu thống kê lượng tử. Đối với mỗi chiều hành động d

trong tập dữ liệu k , chúng tôi tính toán phân vị thứ 1 và thứ 99 q_{01}^k và q_{99}^k trên tất cả các quỹ đạo và áp dụng ánh xạ tuyến tính:

$$\tilde{a}_d = 2 \cdot \frac{a_d - q_{01}^k}{q_{99}^k - q_{01}^k} - 1, \quad (5)$$

cắt kết quả thành $[-1, 1]$. Quá trình chuẩn hóa lượng tử trên mỗi tập dữ liệu này sẽ loại bỏ sự khác biệt về tỷ lệ giữa các phương án và không gian hành động trong khi vẫn duy trì cấu trúc chuyển động tương đối trong mỗi nguồn.

Hướng dẫn ngôn ngữ. Hướng dẫn ngôn ngữ có nguồn gốc từ sự kết hợp giữa chú thích tập dữ liệu gốc và chú thích do mô hình tạo được cung cấp cùng với dữ liệu. Tất cả các hướng dẫn đều trải qua quy trình kiểm tra tính nhất quán và lọc chất lượng: các quỹ đạo có chú thích ngôn ngữ không nhất quán với chuyển động được quan sát sẽ bị loại bỏ, đảm bảo sự liên kết hành động-ngôn ngữ đáng tin cậy trên nhiều nguồn khác nhau. Ngoài dữ liệu được gắn nhãn hành động, chúng tôi còn kết hợp các cặp chú thích-video được thể hiện chi tiết (được mô tả trong Phần 3.2.5) làm chức năng giám sát ngôn ngữ-hình ảnh phụ trợ. Tín hiệu ngôn ngữ dày đặc này thu hẹp khoảng cách giữa các nhãn nhiệm vụ thô sơ và các mô tả ngữ nghĩa phong phú về hành vi của robot, cho phép mô hình khái quát hóa phạm vi hướng dẫn ngôn ngữ tự nhiên rộng hơn tại thời điểm suy luận.

Trình bày chế độ xem camera. Nhiều bộ dữ liệu robot cung cấp các quan sát từ nhiều điểm xem camera cùng một lúc, ví dụ. một máy ảnh lấy cái tôi làm trung tâm gắn trên đầu cùng với một hoặc hai máy ảnh gắn trên cổ tay. Để làm cho nguồn gốc của chế độ xem trở nên rõ ràng đối với mô hình, chúng tôi gộp từng hình ảnh trong luồng mã thông báo bằng một cặp mã thông báo ranh giới dành riêng cho chế độ xem:

`<|tag_start|> <image> <|tag_end|>`

trong đó *thẻ* xác định nguồn camera, ví dụ. `ego`, `cam_left_wrist` hoặc `cam_right_wrist`. Các nhãn chế độ xem rõ ràng cho phép xương sống VLM hình thành các biểu diễn nhận biết chế độ xem và cho phép chuyên gia hành động tham gia có chọn lọc vào từng quan điểm khi tạo hành động mà không yêu cầu bất kỳ thay đổi kiến trúc hoặc kênh đầu vào bổ sung nào.

Làm sạch dữ liệu. Chúng tôi áp dụng quy trình lọc nhiều giai đoạn để loại bỏ quỹ đạo có khung bị hỏng hoặc bị thiếu, chuỗi hành động có phương sai gần như bằng 0 biểu thị các bản ghi tĩnh và các tập có độ dài bất thường. Đối với các tập dữ liệu không có nhãn hành động rõ ràng, các hành động giả được phục hồi thông qua các khác biệt hữu hạn trên các chuỗi trạng thái sở hữu.

3.2.2 Dữ liệu về con người lấy cái tôi làm trung tâm

So với quỹ đạo của robot điều khiển từ xa, các cuộc biểu tình của con người lấy cái tôi làm trung tâm mang lại nguồn trải nghiệm thao tác trong thế giới thực phong phú và có thể mở rộng hơn. Con người tương tác với các vật thể đa dạng trong môi trường thế giới mở mỗi ngày, tạo ra các hành vi thao tác khéo léo một cách tự nhiên trải rộng trên phạm vi cảnh, vật thể và ngữ nghĩa nhiệm vụ rộng hơn nhiều so với hoạt động từ xa của robot. Các nghiên cứu gần đây chứng minh rằng việc đào tạo về video con người lấy cái tôi làm trung tâm trên quy mô lớn mang lại cho các mô hình hành động-ngôn ngữ-thị giác với các ưu tiên thao tác phong phú hơn và cải thiện khả năng khái quát hóa cho các nhiệm vụ của robot ở phía dưới (Kareer và cộng sự, 2025; Luo và cộng sự, 2025; Li và cộng sự, 2026b; Luo và cộng sự, 2026; Zheng và cộng sự, 2026; Hu và cộng sự, 2026). Được thúc đẩy bởi những phát hiện này, chúng tôi kết hợp một bộ sưu tập đa dạng các bộ dữ liệu thao tác tự nhiên của con người (6,0% trong tổng số hỗn hợp huấn luyện trước) để cung cấp cho mô hình các ưu tiên thao tác rộng bổ sung cho dữ liệu quỹ đạo của robot.

Nguồn dữ liệu. Kho dữ liệu lấy cái tôi làm trung tâm của chúng tôi được rút ra từ bốn tập dữ liệu có sẵn công khai, mỗi tập dữ liệu đóng góp vào phạm vi bổ sung về tính đa dạng của nhiệm vụ, sự đa dạng của cảnh và mức độ chi tiết của chú thích. **(1)** Chúng tôi áp dụng các tập hợp con Ego4D (Grauman và cộng sự, 2022) và EPIC-KITCHENS (Damen và cộng sự, 2022) do VITRA (Li et al., 2022) xử lý. 2026b), áp dụng một quy trình tự động để phân đoạn các video của con người lấy cái tôi làm trung tâm thành các quỹ đạo thao tác nguyên tử và tạo ra các chú thích ngôn ngữ chi tiết, cùng với các quỹ đạo chuyển động của máy ảnh và bàn tay 3D theo khung hình. **(2)** EgoDex (Hoque và cộng sự, 2026) là một tập dữ liệu thao tác khéo léo quy mô lớn được ghi lại bằng Apple Vision Pro, bao gồm 829 giờ video lấy cái tôi làm trung tâm với tính năng theo dõi bàn tay và ngón tay 3D được ghép nối xuyên suốt 194 nhiệm vụ trên bàn đa dạng. **(3)** EgoVerse (Punamiya và cộng sự, 2026) là một nền tảng trình diễn hợp tác lấy cái tôi làm trung tâm kéo dài hơn 1.300 giờ với 1.965 nhiệm vụ và 240 cảnh, với các định dạng được tiêu chuẩn hóa và các chú thích liên quan đến thao tác. **(4)** Xperience (Ropedia, 2026) là một tập dữ liệu đa phương thức lấy cái tôi làm trung tâm quy mô lớn cung cấp các bản ghi đồng bộ ở góc nhìn thứ nhất với khả năng ghi lại chiều sâu, chuyển động của bàn tay và cơ thể cũng như chú thích ngôn ngữ phân cấp.

Biểu diễn hành động. Mô hình này nhận được hình ảnh lấy tự nhiên làm trung tâm tại một bước thời gian tùy ý cùng với hướng dẫn ngôn ngữ và dự đoán đoạn hành động bao gồm chuyển động cổ tay bằng hai tay trong tương lai và bàn tay

khớp nối trên một chân trời dự đoán cố định. Đối với mỗi bàn tay, chuyển động của cổ tay được biểu diễn dưới dạng phép biến đổi $SE(3)$ của khung tọa độ cổ tay ở bước thời gian trong tương lai so với khung ban đầu. Trong quá trình luyện tập, hành động tương đối này được biểu diễn bằng vector dịch chuyển và góc xoay trục, mang lại 6 kích thước hành động cổ tay cho mỗi bàn tay. Để thể hiện khớp nối bàn tay một cách gọn gàng, chúng tôi thực hiện phân tích thành phần chính (PCA) trên tư thế khớp góc trục 45 chiều của bàn tay trên tất cả các tập dữ liệu của con người và giữ lại trọng số của 10 thành phần chính đầu tiên. Các hệ số chiều thấp này, được gọi là *eigengrasps* (Ciocarlie và cộng sự, 2007; Yuan và cộng sự, 2025), nắm bắt các phương thức chủ yếu của biến đổi tư thế bàn tay của con người trong khi loại bỏ sự dư thừa trên mỗi khớp. Mô hình này dự đoán các hành động tương đối của cổ tay và 10 hệ số riêng cho mỗi bàn tay, mang lại tổng cộng 32 chiều hành động trên mỗi bước thời gian cho dữ liệu về con người lấy cái tôi làm trung tâm.

3.2.3 Dữ liệu mô phỏng tổng hợp

Để cải thiện phạm vi bao phủ, khả năng kiểm soát và độ tin cậy của tính năng giám sát được thể hiện, chúng tôi xây dựng một đường dẫn dữ liệu mô phỏng tổng hợp quy mô lớn với hai thành phần bổ sung: (1) *dữ liệu tầm nhìn-ngôn ngữ-hành động*, trong đó mô hình dự đoán hành động từ cả hướng dẫn nhiệm vụ và quan sát hình ảnh và (2) *dữ liệu hành động ngôn ngữ*, trong đó mô hình dự đoán hành động chỉ từ ngôn ngữ. Hai nguồn giám sát này đóng vai trò khác nhau nhưng có tác dụng hiệp đồng. Thành phần chỉ có văn bản khuyến khích mô hình đạt được sự trừu tượng hóa nhiệm vụ cấp cao và tính quy luật hành động ngôn ngữ mà không phụ thuộc vào hình thức trực quan, trong khi thành phần điều chỉnh tầm nhìn đưa ra những sự trừu tượng đó trong các quan sát nhận thức thực tế, các biến thể của cảnh và động lực tương tác được thể hiện. Chúng tôi đã phát triển quy trình của mình dựa trên IsaacLab (Mittal và cộng sự, 2025) cho môi trường mô phỏng của chúng tôi và cuRobo (Sundaralingam và cộng sự, 2023) để lập kế hoạch chuyển động tránh va chạm.

Dữ liệu thị giác-ngôn ngữ-hành động. Đối với dữ liệu tổng hợp điều chỉnh thị giác, chúng tôi sử dụng phiên bản nội bộ ban đầu của ROBOINF (XLANG Lab, 2026) để tạo ra khả năng giám sát kiểu VLA tiêu chuẩn, trong đó mô hình nhận hướng dẫn ngôn ngữ và quan sát hình ảnh làm đầu vào và dự đoán hành động của robot là đầu ra. ROBOINF xây dựng các cảnh thao tác, tạo các nhiệm vụ có điều kiện theo cảnh, tổng hợp các bước kiểm tra thành công có thể thực thi được, tạo ra các chương trình chuyển động của rô-bốt thông qua phân hồi của trình mô phỏng và triển khai các quỹ đạo thành công theo phương pháp ngẫu nhiên hóa miền. Vì chi tiết kỹ thuật đầy đủ của quy trình được cung cấp trong bài đăng trên blog ROBOINF của chúng tôi nên chúng tôi chỉ tóm tắt thành phần và tính đa dạng của tập dữ liệu ở đây.


Trong bản phát hành này, chúng tôi tập trung vào cài đặt tạo cảnh theo vị trí ngẫu nhiên để đơn giản hóa. Chúng tôi xây dựng 20 cảnh trên bàn, mỗi cảnh được tăng cường với 10 cấu hình tư thế ban đầu của đối tượng khác nhau, tạo ra 200 cấu hình cảnh cơ sở. Những cảnh này chứa các vật thể hàng ngày đa dạng được sắp xếp theo bố cục trên mặt bàn có giá trị vật lý, cung cấp các bối cảnh không gian và hình ảnh đa dạng để thao tác.

Ngoài những cảnh này, chúng tôi tạo ra 450 tác vụ thao tác bao gồm cả hành vi ngắn hạn và dài hạn. Các tác vụ có thời gian ngắn thường bao gồm một số ít các bước thao tác cơ bản, chẳng hạn như “*Đặt hai chiếc kim bấm màu xanh lá cây cạnh nhau*”. Các nhiệm vụ có thời gian dài yêu cầu nhiều tương tác tuần tự hoặc lý luận mang tính tổng hợp hơn, chẳng hạn như “*Nhóm các đồ uống lại với nhau và để riêng miếng bọt biển lau chùi*”, trong đó robot cần thao tác một số đồ vật theo trình tự. Như được minh họa trong Hình 3, hỗn hợp nhiệm vụ này cung cấp cho mô hình cả các kỹ năng thao tác nguyên tử và các mẫu làm theo hướng dẫn ở cấp độ cao hơn trong các phạm vi thời gian mở rộng.

Đối với mỗi nhiệm vụ, chúng tôi tạo ra 300 quỹ đạo thành công với môi trường và các biện pháp tăng cường thực thi khác nhau. Trong quá trình triển khai, chúng tôi ngẫu nhiên hóa các yếu tố liên quan đến hình ảnh, hình học và điều khiển, bao gồm ánh sáng, tư thế máy ảnh, hình nền, kết cấu bàn, trạng thái ban đầu của robot, tư thế ban đầu của đối tượng và động lực học của bộ điều khiển như độ cứng và giảm chấn. Để ngẫu nhiên hóa trực quan, chúng tôi lấy mẫu từ một nhóm lớn có nền khoảng 3K và kết cấu bảng 1K. Đối với các yếu tố khác, chẳng hạn như tư thế máy ảnh, trạng thái robot, ánh sáng và thông số bộ điều khiển, chúng tôi xác định phạm vi hợp lý theo cách thủ công và lấy mẫu các biến thể trong phạm vi đó. Những cải tiến này được thiết kế để cải thiện tính mạnh mẽ đối với những thay đổi phân phối về hình thức, quan điểm, bố cục và động lực thực thi cấp thấp.

Đặc tính hữu ích của dữ liệu được tạo ra này là các quỹ đạo được tạo ra từ các chương trình lập kế hoạch chuyển động được phân tách tự nhiên thành các giai đoạn trung gian. Do đó, chúng tôi cũng phân chia từng quỹ đạo đầy đủ thành một số quỹ đạo nhiệm vụ phụ, như trong Hình 3. Điều này cung cấp khả năng giám sát ở nhiều mức độ chi tiết theo thời gian: các quỹ đạo đầy đủ dạy mô hình tuân theo các hướng dẫn cấp cao trong các tầm nhìn dài hơn, trong khi các quỹ đạo nhiệm vụ phụ đưa mô hình đến các hành vi nguyên tử ngắn hơn và các mục tiêu trung gian. Chúng tôi kỳ vọng sự kết hợp này sẽ giúp mô hình kết nối tốt hơn các hướng dẫn ngôn ngữ cấp cao với các phân đoạn hành động cấp thấp hơn cần thiết để hoàn thành chúng.

Nhìn chung, dữ liệu tổng hợp điều chỉnh tầm nhìn chứa 359.848 quỹ đạo thành công đầy đủ bao gồm các phân đoạn nhiệm vụ phụ. Tập dữ liệu thu được cung cấp một nguồn giám sát VLA đa dạng, có thể kiểm soát và được xác minh tự động trên quy mô lớn, bổ sung cho các minh chứng trong thế giới thực và cải thiện



Hình 3: Ví dụ về dữ liệu được tạo thông qua ROBOINF. Hàng trên cùng hiển thị một nhiệm vụ có chiều ngang ngắn, “Đặt hai chiếc kim bấm màu xanh lá cây cạnh nhau,” bao gồm một chuỗi ngắn gọn các thao tác với, nắm, vận chuyển và đặt. Hàng dưới cùng hiển thị một nhiệm vụ có phạm vi dài, “Nhóm các đồ uống lại với nhau và để riêng miếng bọt biển làm sạch,” yêu cầu nhiều thao tác đối tượng và có thể được phân tách thành các phân đoạn nhiệm vụ phụ như chọn và đặt từng đồ uống.

khái quát hóa mô hình qua các loại nhiệm vụ, điều kiện trực quan và các biến thể thực thi.

Dữ liệu hành động ngôn ngữ. Ngoài ra, chúng tôi còn xây dựng một tập dữ liệu hành động chỉ có văn bản làm nguồn giám sát bổ sung. Mục tiêu của thành phần này là đưa mô hình vào một không gian rộng lớn gồm các ý định thao tác và các mẫu hành động trước khi đưa ra các quan sát trực quan, từ đó khuyến khích sự khái quát hóa trong không gian chung ngôn ngữ-hành động. Cụ thể, chúng tôi nghĩ ra một tập hợp đa dạng các nhiệm vụ thao tác nguyên tử và thành phần mà robot có thể thực hiện trong mô phỏng và tạo ra các quỹ đạo tương ứng bằng cách sử dụng các đường ống lấy trạng thái làm trung tâm của robot mà không cần đầu vào hình ảnh. Dữ liệu này chủ yếu đóng vai trò như một hình thức huấn luyện trước về ngữ nghĩa và hành vi, giúp mô hình nắm bắt các cấu trúc nhiệm vụ phổ biến như di chuyển, nhóm, tách, căn chỉnh, xoay, xếp chồng và sắp xếp lại các đối tượng chỉ từ hướng dẫn ngôn ngữ.

Cụ thể, chúng tôi xác định sáu họ mẫu tác vụ bao gồm các nguyên tắc thao tác một cánh tay cốt lõi: chọn và đặt, đẩy tuyến tính, kéo tuyến tính, xoay với định vị lại, xoay theo hướng quan điểm và hoán đổi vị trí của hai đối tượng. Mỗi mẫu mã hóa cấu trúc chuyển động chuẩn trong khi ngẫu nhiên hóa các tham số không gian và mô tả ngôn ngữ tự nhiên giữa các phiên bản. Các hướng dẫn được soạn thảo theo thủ tục từ các từ vựng theo mẫu cụ thể gồm động từ, giới từ, tên đối tượng và tham chiếu không gian để tạo ra các mô tả khác nhau về cùng một hành vi cơ bản (ví dụ: “Đặt quả táo vào thùng chứa”, “Di chuyển miếng bọt biển về phía vị trí mục tiêu”). Thiết kế này cung cấp khả năng kiểm soát chính xác về phạm vi và độ khó của nhiệm vụ trong khi vẫn đủ đơn giản để mở rộng tới hàng triệu quỹ đạo.

Để đảm bảo phạm vi bao quát rộng rãi về hình học không gian làm việc và động học theo phương án cụ thể, chúng tôi khởi tạo tất cả sáu mẫu nhiệm vụ trên sáu cấu hình rô-bốt một tay (Franka Panda, UR10e, UR5e, Kinova Gen3, TM12 và xArm7) trải rộng trên nhiều mức độ tự do, hình thái cánh tay và không gian làm việc có thể tiếp cận khác nhau. Đối với mỗi cặp rô-bốt-nhiệm vụ, chúng tôi tạo ra khoảng 200 nghìn quỹ đạo, mang lại khoảng 7,2 triệu quỹ đạo và tổng cộng hơn 14.000 giờ dữ liệu quỹ đạo mô phỏng của rô-bốt. Quá trình tổng hợp quỹ đạo được tiến hành mà không cần mô phỏng vật lý hoặc kết xuất cảnh: đối với mỗi trường hợp, chúng tôi lấy mẫu các tư thế mục tiêu của tác nhân cuối cùng

trong giới hạn không gian làm việc có thể tiếp cận của robot, ngẫu nhiên hóa các vị trí, hướng và khoảng cách giữa các tư thế, đồng thời tính toán các đường dẫn trong không gian chung không va chạm bằng cách sử dụng công cụ lập kế hoạch chuyển động hàng loạt được tăng tốc GPU. Quy trình tạo được song song trên nhiều GPU, trong đó mỗi công nhân lấy mẫu độc lập các cấu hình mục tiêu, lập kế hoạch chuyển động và viết các quỹ đạo thành công. Chỉ những quỹ đạo hợp lệ về mặt động học mà người lập kế hoạch đưa ra các giải pháp khả thi, không va chạm trên tất cả các phân đoạn chuyển động cần thiết mới được giữ lại.

Mỗi quỹ đạo ghi lại các vị trí khớp, vận tốc khớp, tư thế tác động cuối (vị trí và hướng) và trạng thái tay kẹp ở tần số 50 Hz, cung cấp tín hiệu giám sát phong phú và linh hoạt có thể hỗ trợ nhiều biểu diễn hành động và chế độ điều khiển khác nhau trong quá trình huấn luyện.

Trong quá trình đào tạo, tập dữ liệu này đóng vai trò là kho dữ liệu chính cho giai đoạn tiền huấn luyện T2A Giai đoạn I (Phần 3.1), trong đó bộ giải mã hành động DiT được khởi tạo trên các tương ứng ngôn ngữ-hành động trước khi đưa nền tảng trực quan vào. Bằng cách đưa bộ giải mã tiếp xúc với một tập hợp lớn và đa dạng các cặp ngôn ngữ-hành động mà không cần điều chỉnh thị giác, thành phần này tạo ra các lỗi tất thực quan và thiết lập hành động mạnh mẽ trước đó để chuyển sang và bổ sung cho các giai đoạn huấn luyện có điều kiện về thị giác ở phía dưới.

3.2.4 Dữ liệu điều hướng.

Chúng tôi kết hợp dữ liệu Điều hướng (7,5%), nổi bật với quỹ đạo đường chân trời dài cùng với thông tin trực quan phong phú. Robot di động được giả định có 3 bậc tự do: tịnh tiến trong mặt phẳng và quay quanh trục thẳng đứng (góc hướng). Dữ liệu điều hướng bao gồm các video điều hướng (được lấy mẫu ở tốc độ 2 FPS), hướng dẫn và thông tin quỹ đạo, cùng trang bị cho mô hình các khả năng di động như làm theo hướng dẫn, tìm kiếm đối tượng và theo dõi mục tiêu.

Tuân theo hướng dẫn. Dữ liệu điều hướng theo hướng dẫn (4,3%) bao gồm nhiều phạm vi điều hướng đa dạng và mức độ chi tiết của hướng dẫn. Trong các tập này, robot di động phải thực hiện các lệnh kết hợp các nguyên tắc chuyển động nguyên thủy (ví dụ: di chuyển về phía trước, rẽ phải/trái, dừng) với các mốc văn bản. Dữ liệu này khuyến khích mô hình căn chỉnh lịch sử điều hướng với hướng dẫn đã cho và dự đoán quỹ đạo tiếp theo.

Tìm kiếm đối tượng. Dữ liệu tìm kiếm đối tượng (2,3%) bắt nguồn từ lịch sử điều hướng trong đó robot tìm kiếm đối tượng được mô tả bằng văn bản trong môi trường trong nhà quy mô lớn. Robot được thử thách ghi nhớ các khu vực đã được điều hướng trước đó đồng thời khám phá một cách hiệu quả để xác định vị trí mục tiêu. Những giai đoạn như vậy thúc đẩy khả năng nhận dạng và khám phá tầm nhìn dài hạn của mô hình.

Theo dõi mục tiêu. Dữ liệu theo dõi mục tiêu (1,0%) bao gồm các tập trong đó robot đi theo mục tiêu đang di chuyển (ví dụ: người được mô tả) qua các không gian trong nhà, duy trì khoảng cách theo dõi an toàn và giữ mục tiêu trong tầm nhìn. Các quỹ đạo thu được kết hợp các điều chỉnh chuyển động phản ứng với các quyết định về đường đi có tầm nhìn dài hơn được kích hoạt bởi các ngã rẽ hoặc tắc nghẽn.

3.2.5 Dữ liệu ngôn ngữ thị giác.

Chúng tôi tiếp tục kết hợp giám sát ngôn ngữ thị giác bổ trợ (tổng cộng 8,5%) để củng cố nền tảng ngữ nghĩa, hướng dẫn chi tiết theo sau và lý luận trực quan chung.

Chú thích hành động được thể hiện chi tiết. Hầu hết các bộ dữ liệu robot hiện có chỉ cung cấp các nhãn ở cấp độ nhiệm vụ thô (ví dụ: “nhắc bát sứ lên”). Nhãn này không đủ để dự đoán hành động chính xác: cùng một nhãn có thể tương ứng với các chiến lược thực hiện rất khác nhau (ví dụ: nắm từ bên trái so với bên phải, xoay theo chiều kim đồng hồ so với ngược chiều kim đồng hồ), tạo ra sự mơ hồ trong quá trình tìm hiểu chính sách. Lấy cảm hứng từ việc kiểm soát văn bản chi tiết trong quá trình tạo video, chúng tôi xây dựng các mô tả hành động đầy đặc kết hợp chặt chẽ ngôn ngữ với từng tập riêng lẻ. Để xây dựng một bộ chú thích đa dạng nhưng có thể quản lý được, chúng tôi rút ra các tập từ các bộ dữ liệu thao tác nguồn mở chính trên tất cả các danh mục nhiệm vụ và áp dụng chiến lược lựa chọn dựa trên phân cụm: các tập trong mỗi nhiệm vụ được nhóm theo thông tin hành động của chúng và các tập đại diện được lấy mẫu để đảm bảo phạm vi bao phủ rộng. Mỗi tập được chọn sẽ được chú thích theo 13 chiều: hành động nguyên thủy, nhận dạng tác nhân, nhận dạng và định hướng đối tượng, vùng tiếp xúc, vị trí nguồn và đích, quỹ đạo và hướng, trạng thái tay kẹp và chuyển động cơ thể. Chúng tôi sử dụng quy trình hai giai đoạn để chú thích. Trong giai đoạn đầu tiên, mô hình ngôn ngữ tầm nhìn (Qwen3.6-plus) xem video và trích xuất chuỗi hành động thô cùng với đối tượng được thao tác. Ở giai đoạn thứ hai, video được lấy mẫu dày đặc thành các khung hình để bảo toàn các chi tiết chuyển động tinh tế; Sau đó, mô hình sẽ xem lại các khung hình này dựa trên đầu ra ở giai đoạn đầu tiên và tạo ra các mô tả chi tiết từng bước được làm giàu với các điểm tiếp xúc, mối quan hệ không gian và quỹ đạo chuyển động. Đối với các tập dữ liệu có nhiều chế độ xem, một thể sàng lọc bổ sung kết hợp cảnh quay ở cổ tay hoặc camera bên để chỉnh sửa các chi tiết chỉ hiển thị khi chụp cận cảnh hoặc

những quan điểm thay thế. Tất cả các chú thích được tạo cuối cùng đều được người chú thích xem xét và sửa chữa. Quy trình này mang lại khoảng 48.000 cặp phụ đề video chi tiết (0,2% hỗn hợp tiền huấn luyện). Bảng 3 đối chiếu nhãn thô với chú thích chi tiết của chúng tôi cho cùng một tập.

Bảng 3: Nhãn tác vụ thô so với chú thích hành động chi tiết cho cùng một tập.

Nhãn thô	“Nhắc lên, xoay và đặt chiếc bát sứ vào.”
Hạt mịn	<i>Bước 1:</i> Nhắc bát sứ từ mép xa bên phải. <i>Bước 2:</i> Xoay bát theo chiều kim đồng hồ để tạo thành hai vòng tròn đầy đủ. <i>Bước 3:</i> Đặt bát vào giữa bàn.

Dựa trên dữ liệu được chú thích, chúng tôi tinh chỉnh thêm VLM chuyên dụng cho chú thích hành động được thể hiện. Chúng tôi cũng thiết kế một tiêu chuẩn đánh giá đồng hành bao gồm các cặp QA bắt nguồn từ các chú thích thực tế cùng với thang đánh giá chấm điểm để đánh giá chất lượng phụ đề.

VQA lái xe tự động. Chúng tôi kết hợp dữ liệu trả lời câu hỏi trực quan về lái xe tự động (2,4%) như một nguồn bổ sung cho hoạt động giám sát định hướng quyết định, có căn cứ trực quan. Sự kết hợp này tập trung vào bốn khả năng có thể chuyển đổi: (1) *Hiểu biết về bối cảnh tạm thời*: các cảnh lái xe phát triển theo chuyển động của bản ngã, các tác nhân năng động và các mối nguy hiểm luôn thay đổi. Chúng tôi bao gồm LingoQA (Marcu và cộng sự, 2024), DriveAction (Hao và cộng sự, 2025) và MMAU (Fang và cộng sự, 2024) để tăng cường hiểu biết về sự kiện và dự đoán trạng thái trong tương lai. (2) *Lý luận về không gian nhìn xung quanh*: quan sát nhiều camera cung cấp bối cảnh hình học trường rộng. Chúng tôi bao gồm Impromptu-VLA (Chi và cộng sự, 2025), nuScenes-QA (Qian và cộng sự, 2024), nuScenes-MQA (Inoue và cộng sự, 2024), MapLM (Cao và cộng sự, 2024) và WaymoQA (Yu và cộng sự, 2025b) để cải thiện khả năng bản địa hóa mạnh mẽ về quan điểm và hiểu biết về mối quan hệ không gian giữa các phương tiện, cảm biến khác nhau, và bố trí đường. (3) *Bản địa hóa dựa trên ngôn ngữ*: các tác nhân được thể hiện phải liên kết ngôn ngữ với các đối tượng, vùng và quan hệ không gian trước khi hành động. Chúng tôi bao gồm CODA-LM (Chen và cộng sự, 2025a), Talk2Car (Deruyttere và cộng sự, 2019), DrivingVQA Corbieri và cộng sự. (2025), DriveLM (Sima và cộng sự, 2024), W3DA (Zhou và cộng sự, 2025) và GRAID (El-maaroufi và cộng sự, 2025) để trả lời câu hỏi dựa trên nền tảng đối tượng và nhận thức khu vực. (4) *Lập luận dựa trên kế hoạch*: việc đưa ra quyết định an toàn đòi hỏi phải liên kết nhận thức với các hạn chế về tuyến đường, làn đường và quỹ đạo. Chúng tôi bao gồm Bench2Drive-VL (Jia và cộng sự, 2026), DriveGPT4 (Xu và cộng sự, 2024), OmniDrive (Wang và cộng sự, 2025b), Senna (Jiang và cộng sự, 2024), NAVSIM-RecogDrive (Li và cộng sự, 2026c) và NAVSIM-Traj để cung cấp khả năng giám sát cho việc lựa chọn thao tác và dự đoán quỹ đạo trong tương lai. Trước khi huấn luyện trước, tất cả các nguồn dữ liệu đều trải qua quá trình chuẩn hóa thành định dạng hội thoại thống nhất. Chúng tôi chuyển đổi các chú thích trắc nghiệm thành giám sát QA dạng tự do và chuẩn hóa các hộp giới hạn thành hệ tọa độ tỷ lệ 1000. Ngoài ra, các mẫu nhiều khung hình nhận thức khung hình để duy trì trật tự thời gian, trong khi các mẫu chế độ xem xung quanh được gán thẻ chế độ xem để biểu thị rõ ràng nhận dạng camera. Nói chung, các nguồn có cấu trúc này cung cấp khả năng giám sát có thể chuyển đổi để xây dựng nền tảng lấy đối tượng làm trung tâm, ước tính trạng thái tạm thời, dự đoán ý định và ra quyết định dựa trên mục tiêu. Điều này bổ sung một cách toàn diện cho dữ liệu thao tác và điều hướng được sử dụng trong quá trình đào tạo trước được thể hiện của chúng tôi.

Nói đất không gian. Chúng tôi bao gồm dữ liệu nói đất hộp giới hạn 2D (2,5%) để củng cố hiểu biết về không gian ở cấp độ đối tượng. Nền tảng không gian chính xác là điều kiện tiên quyết cho thao tác có điều kiện bằng ngôn ngữ, trong đó mô hình phải bản địa hóa các đối tượng liên quan đến nhiệm vụ từ các mô tả được chỉ định theo hướng dẫn.

Dữ liệu ngôn ngữ tầm nhìn chung. Để duy trì nhận thức thị giác mạnh mẽ và nền tảng ngôn ngữ trong quá trình đào tạo trước VLA được thể hiện, chúng tôi bổ sung tập dữ liệu chính tập trung vào hành động bằng một hỗn hợp được tuyển chọn gồm dữ liệu ngôn ngữ tầm nhìn chung (3,4% tổng số mã thông báo). Hỗn hợp phụ trợ này rõ ràng bao gồm: (1) dữ liệu phụ đề để căn chỉnh văn bản-hình ảnh; (2) VQA định hướng kiến thức và lý luận trực quan để lưu giữ kiến thức thể giới; (3) OCR và các mẫu nền tảng văn bản để nhận biết văn bản chi tiết; (4) dữ liệu theo hướng dẫn xen kẽ để căn chỉnh đa phương thức ổn định; và (5) các nhiệm vụ nền tảng chung (ví dụ: biểu thức tham chiếu, dự đoán quan hệ không gian) cho nền tảng ngôn ngữ cấp đối tượng. Điều quan trọng là, để hỗ trợ tốt hơn cho lý luận được thể hiện, chúng tôi đã tăng cường một cách chiến lược việc giám sát lấy video làm trung tâm, liên quan đến không gian và nhận thức 3D trong hỗn hợp này. Nói chung, các mục tiêu ngôn ngữ-hình ảnh chung này giảm thiểu tình trạng quên lãng tai hại, duy trì nền tảng kiến thức thể giới tiên nghiệm và nâng cao tính vững chắc trong nhận thức thể hiện do ngôn ngữ điều kiện hóa.

4 Sau đào tạo

Quá trình đào tạo trước T2A và CPT trên quy mô lớn tạo ra **Qwen-VLA-Base**, một mô hình hành động-ngôn ngữ-tầm nhìn tổng quát thể hiện sự khái quát hóa xuyên nhiệm vụ và hiện thân chéo rộng rãi. Mặc dù phạm vi bao phủ rộng này trang bị cho mô hình kiến thức linh hoạt nhưng nó vẫn chưa mang lại độ chính xác cần thiết cho

điều khiển vòng kín đáng tin cậy đối với các nhiệm vụ tiếp theo cụ thể. Để thu hẹp khoảng cách này, chúng tôi giới thiệu quy trình sau đào tạo gồm hai giai đoạn chuyên môn hóa mô hình cơ sở để thực hiện nhiệm vụ chính xác:

(i) Một giai đoạn *tinh chỉnh có giám sát* (SFT) đa nhiệm vụ cùng tinh chỉnh cả xương sống VLM và chuyên gia hành động về các nhiệm vụ không đồng nhất, bao gồm trả lời câu hỏi trực quan, nổi đất không gian, thao tác và điều hướng, theo lấy mẫu cân bằng theo phương án và cân bằng nhiệm vụ. (ii) Giai đoạn *học tăng cường* (RL), được khởi tạo từ điểm kiểm tra SFT, giúp tinh chỉnh thêm chính sách bằng cách tối ưu hóa trực tiếp các phần thưởng dựa trên thành công của nhiệm vụ thu được từ việc triển khai chính sách trong mô phỏng, tạo ra mô hình cuối cùng **Qwen-VLA-Instruct**.

Trên cả hai giai đoạn, chúng tôi sử dụng tốc độ học giảm dần theo cosine với lịch trình theo nhóm riêng biệt cho xương sống ngôn ngữ thị giác và bộ giải mã hành động, cùng với việc cắt giảm độ dốc phù hợp với quá trình đào tạo trước. Số liệu và phương pháp cụ thể cho từng giai đoạn sẽ được trình bày chi tiết ở các phần tiếp theo.

4.1 Tinh chỉnh được giám sát đa tác vụ

Dữ liệu. Hỗn hợp dữ liệu SFT bao gồm ba loại: mẫu ngôn ngữ thị giác chung, các tập điều hướng ngôn ngữ thị giác và các minh họa thao tác robot. Đầu tiên, chúng tôi tuyển chọn một tập hợp các mẫu ngôn ngữ thị giác—bao gồm trả lời câu hỏi bằng hình ảnh, nền tảng không gian và chú thích hành động—để duy trì khả năng hiểu biết trực quan của xương sống trong suốt quá trình tinh chỉnh. Thứ hai, chúng tôi thu thập các minh họa thao tác robot từ mô phỏng, bao gồm quỹ đạo trên một loạt nền tảng bao gồm các robot một cánh tay, hai cánh tay và hình người, tất cả đều sử dụng phạm vi dự đoán gồm 16 bước hành động trên mỗi khối (Cộng đồng, 2026). Theo cùng một thiết kế lời nhắc nhận biết phương án được sử dụng trong quá trình đào tạo trước (Phần 2.3), mỗi mẫu đào tạo đều có trước một lời nhắc bằng văn bản chỉ định nền tảng rô-bốt, cấu hình cánh tay, tần suất điều khiển và phạm vi dự đoán. Thứ ba, chúng tôi thu thập các tập điều hướng bằng ngôn ngữ thị giác từ các môi trường điều khiển liên tục, bao gồm nhiều cảnh trong nhà và phong cách hướng dẫn khác nhau. Chúng tôi chỉ giữ lại các tập đã hoàn thành thành công với phạm vi dự đoán là 8 điểm tham chiếu trên mỗi đoạn.

Mục tiêu. Giai đoạn SFT cùng nhau tối ưu hóa hai tổn thất: dự đoán mã thông báo tiếp theo trên mã thông báo ngôn ngữ tầm nhìn và khớp luồng trên mã thông báo hành động. Trọng số tổn thất được đặt thành 0,1 cho dự đoán mã thông báo tiếp theo bằng ngôn ngữ tầm nhìn và 1,0 cho cả dự đoán hành động thao tác và điều hướng, đảm bảo rằng mô hình vẫn giữ được ngôn ngữ và hiểu biết trực quan trong khi tập trung khả năng chuyển màu vào việc tạo hành động.

4.2 Học tăng cường

SFT dựa trên khả năng tối ưu hóa một đại diện thay thế để đo lường mức độ chính sách *bắt buộc* trình diễn, nhưng đại lượng quan trọng cuối cùng trong kiểm soát thể hiện là *sự thành công của nhiệm vụ vòng kín*: liệu quỹ đạo được thực hiện có đạt được mục tiêu hay không. Hai mục tiêu này có thể khác nhau: một chính sách có thể gán khả năng cao cho các hành động hợp lý nhưng lại thất bại khi kết quả đầu ra của chính nó làm dịch chuyển sự phân bố của nhà nước khỏi hỗ trợ trình diễn. Giai đoạn RL thu hẹp khoảng cách này bằng cách trực tiếp tối ưu hóa phần thưởng dựa trên thành công của nhiệm vụ theo quỹ đạo do chính chính sách đưa ra, tạo ra mô hình cuối cùng. Chúng tôi triển khai giai đoạn này bằng cách sử dụng khung Rlinf (Yu và cộng sự, 2025a).

Mục tiêu tối ưu hóa chính sách. Chúng tôi áp dụng Tối ưu hóa chính sách gần nhất (PPO) (Schulman và cộng sự, 2017) với Ước tính lợi thế tổng quát (GAE) (Schulman và cộng sự, 2015) làm thuật toán RL. Hãy π_θ biểu thị chính sách hiện tại và $\pi_{\theta_{\text{old}}}$ chính sách đã tạo ra đợt triển khai. Mục tiêu thay thế bị cắt bớt là

$$\mathcal{L}^{\text{actor}}(\theta) = -\mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_t \right) \right], \quad (6)$$

trong đó $r_t(\theta) = \pi_\theta(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$ là tầm quan trọng tỷ lệ, với $s_t = (o_t, x, e)$ trạng thái hiện tại (quan sát trực quan, hướng dẫn nhiệm vụ và lời nhắc thực hiện theo Phần 2.3) và a_t đoạn hành động dự đoán của đường chân trời H , $\hat{A}_t$ là ước tính lợi thế GAE với chiết khấu $\gamma=0,99$ và phân rã theo vết $\lambda=0,95$ và $\epsilon=0,2$ là ngưỡng cắt được áp dụng đối xứng. Tổng tổn thất kết hợp đại diện chính sách với thuật ngữ hồi quy hàm giá trị:

$$\mathcal{L}(\theta) = \mathcal{L}^{\text{actor}}(\theta) + c_v \mathcal{L}^{\text{value}}(\theta), \quad (7)$$

trong đó $\mathcal{L}^{\text{value}}$ là sự mất mát về dự đoán giá trị và $c_v=1$. Chúng tôi thực hiện bốn giai đoạn tối ưu hóa cho mỗi đợt triển khai.

Ước tính giá trị. Thay vì đào tạo một mạng lưới phê bình riêng biệt, chúng tôi gán trực tiếp phần đầu giá trị nhẹ vào xương sống ngôn ngữ tầm nhìn. Giá trị trung bình của đầu giá trị gộp tất cả các trạng thái ẩn VLM và ánh xạ chúng tới ước tính giá trị vô hướng thông qua phép chiếu tuyến tính. Chúng tôi áp dụng stop-gradient trên VLM ẩn

trạng thái trước khi chúng nhập vào phần đầu giá trị, do đó độ dốc của hàm giá trị không truyền trở lại qua đường trục được huấn luyện trước. Phần đầu giá trị được huấn luyện với tổn thất MSE bị cắt bớt và tốc độ học riêng biệt (10^{-4} , xấp xỉ $20\times$ tốc độ học của diễn viên là 5×10^{-6}), cho phép nó hội tụ nhanh chóng trong khi các cập nhật chính sách vẫn ở mức thận trọng.

Ước tính xác suất nhậ ký khi khớp luồng. Một thách thức chính khi áp dụng PPO cho bộ giải mã hành động khớp luồng của chúng tôi là tính toán nhậ ký xác suất nhậ ký $\pi_\theta(a_t | s_t)$ cần thiết cho tỷ lệ tầm quan trọng $r_t(\theta)$. Không giống như các chính sách dựa trên mã thông báo tự hồi quy trong đó xác suất nhậ ký có sẵn trực tiếp từ đầu ra softmax, các mô hình khớp luồng xác định mật độ ngầm định thông qua trường vận tốc đã học và khử nhiễu lặp lại. Chúng tôi chuyển đổi ODE luồng xác suất xác định thành SDE tương ứng bằng cách đưa nhiễu có kiểm soát vào mỗi bước khử nhiễu Euler (Song và cộng sự, 2021), để mỗi quá trình chuyển đổi trở thành một Gaussian rõ ràng mà xác suất log có thể được tính toán bằng phương pháp phân tích mà không cần tích hợp ODE số. Trong quá trình triển khai, chúng tôi lưu trữ các trạng thái khử nhiễu trung gian; tại bản cập nhật PPO, chúng tôi đánh giá lại trường vận tốc theo các tham số hiện tại và tính toán lại xác suất nhậ ký Gaussian, mang lại tỷ lệ quan trọng với chi phí bổ sung không đáng kể. Theo mặc định, chúng tôi chọn ngẫu nhiên một bước khử nhiễu cho mỗi lần triển khai để ước tính xác suất ghi nhậ ký, chỉ yêu cầu thêm một lần chuyển tiếp DiT trong quá trình tính toán lại. Cả xác suất nhậ ký và lợi thế đều được tính toán ở cấp độ *khối hành động*: mỗi đoạn của $H=16$ bước hành động nhận được một phần thưởng vô hướng duy nhất và một ước tính lợi thế duy nhất, phù hợp với độ chi tiết theo thời gian của đầu ra của bộ giải mã khớp luồng.

Thiết kế phần thưởng. Chúng tôi sử dụng phần thưởng nhị phân thừa thớt từ trình mô phỏng: $R=1$ nếu đạt được mục tiêu nhiệm vụ ở cuối tập và $R=0$ nếu không. Việc chỉ định tín dụng cho các khối hành động được xử lý bởi GAE (eq. (6)), truyền tín hiệu cấp tập trở lại thông qua đường cơ sở giá trị. Không có mô hình phần thưởng đã học nào được sử dụng; tất cả các tín hiệu đều đến từ ngữ nghĩa hoàn thành nhiệm vụ thực tế của trình mô phỏng.

Cơ sở hạ tầng triển khai. Triển khai theo chính sách được thu thập trong môi trường mô phỏng phản ánh các tiêu chuẩn đánh giá tiếp theo. Chúng tôi áp dụng kiến trúc máy khách-máy chủ tách rời, trong đó máy chủ điểm chuẩn từ xa lưu trữ các môi trường mô phỏng và quá trình đào tạo giao tiếp với nó thông qua giao diện mạng. Sự tách biệt này cho phép khối lượng công việc mô phỏng mở rộng quy mô độc lập với việc tối ưu hóa chính sách chuyên sâu về GPU. Chúng tôi khởi tạo $N=128$ phiên bản môi trường song song được phân bổ trên nhiều bộ tác vụ thao tác với sự phân bổ không đồng nhất tỷ lệ thuận với độ khó của tác vụ. Mỗi lần lặp đào tạo thu thập 8 giai đoạn triển khai, mỗi giai đoạn có 128 bước môi trường, mang lại $N \times \lfloor 128/H \rfloor \times 8 = 128 \times 8 \times 8 = 8.192$ đoạn chuyển tiếp cho mỗi lần lặp (trong đó $H=16$ là độ dài đoạn hành động). Trong quá trình triển khai, các hành động được lấy mẫu từ chính sách với nhiệt độ $\tau=1,0$; tại thời điểm đánh giá, chúng tôi giảm nhiệt độ xuống $\tau=0,6$ để làm sắc nét sự phân bổ hành động. Lờ nhắc phương án được sử dụng trong quá trình triển khai giống hệt với lờ nhắc trong SFT, đảm bảo rằng giai đoạn RL không đưa lại sự thay đổi phân phối trong điều hòa lờ nhắc.

Khái quát hóa ngoài miền. Vì lờ nhắc phương án là giao diện duy nhất dành riêng cho nền tảng nên chính sách do RL tinh chỉnh sẽ chuyển sang các môi trường, nhiệm vụ và phương án ngoài miền mà không cần đầu thích ứng bổ sung hoặc tinh chỉnh theo miền cụ thể. Khi triển khai, chúng tôi chỉ cần thay thế lờ nhắc phương án bằng mô tả bằng văn bản về nền tảng robot vật lý, bao gồm cấu hình cánh tay, tần số điều khiển và không gian hành động, trong khi vẫn giữ nguyên khung VLM và bộ giải mã hành động DiT. Khả năng tổng quát hóa không bản này được kích hoạt bởi hai thuộc tính trong công thức đào tạo của chúng tôi: (1) giai đoạn CPT đã đưa mô hình tiếp xúc với cả phân phối hình ảnh mô phỏng và thể giới thực (Phần 3.1), do đó, các biểu diễn trực quan của xương sống không dành riêng cho trình kết xuất mô phỏng; và (2) giai đoạn RL tối ưu hóa các số liệu về thành công của nhiệm vụ bất biến đối với miền trực quan, khuyến khích chính sách dựa vào các đặc điểm hình ảnh có ý nghĩa về mặt ngữ nghĩa thay vì kết cấu dành riêng cho trình kết xuất. Chúng tôi định lượng tác động tích lũy của từng giai đoạn sau đào tạo trong Phần 5.2.3.

5 thí nghiệm

Chúng tôi tiến hành các thử nghiệm sâu rộng để đánh giá hiệu suất của Qwen-VLA trong cả cài đặt mô phỏng và thể giới thực, bao gồm hai lĩnh vực AI cốt lõi: thao tác robot và điều hướng trực quan. Chúng tôi đánh giá hai biến thể mô hình xuyên suốt: **Qwen-VLA-Base**, được huấn luyện trước trên quy mô lớn về dữ liệu được thể hiện đa dạng và

Qwen-VLA-Instruct, được tinh chỉnh thêm bằng dữ liệu tuân theo hướng dẫn được thu thập qua các tác vụ và môi trường mô phỏng đa dạng, có khả năng thực hiện thao tác và điều hướng chi tiết với độ chính xác và độ tin cậy cao hơn trong một mô hình thống nhất.

5.1 Kết quả chính

5.1.1 Kết quả thao tác trong mô phỏng

Để đánh giá toàn diện khả năng thao tác của Qwen-VLA, chúng tôi đánh giá bốn môi trường mô phỏng bao gồm cài đặt một cánh tay và hai cánh tay: LIBERO (Liu và cộng sự, 2023), Simplifier (Li và cộng sự, 2024), RoboCasa-GR1 Tabletop Tasks (Nasiriany và cộng sự, 2024) và RoboTwin 2.0 (Mu và cộng sự, 2024).

- **LIBERO** là điểm chuẩn để bàn một tay bao gồm các nhiệm vụ đa dạng qua bốn phần: Libero-Spatial, Libero-Object, Libero-Goal và Libero-Long.
- **Simplifier-WidowX** là bộ đánh giá mô phỏng thực tế bằng cách sử dụng cánh tay robot WidowX.
- **RoboCasa-GR1** là một chuẩn mực hình người hai tay với 24 nhiệm vụ nhà bếp nguyên tử.
- **RoboTwin 2.0** là điểm chuẩn hai cánh tay với 50 nhiệm vụ hai tay được chia thành các cấp độ khó Dễ và Khó.

Cùng với nhau, những điểm chuẩn này kiểm tra một loạt các kỹ năng thao tác từ việc chọn và đặt trên bàn cho đến các công việc nhà bếp bằng tay có chiều dài lớn. Đối với tất cả các điểm chuẩn, chúng tôi đặt độ dài đoạn hành động $H = 16$ và báo cáo tỷ lệ thành công trung bình theo giao thức đánh giá tiêu chuẩn trong StarVLA (Cộng đồng, 2026).

Bảng 4: **Kết quả thao tác robot trên các điểm chuẩn: chuyên gia so với một nhà tổng quát duy nhất.** Các mô hình chuyên gia được tinh chỉnh riêng biệt trên từng điểm chuẩn, trong khi nhà tổng quát của chúng tôi (Qwen-VLA) được đào tạo chung một lần trên tất cả các phương án và được đánh giá trên tất cả các nền tảng mà không cần điều chỉnh theo điểm chuẩn. **In đậm:** tốt nhất; gạch chân: tốt thứ hai.

Method	Type	Benchmark				
		LIBERO	RoboCasa-GR1	Simplifier-WidowX	RoboTwin-Easy	RoboTwin-Hard
π_0 (Black et al., 2024)	Specialist	94.4	–	–	65.9	58.4
StarVLA-OFT (Community, 2026)		96.6	48.8	64.6	50.4	–
GR00T N1.6 (NVIDIA et al., 2025)		97.2	49.9	63.2	47.6	–
$\pi_{0.5}$ (Black et al., 2025)		97.6	37.0	46.9	82.7	76.8
ABot-M0 (Yang et al., 2026)		98.6	58.3	–	<u>86.0</u>	<u>85.0</u>
Being-H0.5 (Luo et al., 2026)		97.6	53.3	–	–	–
Qwen-VLA-Base	Generalist	90.8	40.4	64.3	64.3	66.4
Qwen-VLA-Instruct		<u>97.9</u>	<u>56.7</u>	73.7	86.1	87.2


Bảng 4 so sánh mô hình tổng quát của chúng tôi với các chính sách chuyên môn hiện đại. Các mô hình chuyên biệt được tinh chỉnh riêng biệt trên từng điểm chuẩn và vẫn dành riêng cho từng phương án, trong khi chuyên gia tổng quát duy nhất của chúng tôi được đào tạo chung về dữ liệu đa dạng, quy mô lớn trải rộng trên nhiều cảnh và phương án, cho phép triển khai trên cả bốn nền tảng chỉ thông qua lời nhắc nhận biết phương án.

Một chuyên gia tổng quát duy nhất hoạt động tốt hơn hầu hết các chuyên gia. Mặc dù là mô hình tất cả trong một, Qwen-VLA-Instruct vượt qua phần lớn các tiêu chuẩn cơ bản của chuyên gia. Trên LIBERO, nó đạt được 97,9%, ngang bằng với các chuyên gia giỏi nhất. Trên RoboCasa-GR1 đạt 56,7%, vượt trội $\pi_{0.5}$ (37,0%), GR00T N1.6 (49,9%) và Being-H0.5 (53,3%). Trên Simplifier-WidowX, nó đạt 73,7%, vượt qua mức cơ bản của chuyên gia bao gồm StarVLA-OFT (64,6%). Trên RoboTwin-Easy/Hard, nó đạt điểm 86,1%/87,2%, **vượt** chuyên gia giỏi nhất trước đó là ABot-M0 (86,0%/85,0%). Những kết quả này xác nhận rằng việc đào tạo chung theo nhiều phương án không ảnh hưởng đến hiệu suất của một nhiệm vụ cụ thể; trong một số điểm chuẩn, mô hình tổng quát thậm chí còn vượt trội hơn các mô hình chuyên dụng.

Đào tạo trước cung cấp nền tảng vững chắc và việc điều chỉnh hướng dẫn mang lại lợi ích đáng kể. Qwen-VLA-Base đã đạt được hiệu suất hợp lý (ví dụ: 90,8% trên LIBERO, 64,3% trên Simplifier-WidowX), cho thấy rằng việc đào tạo trước trên quy mô lớn học các nguyên tắc thao tác có thể chuyển nhượng được qua các phương án. Với việc điều chỉnh hướng dẫn, Qwen-VLA-Instruct cải thiện nhất quán trên tất cả các điểm chuẩn (+7,1% trên LIBERO, +16,3% trên RoboCasa-GR1, +9,4% trên Simplifier-WidowX, +21,8% trên RoboTwin-Easy, +20,8% trên RoboTwin-Hard), xác nhận rằng mức độ căn chỉnh cụ thể theo nhiệm vụ ở mức khiêm tốn là đủ để chuyển đổi các biểu diễn chung đã được huấn luyện trước thành các chính sách chính xác, có thể triển khai.

5.1.2 Kết quả thao tác trong thế giới thực

Chúng tôi thu thập tập dữ liệu trong thế giới thực về ALOHA, một phiên bản robot hai tay tiêu biểu. Nền tảng bao gồm hai cánh tay robot 6-DoF được trang bị bộ kẹp hàm song song, tạo thành một hệ thống thao tác hai tay. Nó được trang bị ba camera RGB, bao gồm hai camera gắn trên cổ tay và một camera góc nhìn thứ nhất. Không giống như Qwen-VLA-Instruct, được tinh chỉnh trên mô phỏng



Hình 4: Tổng quan về các nhiệm vụ đánh giá thực tế trên nền tảng hai tay ALOHA.

môi trường, chúng tôi xác nhận thêm Qwen-VLA về các tác vụ trong thế giới thực bằng cách tinh chỉnh các bản trình diễn được thu thập thông qua ALOHA trên nhiều tác vụ. Chúng tôi chuẩn bị hai biến thể có chung kiến trúc: Qwen-VLA-aloha_{w/o} pretrain được đào tạo từ đầu và Qwen-VLA-aloha_{w/} pretrain được tinh chỉnh từ Qwen-VLA-Base, để đánh giá khả năng chuyển đổi của quá trình đào tạo trước được thể hiện ở quy mô lớn sang cài đặt trong thế giới thực.

Chúng tôi đánh giá mô hình trên một loạt các nhiệm vụ thao túng trong thế giới thực, bao gồm cả các kịch bản trong miền và ngoài phân phối (OOD). Đánh giá trong miền bao gồm sáu loại nhiệm vụ: chọn và đặt, lau bàn, xếp bát, nhặt bát và đặt đồ vật, gấp khăn, thao tác chi tiết. Đánh giá OOD kiểm tra thêm khả năng khái quát hóa đối với các màu sắc, trường hợp, vị trí, nền, hướng dẫn ngôn ngữ không nhìn thấy được.

Nhiệm vụ trong miền. Đánh giá trong miền bao gồm sáu loại nhiệm vụ có độ phức tạp tăng dần:

- **Nhiệm vụ 1: Chọn và đặt.** Robot nhặt các đồ vật cơ bản, bao gồm khối và bút rồi đặt chúng vào các vị trí mục tiêu được chỉ định.
- **Nhiệm vụ 2: Dọn dẹp bàn.** Robot dọn dẹp các đồ vật trên bàn và đặt chúng vào thùng chứa mục tiêu.
- **Nhiệm vụ 3: Xếp bát.** Robot xếp bát theo thứ tự màu sắc được chỉ định bởi hướng dẫn ngôn ngữ.
- **Nhiệm vụ 4: Chọn & Đặt Bát.** Robot nhặt một chiếc bát và đặt các đồ vật mục tiêu vào đó theo hướng dẫn ngôn ngữ.
- **Nhiệm vụ 5: Gấp khăn.** Robot gấp khăn trên bàn, kiểm tra khả năng điều khiển các vật thể biến dạng.
- **Nhiệm vụ 6: Thao tác chi tiết.** Hạng mục này bao gồm một số nhiệm vụ thao tác chính xác, chẳng hạn như mở ngăn kéo để đặt một đồ vật vào bên trong rồi đóng lại, nhét một đồ vật vào một khe và xếp chồng hai khối.

Nhiệm vụ OOD. Đánh giá OOD bao gồm năm cài đặt đánh giá các loại khái quát hóa khác nhau:

- **Tổng quát hóa màu sắc.** Cài đặt này đánh giá khả năng khái quát hóa màu sắc trong Nhiệm vụ 1 và Nhiệm vụ 4, trong đó rô-bốt cần xử lý các thông số màu không nhìn thấy được, chẳng hạn như nhắc một cái bát có màu xác định (không nhìn thấy) và đặt một vật thể vào đó hoặc đặt bút có màu xác định (không nhìn thấy) vào thùng chứa mục tiêu.
- **Tổng quát hóa phiên bản.** Cài đặt này đánh giá tổng quát hóa phiên bản trong Nhiệm vụ 1 và Nhiệm vụ 2, trong đó robot gấp các vật thể mới, chẳng hạn như nho (không nhìn thấy) và một quả chanh (không nhìn thấy) trong khi dọn bàn,

hoặc một khối màu đỏ (không nhìn thấy) trong quá trình đặt đối tượng.

- **Tổng quát hóa vị trí.** Cài đặt này đánh giá khái quát hóa vị trí trong Nhiệm vụ 3 và Nhiệm vụ 4, trong đó các cái bát và đối tượng mục tiêu xuất hiện ở cấu hình không gian (không nhìn thấy).
- **Tổng quát hóa nền.** Cài đặt này đánh giá khái quát về nền và ánh sáng trong Nhiệm vụ 2 và Nhiệm vụ 3, bao gồm các điều kiện ánh sáng (không nhìn thấy) để xếp bát và nền xanh (không nhìn thấy) để dọn bàn.
- **Tổng quát hóa lệnh.** Cài đặt này đánh giá tổng quát hóa lệnh trong Nhiệm vụ 3 và Nhiệm vụ 6, trong đó robot được yêu cầu thực hiện các hành động khác nhau theo hướng dẫn ngôn ngữ nhất định. Ví dụ bao gồm xếp các bát theo một thứ tự cụ thể (không nhìn thấy) hoặc xếp các khối theo quan hệ màu sắc, ví dụ: đặt khối màu xanh lá cây (không nhìn thấy) trên khối màu tím (không nhìn thấy).

Bảng 5: Hiệu suất trong miền trên các danh mục nhiệm vụ ngắn hạn và dài hạn.

Qwen-VLA-aloha_{w/o} pretrain và Qwen-VLA-aloha_{w/} pretrain có chung kiến trúc mô hình Qwen-VLA; cái trước được đào tạo từ đầu và cái sau được tinh chỉnh từ Qwen-VLA-Base.

Model	Short-horizon Tasks			Long-horizon Tasks			Avg.
	Pick and Place	Table Cleaning	Bowl Stacking	Bowl Pick & Place	Towel Folding	Fine-grained Manipulation	
GR00T N1.6 (NVIDIA et al., 2025)	30.8	38.5	53.8	19.2	19.2	10.3	28.6
$\pi_{0.5}$ (Black et al., 2025)	73.1	84.6	88.5	69.2	80.8	33.3	71.6
Qwen-VLA-aloha _{w/o} pretrain	30.8	53.8	61.5	64.1	50.0	30.8	48.5
Qwen-VLA-aloha _{w/} pretrain	96.2	92.3	98.7	87.2	65.4	61.5	83.6

Kết quả của các nhiệm vụ trong miền. Bảng 5 tóm tắt các kết quả trong miền. Qwen-VLA-aloha_{w/} pretrain đạt tỷ lệ thành công trung bình tốt nhất là 83,6%, vượt trội so với các mức cơ sở mạnh mẽ bao gồm GR00T N1.6 (NVIDIA và cộng sự, 2025) và $\pi_{0.5}$ (Black và cộng sự, 2025) trên hầu hết các hạng mục nhiệm vụ. Lợi ích của việc huấn luyện trước trên quy mô lớn được thể hiện rõ khi so sánh với Qwen-VLA-aloha_{w/o} pretrain: tinh chỉnh từ Qwen-VLA-Base tăng tỷ lệ thành công trung bình từ 48,5% lên 83,6%, với mức tăng đặc biệt lớn về Chọn và Đặt, Dọn bàn, Xếp bát, Chọn & Đặt bát và Thao tác chi tiết. Những kết quả này xác nhận rằng việc đào tạo trước cung cấp nền tảng vững chắc cho thao tác trong thế giới thực nhằm chuyển giao hiệu quả các tác vụ đa dạng trong miền.

Kết quả của các nhiệm vụ OOD. Bảng 6 báo cáo hiệu suất khái quát hóa OOD. Qwen-VLA-aloha_{w/} pretrain luôn đạt được kết quả tốt nhất trên tất cả năm cài đặt khái quát hóa, bao gồm màu sắc, thể hiện, vị trí, nền và khái quát hóa hướng dẫn. Tỷ lệ thành công OOD trung bình của nó đạt 76,9%, vượt trội đáng kể $\pi_{0.5}$ (Black và cộng sự, 2025) 35,4 điểm phần trăm và Qwen-VLA-aloha_{w/o} pretrain 40,7 điểm phần trăm. Sự cải thiện đặc biệt có ý nghĩa trong việc khái quát hóa nền tảng và hướng dẫn, trong đó Qwen-VLA-aloha_{w/} pretrain lần lượt đạt được 80,8% và 84,6%. Những kết quả này cho thấy rằng việc đào tạo trước không chỉ cải thiện hiệu suất trong miền mà còn cung cấp độ tin cậy mạnh mẽ hơn cho các điều kiện thị giác không thể nhìn thấy, phiên bản đối tượng, vị trí và các biến thể hướng dẫn.

Phân tích tổng thể. Nhìn chung, kết quả chứng minh rằng việc đào tạo trước đóng một vai trò quan trọng trong việc học thao tác trong thế giới thực. Trong khi Qwen-VLA-aloha_{w/o} pretrain và Qwen-VLA-aloha_{w/} pretrain có cùng kiến trúc, việc đào tạo từ đầu sẽ dẫn đến hiệu suất thấp hơn nhiều, đặc biệt là trong cài đặt OOD. Sự so sánh này chỉ ra rằng hiệu suất đạt được không chỉ đơn giản đến từ kiến trúc mô hình mà chủ yếu đến từ mô hình Qwen-VLA-Base đã được huấn luyện trước. Hơn nữa, hiệu suất OOD mạnh mẽ của Qwen-VLA-aloha_{w/} pretrain cho thấy rằng các biểu diễn tầm nhìn-ngôn ngữ-hành động được huấn luyện trước có thể hỗ trợ hiệu quả việc khái quát hóa trên cả các biến thể trực quan và biến thể hướng dẫn.

5.1.3 Kết quả điều hướng

Chúng tôi đánh giá khả năng điều hướng của Qwen-VLA về điều hướng tầm nhìn và ngôn ngữ trong môi trường liên tục (VLN-CE (Krantz và cộng sự, 2020; Ku và cộng sự, 2020)). Cụ thể, chúng tôi kiểm tra các phiên bản Qwen-VLA Base và Instruct trên phần phân chia Val-Unseen của điểm chuẩn R2R và RxR, đồng thời so sánh chúng với các đường cơ sở nguồn mở. Chúng tôi sử dụng cài đặt mặc định của VLN-CE và đặc biệt là triển khai sliding-window hành động điểm tham chiếu tương thích với quỹ đạo dự đoán của Qwen-VLA.

Như được hiển thị trong Bảng 7, Qwen-VLA-Instruct đạt được hiệu suất tốt nhất trên hầu hết các số liệu trên cả điểm chuẩn R2R và RxR. Trên R2R Val-Unseen, nó đạt Tỷ lệ thành công cao nhất của Oracle (69,0) và Tỷ lệ thành công (57,5), vượt qua StreamVLN lần lượt là 4,8 và 0,6 điểm, đồng thời duy trì SPL cạnh tranh. Ở phần phân chia RxR Val-Unseen đầy thử thách hơn, Qwen-VLA-Instruct dẫn đầu về cả SR (59,6) và SPL (47,8), vượt trội so với tất cả các đường cơ sở với một mức chênh lệch đáng chú ý. Đào tạo chung về dữ liệu VLA và VLN duy trì hiệu suất hợp lý trên cả hai điểm chuẩn.

Bảng 6: **Hiệu suất OOD trên các danh mục khái quát hóa.** Qwen-VLA-aloha_{w/o} pretrain và Qwen-VLA-aloha_{w/} pretrain có chung kiến trúc mô hình Qwen-VLA; cái trước được huấn luyện từ đầu và cái sau được tinh chỉnh từ Qwen-VLA-Base đã được huấn luyện trước.

Model	Color	Instance	Position	Background	Instruction	Avg.
GR00T N1.6 (NVIDIA et al., 2025)	46.2	38.5	3.8	19.2	19.2	25.4
$\pi_{0.5}$ (Black et al., 2025)	57.7	61.5	19.2	26.9	42.3	41.5
Qwen-VLA-aloha _{w/o} pretrain	42.3	30.8	34.6	30.8	42.3	36.2
Qwen-VLA-aloha _{w/} pretrain	88.5	76.9	53.8	80.8	84.6	76.9

Bảng 7: **So sánh với các đường cơ sở nguồn mở trên VLN-CE.** Chúng tôi so sánh các phiên bản Qwen-VLA Base và Instruct với các đường cơ sở nguồn mở được đánh giá rộng rãi trên phân chia Val-Unseen của các điểm chuẩn R2R và RxR. **Bold:** tốt nhất; gạch chân: tốt thứ hai.

Method	R2R Val-Unseen				RxR Val-Unseen			
	NE↓	OS↑	SR↑	SPL↑	NE↓	SR↑	SPL↑	nDTW↑
NaVid (Zhang và cộng sự, 2024)	5.7	49.2	41.9	36.5	5.7	45.7	38.2	–
Uni-NaVid (Zhang và cộng sự, 2025b)	5.6	53.3	47.0	42.7	6.2	48.7	40.9	–
NaVILA (Cheng và cộng sự, 2025)	5.2	62.5	54.0	49.0	6.8	49.3	44.0	<u>58.8</u>
StreamVLN (Wei và cộng sự, 2025)	5.0	<u>64.2</u>	<u>56.9</u>	51.9	6.2	52.9	<u>46.0</u>	61.9
Qwen-VLA-Base	5.2	61.7	53.8	49.4	6.4	<u>55.1</u>	45.8	56.2
Qwen-VLA-Instruct	<u>5.1</u>	69.0	57.5	<u>51.2</u>	<u>5.8</u>	59.6	47.8	57.1

5.1.4 Đánh giá ngoài phân phối về thao tác tĩnh

Để kiểm tra xem liệu các ưu tiên đào tạo trước có khái quát hóa ngoài phân phối tinh chỉnh hay không, chúng tôi xây dựng một điểm chuẩn OOD được kiểm soát trong đó việc tinh chỉnh chỉ bao gồm việc chọn và đặt đơn giản nhưng việc đánh giá yêu cầu các loại nhiệm vụ không thể nhìn thấy. Chúng tôi phát triển SimplEnv-OOD, một bộ gồm 6 tác vụ không được phân phối trải dài trên 3 cảnh trên bàn được xây dựng dựa trên khung SimplEnv với cánh tay robot WidowX. Tất cả các mô hình chỉ được tinh chỉnh trong phân đào tạo Bridge, chỉ bao gồm các phần trình diễn chọn và đặt đơn giản với các cặp đối tượng cố định. Không có hướng dẫn nhiệm vụ OOD, quan hệ không gian hoặc thao tác nguyên thủy nào xuất hiện trong dữ liệu huấn luyện. Sáu nhiệm vụ đó là:

- **Di chuyển đi:** Di chuyển thìa ra xa miếng vải sao cho khoảng cách cuối cùng vượt quá khoảng cách ban đầu. Bài kiểm tra này *khái quát hóa vị trí* thông qua việc sắp xếp vị trí tăng khoảng cách.
- **MoveRight:** Di chuyển thìa sang bên phải của tấm vải. Điều này kiểm tra *khái quát hóa vị trí* thông qua vị trí có hướng với các ràng buộc trực tiếp giao.
- **Đặt Gần:** Di chuyển củ cà rốt đến vị trí liền kề nhưng không ở phía trên đĩa. Điều này kiểm tra *khái quát hóa vị trí* thông qua vị trí dựa trên vùng lân cận.
- **PlaceRight:** Đặt thìa lên nửa bên phải của tấm vải. Điều này kiểm tra *khái quát hóa vị trí* với vị trí bị giới hạn theo vùng, yêu cầu chính sách diễn giải thông số xác định tiểu vùng (“nửa bên phải”) và đạt được cả khả năng tiếp xúc mục tiêu chính xác và độ chính xác về không gian trong khu vực được chỉ định.
- **PutFront:** Đặt củ cà rốt trước đĩa. Điều này kiểm tra *khái quát hóa vị trí* dọc theo trục định hướng trước/sau.
- **Xếp chồng màu vàng:** Nhặt khối màu vàng và xếp nó lên khối màu xanh lá cây. Dữ liệu huấn luyện chỉ chứa xếp chồng màu xanh lá cây trên màu vàng; thứ tự đảo ngược này kiểm tra *khả năng khái quát hóa trực quan* bằng cách yêu cầu lý luận và khái quát hóa dựa trên màu sắc đối với các ràng buộc màu sắc đối tượng mới chưa từng thấy trong quá trình huấn luyện.

Như được hiển thị trong Bảng 8, Qwen-VLA-Instruct đạt tỷ lệ thành công trung bình cao nhất **32,0%**, vượt trội đáng kể $\pi_{0.5}$ (12,6%) trong hầu hết các nhiệm vụ. Ưu điểm mạnh nhất về khái quát hóa vị trí: $\pi_{0.5}$ thất bại hoàn toàn trên MoveRight và PlaceNear, trong khi Qwen-VLA-Instruct lần lượt đạt 33,3% và 39,6%. Mức tăng nhất quán cũng xuất hiện trên MoveAway (43,8% so với 26,1%) và PlaceRight (47,9% so với 32,1%), cho thấy khả năng khái quát hóa mạnh mẽ hơn đối với các hướng dẫn không gian không nhìn thấy được. Trên StackYellow (22,9% so với 4,2%), trong đó dữ liệu huấn luyện chỉ chứa xếp chồng màu xanh lá cây trên màu vàng nhưng tác vụ yêu cầu thứ tự đảo ngược, Qwen-VLA-Instruct thể hiện khả năng khái quát hóa mạnh mẽ hơn đối với các ràng buộc đối tượng màu mới.

5.1.5 Đánh giá ngoài phân phối về Thao tác động

Việc triển khai robot trong môi trường phức tạp đòi hỏi phải thành thạo thao tác động và cần phải thích ứng với chuyển động của vật thể độc lập (Liang và cộng sự, 2026). Để đánh giá một cách có hệ thống điều quan trọng này

Bảng 8: Kết quả khái quát hóa OOD trên SimplerEnv-OOD. In đậm: tốt nhất; gạch chân: tốt thứ hai.

Method	OOD Task						Avg.
	MoveAway	MoveRight	PlaceNear	PlaceRight	PutFront	StackYellow	
$\pi_{0,5}$ (Đen và cộng sự, 2025)	26.1	0.0	0.0	32.1	13.0	4.2	12.6
Qwen-VLA-Base	<u>31.3</u>	<u>31.6</u>	<u>16.7</u>	<u>47.1</u>	<u>6.3</u>	<u>18.8</u>	<u>25.3</u>
Qwen-VLA-Instruct	43.8	33.3	39.6	47.9	4.2	22.9	32.0

Bảng 9: So sánh với các phương pháp tiên tiến trên DOMINO. In đậm: tốt nhất; gạch chân: tốt thứ hai.


Phương pháp	SR (%)↑	MS↑
<i>Tinh chỉnh trên dữ liệu thao tác động</i>		
OpenVLA (Kim et al., 2024)	1.5	6.1
RDT-1B (Liu et al., 2025b)	5.3	17.7
π_0 (Black et al., 2024)	8.2	24.0
$\pi_{0,5}$ (Black et al., 2025)	9.6	26.2
InternVLA-M1 (Chen et al., 2025b)	5.4	27.6
VLA-Adapter (Wang et al., 2026)	4.4	24.3
π_0 -FAST (Pertsch et al., 2025)	3.5	20.9
OpenVLA-OFT (Kim et al., 2025)	9.1	24.1
StarVLA-OFT (Community, 2026)	10.9	30.5
PUMA (Fang et al., 2026)	17.2	35.0
<i>Không bắt đến thao tác động</i>		
OpenVLA-OFT (Kim et al., 2025)	6.7	20.0
$\pi_{0,5}$ (Black et al., 2025)	7.5	20.4
LingBot-VLA w/ depth (Wu et al., 2026)	11.8	26.7
LingBot-VA (Li et al., 2026a)	<u>24.1</u>	36.1
Qwen-VLA-Base	21.1	<u>37.4</u>
Qwen-VLA-Instruct	26.6	39.5

năng lực, tiêu chuẩn DOMINO được giới thiệu gần đây (Fang và cộng sự, 2026) đi tiên phong trong mô hình đánh giá toàn diện. Nó giới thiệu một cách sáng tạo thiết kế chuyển động có thứ bậc và Điểm thao tác liên tục để nắm bắt chất lượng thực thi trong những hạn chế không thể đoán trước. Những tính năng độc đáo này làm cho DOMINO trở thành một bài kiểm tra căng thẳng đặc biệt để xác định xem liệu mô hình hành động ngôn ngữ thị giác có sở hữu khả năng lập bản đồ không gian-động học có thể khái quát hóa hay không thay vì chỉ thực hiện các quy trình tĩnh được ghi nhớ. Chúng tôi đã đánh giá Qwen-VLA ở cài đặt không bắt trên tất cả 35 bộ DOMINO và báo cáo Tỷ lệ thành công (SR) cùng với Điểm thao tác (MS).

Như được hiển thị trong Bảng 9, Qwen-VLA thiết lập hiệu suất tổng thể tốt nhất trên điểm chuẩn DOMINO. Qwen-VLA-Instruct đạt SR cao nhất (26,6%) và MS (39,5). Trong danh mục không bắt, mô hình của chúng tôi thể hiện lợi thế đáng kể so với các kiến trúc hành động-ngôn ngữ-tầm nhìn tiêu chuẩn bằng cách vượt qua cả OpenVLA-OFT (Kim và cộng sự, 2025) và $\pi_{0,5}$ (Black và cộng sự, 2025) hơn 19 điểm phần trăm trong SR. Hơn nữa, nó vượt trội hơn phương pháp LingBot-VA kiểu WAM tiêu biểu (Li và cộng sự, 2026a) đồng thời thể hiện chất lượng thực thi liên tục mạnh mẽ hơn dưới động lực học của đối tượng chuyển động. Điều quan trọng là Qwen-VLA vượt trội hơn toàn bộ bộ đường cơ sở được tinh chỉnh rõ ràng cho thao tác động. Ví dụ: phương pháp nâng cao PUMA (Fang và cộng sự, 2026) dựa vào các đầu vào chuyển động thời gian và tinh chỉnh dành riêng cho DOMINO để duy trì nhận thức động. Mặc dù thiếu những khả năng thích ứng phù hợp này và chỉ dựa vào quan sát khung hình hiện tại, Qwen-VLA-Instruct vẫn vượt qua PUMA 9,4 điểm phần trăm trong SR và 4,5 điểm trong MS. Mô hình của chúng tôi đạt được những mức tăng ấn tượng này khi suy luận chỉ bằng cách sử dụng các quan sát khung hình hiện tại mà không cần bất kỳ tinh chỉnh thao tác động nào. Kết quả này nêu bật lợi thế của chiến lược huấn luyện trước hành động và quỹ đạo thống nhất của chúng tôi trong việc học các ưu tiên từ không gian sang động học có thể chuyển đổi.

Chúng tôi cho rằng sự khái quát hóa ngoài phạm vi phân phối này là do sự kết hợp giữa việc tạo ra hành động quyết định và đào tạo trước trên phạm vi rộng. Bộ giải mã hành động khớp luồng tạo ra các khối hành động mạch lạc. Cơ chế này làm giảm sự do dự và giúp chính sách hành động chính xác trong khoảng thời gian hẹp. Ngoài ra, việc đào tạo trước chung trên quy mô lớn về thao tác, điều hướng, dự đoán quỹ đạo và dữ liệu ngôn ngữ thị giác cung cấp các thông tin ưu tiên có thể chuyển đổi về nền tảng trực quan, lý luận không gian và kiểm soát liên tục. Những ưu tiên mạnh mẽ này cho phép Qwen-VLA khái quát hóa một cách hiệu quả thao tác đối tượng chuyển động mặc dù hoàn toàn không có dữ liệu huấn luyện động.

5.1.6 Khái quát hóa ngoài phân phối trong thế giới thực




Hình 5: **Khái quát định tính ngoài phân phối của Qwen-VLA-Base trên robot hai tay ALOHA.** Trên cùng bên trái: khả năng cầm nắm có điều kiện về màu sắc của các quả bóng xanh lục, xanh lam, đỏ và vàng. Trên cùng bên phải: hai bảng phía trên hiển thị khả năng cầm nắm các đồ vật mới (bông cải xanh, vịt đồ chơi); hai bảng phía dưới hiển thị nhiệm vụ “dọn bàn” tổng hợp với việc nhặt và đặt tuần tự vào thùng (ô màu xanh, vịt đồ chơi, sữa chua đóng chai). Dưới cùng bên trái: tương tác với các vật thể hoàn toàn không nhìn thấy (kính râm, búp bê sang trọng, vịt đồ chơi). Dưới cùng bên phải: chuyển tác động nguyên tử thông qua việc mở nắp bút và đặt nắp, từ nền chắc chắn đến màu vàng không nhìn thấy được.

Để kiểm tra định tính quá trình đào tạo trước liên tục, chúng tôi đánh giá **Qwen-VLA-Base** trên robot hai cánh tay ALOHA theo bốn cài đặt ngoài phân phối: nền màu, thao tác đối tượng mới, nhận dạng đối tượng không nhìn thấy và độ ổn định của nền. Triển khai đại diện được hiển thị trong Hình 5.

Nối đất màu (trên cùng bên trái). Chúng tôi kiểm tra xem Qwen-VLA-Base có thể phân biệt giữa các vật thể trông giống nhau chỉ khác nhau về màu sắc hay không. Qua bốn lần thử nghiệm, rô-bốt được nhắc nhở bằng cách “nhắm quả bóng {color}” tương ứng với các màu xanh lá cây, xanh lam, đỏ và vàng. Trong mọi trường hợp, mô hình xác định chính xác màu mục tiêu và tạo ra quỹ đạo tiếp cận và nắm bắt chính xác, biểu thị nền tảng ngữ nghĩa có điều kiện về màu sắc sau khi liên tục được đào tạo trước.

Nắm bắt đối tượng mới lạ và làm sạch thành phần (trên cùng bên phải). Tiếp theo, chúng tôi kiểm tra xem liệu mô hình có thể *zero-shot* nắm bắt các đối tượng chưa từng thấy trong dữ liệu huấn luyện trước thao tác hay không. Hai bảng trên cùng cho thấy khả năng nắm bắt thành công được nhắc nhở bởi “nhắm lấy {vật thể}” đối với bông cải xanh màu xanh lá cây và một con vịt đồ chơi, cả hai đều không có trong bộ huấn luyện thao tác. Mô hình đã định vị và nắm bắt thành công bông cải xanh; đối với con vịt đồ chơi, nó xác định chính xác vật thể và vươn về phía nó, mặc dù hình dạng không đều ngăn cản khả năng cầm nắm ổn định. Hai bảng dưới cùng thể hiện thêm một nhiệm vụ tổng hợp được nhắc nhở bằng cách “dọn bàn”, trong đó rô-bốt lần lượt nhặt một chiếc ô màu xanh, một con vịt đồ chơi và một hộp sữa chua đóng chai rồi đặt chúng vào thùng. Cả ba đều là những đồ vật hàng ngày không có trong bộ thao tác. Qwen-VLA-Base xóa tất cả các đối tượng theo trình tự, hiển thị nhận dạng trực quan không cần chụp đối tượng mới và lập kế hoạch lại sau mỗi chu kỳ chọn và đặt. Hành vi này phù hợp với thiết lập đào tạo hỗn hợp VL-VLA-VLN: dữ liệu ngôn ngữ hình ảnh hiển thị mô hình với vốn từ vựng đối tượng rộng hơn, có thể chuyển sang thao tác ngay cả khi không có minh họa trong miền.

Tương tác với vật thể không nhìn thấy (dưới cùng bên trái). Chúng tôi tiếp tục thăm dò khái quát hóa không bản bằng cách đưa ra hướng dẫn “tiếp cận {đối tượng}” cho các danh mục đối tượng hoàn toàn không có trong quá trình huấn luyện trước: kính râm, búp bê sang trọng và một con vịt đồ chơi. Đáng chú ý, bản thân hành động “tiếp cận” hầu như không bao giờ có trong dữ liệu thao tác của chúng tôi, tuy nhiên mô hình diễn giải chính xác hướng dẫn và điều hướng bộ phận tác động cuối đến từng đối tượng mục tiêu. Đối với con vịt đồ chơi, người mẫu thậm chí còn thành công trong việc nắm được nó bằng đầu. Đối với kính râm, mẫu



Hình 6: Cấu trúc trước khi huấn luyện T2A. **(a) Thành phần dữ liệu và chế độ dự đoán.** Tỷ lệ thành công SFT (%) so với tỷ lệ dữ liệu tổng hợp trong kho văn bản T2A. Đường đứt nét đánh dấu đường cơ sở không có T2A (60,9%). Dự đoán toàn chuỗi với ~20% tổng hợp + 80% dữ liệu thực đạt kết quả tốt nhất (71,1%, +10,2 pp khi không có T2A). Dự đoán khối luôn hoạt động kém hơn chuỗi đầy đủ (ví dụ: +4,9 trang ở mức tổng hợp 10%) và việc bao gồm mã thông báo hình ảnh trong T2A càng làm tổn hại đến hiệu suất ở chế độ khối (−2,9 trang), xác nhận rằng hình ảnh phải bị chặn hoàn toàn ở T2A. **(b) Phân phối dấu thời gian khớp với luồng.** Sự kết hợp giữa Sigmoid-Normal $p(\tau)$ tại T2A và Beta $p(\tau)$ tại SFT đạt tỷ lệ thành công cao nhất (71,1%); việc đảo ngược lựa chọn ở một trong hai giai đoạn sẽ làm giảm hiệu suất. **(c) Thời gian đào tạo T2A.** Hiệu suất đạt đỉnh ở 2.000 bước (71,1%) và ổn định ở 10.000 bước; 40.000 bước gây ra sự sụt giảm nhẹ do trang bị quá mức cho kho dữ liệu T2A.

định vị chính xác đối tượng và tiếp cận nó, mặc dù hình học mờ và phẳng ngăn cản khả năng nắm bắt ổn định. Điều này phản ánh ranh giới vật lý của việc khái quát hóa hình dạng chứ không phải là sự thất bại trong việc nhận dạng trực quan hoặc hướng dẫn sau. Kết quả này cho thấy sự chuyển giao theo hướng dẫn từ quá trình đào tạo trước liên tục hỗn hợp VL–VLA–VLN: mô hình có thể tuân theo các động từ hành động mới và nhận ra các đối tượng không nhìn thấy bằng cách sử dụng phạm vi ngôn ngữ và hình ảnh từ dữ liệu đào tạo trước cho mục đích chung.

Độ bền của nền (dưới cùng bên phải). Cuối cùng, chúng tôi thăm dò độ chắc chắn của sự thay đổi miền hình ảnh. Qwen-VLA-Base mở nắp bút thành công và đặt nắp bút lên bàn, đây là một thao tác khéo léo gồm hai giai đoạn đòi hỏi phải kiểm soát lực chính xác. Mặc dù nhiệm vụ này có thể đã gặp phải trong quá trình đào tạo trước nhưng nền màu vàng được sử dụng ở đây chưa bao giờ được nhìn thấy trong quá trình đào tạo. Bất chấp bối cảnh trực quan không thể nhìn thấy này, chính sách vẫn hoàn thành nhiệm vụ mà không có bất kỳ sự suy giảm nào. Sự bất biến này đối với nhiễu loạn nền phù hợp với tính đa dạng trực quan của dữ liệu hiểu biết VL cho mục đích chung được sử dụng trong quá trình đào tạo trước liên tục. Việc tiếp xúc với các hình ảnh tự nhiên với nhiều cảnh, ánh sáng và phong nền khác nhau có thể khuyến khích bộ mã hóa hình ảnh tập trung vào các đối tượng liên quan đến nhiệm vụ thay vì các tín hiệu nền giả.

5.2 Nghiên cứu cắt bỏ

5.2.1 Cấu trúc văn bản thành hành động trước khi đào tạo

Như đã thiết lập trong Phần 3.1, T2A huấn luyện bộ giải mã để xây dựng lại các phân phối hành động chỉ từ lời nhắc ngôn ngữ và phương án, xây dựng hành động có cấu trúc trước khi bắt đầu nền tảng trực quan. Bây giờ chúng tôi loại bỏ năm lựa chọn thiết kế định hình hình ưu tiên này: thành phần dữ liệu, chế độ dự đoán trình tự, đầu vào trực quan, phân phối dấu thời gian khớp với luồng và thời lượng đào tạo. Tất cả các quá trình cắt bỏ đều có chung một công thức luyện tập ở hạ nguồn; kết quả là tỷ lệ thành công nhiệm vụ (%) sau SFT từ điểm kiểm tra T2A trên Simpler-WidowX.

Thành phần dữ liệu. T2A thu thập các ưu tiên hành động chỉ từ ngôn ngữ, do đó thành phần dữ liệu của nó trực tiếp định hình những gì bộ giải mã học được. Chúng tôi xem xét hai nguồn. *Syn* (quỹ đạo tổng hợp chỉ bằng ngôn ngữ từ quy trình mô phỏng của chúng tôi) có chi phí thấp để mở rộng quy mô và phạm vi nhiệm vụ rộng, nhưng quỹ đạo của nó được lý tưởng hóa về mặt động học. *Thực tế* (dữ liệu điều khiển từ xa của robot thực, giám sát nhìn) nắm bắt được động lực học vật lý đích thực nhưng lại tốn kém để thu thập và thu hẹp phạm vi nhiệm vụ.

Như được hiển thị trong Hình 6(a), dữ liệu T2A thuần túy thực mang lại 51,0%, trong khi dữ liệu tổng hợp thuần túy đạt 64,1%—tốt hơn nhưng vẫn ở mức dưới mức tối ưu. Trộn ~20% tổng hợp với 80% thực tế đạt được kết quả tốt nhất (71,1%), tăng +10,2 pp so với đường cơ sở không có T2A (60,9%). *Syn* mở rộng phạm vi bao phủ của các tương ứng ngôn ngữ–hành động mà bộ giải mã có thể học, trong khi *Real* giữ vững ưu điểm trong các động lực học hợp lý về mặt vật lý.

Chế độ dự đoán trình tự: toàn bộ chiều dài so với đoạn. Dự đoán toàn bộ chuỗi giám sát toàn bộ quỹ đạo trong một lần chuyển tiếp, đưa bộ giải mã tiếp xúc với cấu trúc thời gian có đường chân trời dài và các kiểu bắt đầu/kết thúc tự nhiên. Thay vào đó, dự đoán khối sẽ chia mỗi quỹ đạo thành các cửa sổ có độ dài cố định và huấn luyện bộ giải mã để chỉ tạo ra cửa sổ tiếp theo từ lệnh tác vụ, giúp cắt bớt các phụ thuộc có chiều dài và tạo ra sự mơ hồ về vị trí tại các ranh giới khối.

Hình 6(a) cho thấy rằng dự đoán toàn chuỗi luôn hoạt động tốt hơn dự đoán khối trên các hỗn hợp dữ liệu. Ở mức dữ liệu tổng hợp 10%, khoảng cách là +4,9 pp (65,4% so với 60,4%); ở mức 0% tổng hợp (chỉ thực), khoảng cách là +2,9 pp (51,0% so với 48,2%). Các quỹ đạo đầy đủ cho phép bộ giải mã tìm hiểu cách ánh xạ ngôn ngữ để hoàn thành các chuỗi hành động, bao gồm sự kết hợp và thành phần ở cấp độ quỹ đạo, trong khi các đoạn chỉ cung cấp các đoạn cục bộ khiến ánh xạ này không đầy đủ. Điều quan trọng là cách biểu diễn hành động giống hệt nhau giữa T2A và các giai đoạn xuôi dòng: các hành động được mã hóa dưới dạng chuyển vị của bộ tác động cuối delta so với khung đầu tiên của mỗi đoạn và lời nhắc phương án chỉ định nền tảng robot, quy ước chuẩn hóa và phạm vi dự đoán, cho phép bộ giải mã xử lý các phương án không đồng nhất trong cùng một mục tiêu T2A.

Đầu vào thị giác trong T2A. T2A cổ tình là một giai đoạn *không có thị lực*. Việc bao gồm các quan sát hình ảnh sẽ làm tăng chi phí mỗi bước lên gần một bậc và quan trọng hơn là sẽ cho phép bộ giải mã rút ngắn thông qua các tín hiệu thị giác thay vì học cách thực hiện các hành động bằng ngôn ngữ.

Hình 6(a) xác nhận điều này: ở mức 10% dữ liệu tổng hợp, dự đoán phân đoạn có hình ảnh đạt 57,6%, trong khi cài đặt tương tự không có hình ảnh đạt tới 60,4%—a −2,9 pp hình phạt cho việc bao gồm tầm nhìn. Khi có hình ảnh, bộ giải mã có thể dựa vào các mối tương quan trực quan thay vì xây dựng ánh xạ hành động-ngôn ngữ đáng tin cậy, làm loãng chính xác những gì T2A được thiết kế để thiết lập trước đó. Mã thông báo hình ảnh phải được loại bỏ hoàn toàn trong T2A; nền tảng trực quan được chuyển sang CPT, tại thời điểm đó bộ giải mã đã sở hữu một hành động được định dạng tốt trước đó.

Phân phối dấu thời gian khớp luồng. Chính sách khớp luồng dựa trên dấu thời gian vô hướng $\tau \in [0, 1]$ nội suy giữa mục tiêu sạch ($\tau=0$) và nhiễu thuần túy ($\tau=1$). Phân phối lấy mẫu $p(\tau)$ xác định mức nhiễu nào nhận được tín hiệu gradient nhiều nhất trong quá trình huấn luyện. Thông lệ tiêu chuẩn là sử dụng phân phối *Beta*, tập trung mật độ về phía đầu sạch; chúng tôi tuân theo quy ước này ở giai đoạn CPT và SFT. Tuy nhiên, do T2A hoạt động mà không cần điều hòa thị giác nên bộ giải mã không có tính năng cốt lõi để hướng dẫn khứu nhiều và chúng tôi đưa ra giả thuyết rằng việc chuyển độ dốc sang các dấu thời gian trung gian—trong đó tỷ lệ tín hiệu trên nhiễu là thông tin hữu ích nhất cho việc học ánh xạ hành động-ngôn ngữ—có thể hiệu quả hơn. Do đó, chúng tôi so sánh Beta với *Sigmoid-Normal*, đạt cực đại ở mức nhiễu trung bình (Hình 6(b)).

Như hình 6(b), Sigmoid-Normal $p(\tau)$ tại T2A kết hợp với Beta $p(\tau)$ tại SFT đạt tỷ lệ thành công cao nhất (**71,1%**). Chuyển sang Beta ở T2A giảm hiệu suất xuống 65,4% (−5,7 pp), trong khi sử dụng Sigmoid-Normal ở SFT thay vì Beta mang lại 62,8% (−8,3 pp). Sự kết hợp tệ nhất—Beta ở cả hai giai đoạn—chỉ đạt 59,4%. Nếu không có điều kiện trực quan để hướng dẫn việc khứu nhiều, các dấu thời gian trung gian mang nhiều tín hiệu học tập nhất cho ngôn ngữ-hành động trước đó; khi đường trực VLM cung cấp khả năng điều hòa phong phú ở CPT/SFT, $p(\tau)$ hình Beta giúp trải gradient đồng đều hơn sẽ trở nên hiệu quả hơn về mẫu. Do đó, chúng tôi sử dụng Sigmoid-Normal ở T2A và Beta ở CPT/SFT trong suốt quy trình cuối cùng của chúng tôi.

Thời gian đào tạo T2A. Dài hơn T2A training cho phép bộ giải mã khám phá đầy đủ hơn về phân phối hành động, nhưng việc đào tạo quá mức trên T2A làm mất phần cốt lõi cơ phù hợp quá mức với các đặc điểm riêng của nó và làm giảm tính linh hoạt có sẵn cho CPT. Chúng tôi quét thời lượng T2A trên một phạm vi rộng để xác định điểm phù hợp.


Như được hiển thị trong Hình 6(c), hiệu suất đạt đỉnh ở 2.000 bước (**71,1%**) và vẫn tương đương ở 4.000 bước (67,5%) và 10.000 bước (67,2%). Ở 40.000 bước, chúng tôi quan sát thấy mức giảm đáng chú ý là 60,4%. Dự kiến sẽ có sự hội tụ nhanh chóng: ánh xạ ngôn ngữ-hành động mà T2A học có cấu trúc chiều thấp hơn so với không gian hành động-ngôn ngữ-tầm nhìn đầy đủ, do đó, một số bước khiêm tốn là đủ để nắm bắt nó; đào tạo kéo dài bắt đầu ghi nhớ các trường hợp quỹ đạo cụ thể thay vì tinh chỉnh cấu trúc trước đó. Chúng tôi áp dụng **2.000 bước T2A** làm mặc định trong quy trình cuối cùng của mình, mang lại sự cân bằng thuận lợi về chi phí-chất lượng.

5.2.2 Đồng đào tạo đa phương án

Chúng tôi nghiên cứu hai trục thiết kế rất quan trọng cho hoạt động đồng đào tạo đa phương án: vai trò của dữ liệu ngôn ngữ thị giác trong quá trình học tập hành động và chính sách chiếu đổi với các không gian hành động không đồng nhất.

Tác động của dữ liệu ngôn ngữ tầm nhìn đến hoạt động học tập bằng hành động. Mặc dù hoạt động giám sát ngôn ngữ tầm nhìn hoạt động trong không gian mã thông báo riêng biệt trong khi dự đoán hành động nhắm vào các quỹ đạo liên tục, nhưng hai mục tiêu này có chung xương sống về nhận thức và ngôn ngữ. Một câu hỏi tự nhiên là liệu việc giữ lại dữ liệu VL trong quá trình

việc tinh chỉnh thể hiện sẽ giúp ích hoặc làm tổn hại đến chất lượng hành động. Chúng tôi so sánh ba cấu hình trong Hình 7: **(a) Chỉ hành động**: đường trực được tinh chỉnh riêng trên các quỹ đạo được thể hiện mà không có sự giám sát của VL; **(b) Hành động + Dữ liệu VL**: một phần dữ liệu VL (VQA, chú thích, nổi đất không gian) được trộn vào kho dữ liệu đào tạo.



Hình 7: Sự cắt bỏ đồng đào tạo ngôn ngữ thị giác. **(a) Tác động của dữ liệu VL đến học tập hành động.** Tỷ lệ thành công trung bình của nhiệm vụ (%) trên bốn điểm chuẩn cho Chi VLA (chỉ dữ liệu hành động) so với VL+VLA (đồng đào tạo dữ liệu ngôn ngữ thị giác +). Trên các điểm chuẩn đơn giản hơn (Libero, Simpler-WidowX), hai cấu hình hoạt động tương đương nhau, xác nhận rằng việc đồng đào tạo VL không gây ra sự can thiệp nào. Trên các điểm chuẩn yêu cầu nhận dạng đối tượng chi tiết và phân tích lệnh cấu thành, VL+VLA mang lại mức tăng rõ ràng: +4,9 trang trên RoboCasa-GR1 (51,1% → 56,0%) và +4,6 trang trên RoboTwin-2.0 (81,8% → 86,4%). **(b) Khả năng chuyển đổi của DiT đã được huấn luyện trước.** Tỷ lệ thành công SFT (%) trên RoboCasa-GR1 so với các bước huấn luyện (k) khi ghép nối trực chính Qwen3.5 VLM ban đầu với bộ giải mã DiT được khởi tạo từ đầu so với DiT được huấn luyện trước. DiT được huấn luyện trước hội tụ nhanh hơn và đạt đỉnh cao hơn.

Như được hiển thị trong Hình 7 (a), việc trộn dữ liệu VL vào quá trình đào tạo mang lại lợi ích rõ ràng về các điểm chuẩn thao tác. Trên Libero và Simpler-WidowX, VLA-Only và VL+VLA đạt được tỷ lệ thành công gần như giống nhau. Trên RoboCasa-GR1, yêu cầu điều khiển toàn thân trong các cảnh nhà bếp lộn xộn với các đồ vật và cấu hình không gian đa dạng, VL+VLA cải thiện so với VLA-Only +4,9% tuyệt đối (51,1% → 56,0%). Ngoài ra, chúng tôi gắn DiT đã được huấn luyện trước vào một VLM Qwen3.5-4B mới và so sánh với đường cơ sở ngay từ đầu trong đó DiT được khởi tạo ngẫu nhiên. Như được hiển thị trong Hình 7 (b), DiT được huấn luyện trước luôn hoạt động tốt hơn mức cơ bản ngay từ đầu trong suốt quá trình huấn luyện, hội tụ nhanh hơn ở giai đoạn đầu và đạt được thành công cao nhất.

Thiết kế trình chiếu cho các phương án không đồng nhất. Các nền tảng robot khác nhau có các chiều và ngữ nghĩa hành động khác nhau (ví dụ: cánh tay 7-DoF so với toàn bộ cơ thể 29-DoF). Để tìm hiểu không gian biểu diễn được chia sẻ trên các định dạng hành động không đồng nhất, phép chiếu giữa không gian tiềm ẩn DiT và vector hành động theo phương án phải điều hòa sự không khớp này. Để đạt được mục đích này, chúng tôi so sánh ba thiết kế tiêu biểu.

Multi-MLP. Mỗi phương án sở hữu một MLP bộ mã hóa riêng ánh xạ thứ nguyên hành động gốc của nó với kích thước ẩn DiT và một MLP bộ giải mã riêng ánh xạ ngược lại. Hãy d_i biểu thị kích thước hành động của phương án i , h kích thước ẩn DiT và N số lượng phương án. Mỗi phương án sở hữu một bộ mã hóa riêng $f_i^{\text{enc}} : \mathbb{R}^{d_i} \rightarrow \mathbb{R}^h$ và bộ giải mã $f_i^{\text{dec}} : \mathbb{R}^h \rightarrow \mathbb{R}^{d_i}$, tổng cộng $2h \sum_{i=1}^N d_i$ tham số.

Nói. Các hành động từ tất cả N phương án được ghép nối thành một vector chiều duy nhất $D = \sum_{i=1}^N d_i$; mỗi phương án chiếm một phân đoạn dành riêng, không chồng chéo. Bộ mã hóa dùng chung $f^{\text{enc}} : \mathbb{R}^D \rightarrow \mathbb{R}^h$ và bộ giải mã $f^{\text{dec}} : \mathbb{R}^h \rightarrow \mathbb{R}^D$ xử lý vector đầy đủ ($2h \sum_{i=1}^N d_i$ tham số) và mỗi phương án truy xuất dự đoán của nó từ phân đoạn tương ứng.

Không đệm. Một MLP được chia sẻ duy nhất mã hóa tất cả các phương án; vector hành động ngắn hơn được đệm bên phải bằng các số 0 đến $d_{\max} = \max_i d_i$ trước khi mã hóa. Bộ mã hóa dùng chung $f^{\text{enc}} : \mathbb{R}^{d_{\max}} \rightarrow \mathbb{R}^h$ và bộ giải mã $f^{\text{dec}} : \mathbb{R}^h \rightarrow \mathbb{R}^{d_{\max}}$ xử lý vector đệm ($2h d_{\max}$ tham số); mỗi phương án chỉ đọc tiền tố chiều d_i của nó. Vì $d_{\max} \leq \sum_i d_i$ nên Zero-Padding sử dụng ít tham số chiều hơn cả Multi-MLP và Ghép nối.

Như được hiển thị trong Bảng 10, tất cả các thiết kế chiếu đồng đào tạo đều đạt được hiệu suất tương đương với các đường cơ sở của một phương án duy nhất trên cả hai điểm chuẩn (Bridge single-train 62,8% so với co-train ~63%; Robocasa single-train 53,4% so với co-train 52–53%), xác nhận rằng việc đồng đào tạo đa phương án không gây ra bất lợi đáng kể nào liên quan đến việc đào tạo trên mỗi tập dữ liệu một cách độc lập. Trong số ba thiết kế, sự khác biệt về hiệu suất là rất nhỏ (<1,2% tuyệt đối trên cả hai điểm chuẩn), cho thấy rằng việc lựa chọn hình chiếu

Bảng 10: **Cắt bỏ thiết kế chiều.** Kết quả là tỷ lệ thành công trung bình của nhiệm vụ (%). Tất cả các biến thể đồng đẳng tạo đều có chung một công thức đào tạo.

	Single-Embodiment Training		Multi-Embodiment Co-training		
	Bridge Only	Robocasa Only	Multi-MLP	Concat.	Zero-Pad
Bridge	62.8	—	63.3	63.0	63.0
Robocasa	—	53.4	52.1	52.8	53.2

kiến trúc có tác động hạn chế đến sự thành công của nhiệm vụ khi không gian tiềm ẩn chung được thiết lập. Tuy nhiên, Zero-Padding có kiến trúc nhẹ nhất: nó chỉ yêu cầu $2h \cdot d_{\max}$ tham số chiều so với $2h \sum_i d_i$ cho Multi-MLP và Concatenation. Do đó, chúng tôi sử dụng **Zero-Padding** làm thiết kế trình chiếu mặc định.

5.2.3 Hiệu quả của RL sau đào tạo

Chúng tôi nghiên cứu xem liệu RL trên SFT có mang lại lợi ích bổ sung hay không và liệu những lợi ích đó có chuyển sang các điểm chuẩn không thấy trong quá trình đào tạo RL hay không. Để tách biệt sự đóng góp của từng giai đoạn sau đào tạo, chúng tôi đánh giá ba điểm kiểm tra dọc theo quy trình đào tạo: mô hình cơ sở CPT (**Qwen-VLA-Base**), mô hình sau SFT đa nhiệm (**+SFT**) và mô hình sau sàng lọc RL (**+RL**, tức là Qwen-VLA-Instruct). Việc triển khai RL được thu thập độc quyền trong SimplierEnv với phần thưởng thành công nhị phân thưa thớt; không có dữ liệu điểm chuẩn nào khác được sử dụng trong giai đoạn RL.

Bảng 11: **Hiệu ứng tích lũy của các giai đoạn sau đào tạo.** Mỗi hàng thêm một giai đoạn lên trên điểm kiểm tra trước đó. Việc triển khai RL chỉ được thu thập trong SimplierEnv. Tất cả các con số đều là tỷ lệ thành công (%) ngoại trừ Điểm thao tác DOMINO (MS).

Stage	In-Distribution					OOD-static	OOD-dynamic (DOMINO)	
	Simpler	RoboCasa	RoboTwin-E	RoboTwin-H	LIBERO	SimplerOOD	SR	MS
CPT	64.3	40.4	64.3	66.4	90.8	25.3	21.1	37.4
+ SFT	70.8	56.0	86.3	87.1	97.8	31.6	25.7	39.1
+ RL	73.7	56.7	86.1	87.2	97.9	32.0	26.6	39.5

Như được trình bày trong Bảng 11, mỗi giai đoạn sau đào tạo đều mang lại những lợi ích bổ sung. SFT mang lại những cải tiến lớn trên tất cả các điểm chuẩn bằng cách chuyên biệt hóa các biểu diễn CPT có mục đích chung cho các phân phối nhiệm vụ xuôi dòng. Sau đó, RL sẽ nâng cao hơn nữa so với SFT, với mức tăng lớn nhất trên SimplierEnv (+2,9 trang, từ 70,8% lên 73,7%), môi trường trong đó các đợt triển khai RL được thu thập. Điều này xác nhận rằng việc tối ưu hóa trực tiếp sự thành công của nhiệm vụ vòng kín sẽ nắm bắt được những cải tiến về chính sách mà chỉ mục tiêu bất chước không thể thực hiện được.

Quan trọng hơn, lợi ích RL không chỉ giới hạn trong môi trường đào tạo. Trên các điểm chuẩn *không* nằm trong quá trình phân phối triển khai RL, hiệu suất được giữ nguyên hoặc cải thiện đôi chút: RoboCasa tăng 0,7 trang, RoboTwin-Hard tăng 0,1 trang, LIBERO tăng 0,1 trang và đánh giá OOD trên SimplierEnv-OOD tăng 0,4 trang. RoboTwin-Easy thể hiện những thay đổi không đáng kể (<0,6 trang), xác nhận rằng RL không gây ra tình trạng quên lãng nghiêm trọng các nhiệm vụ đã thực hiện. Trên điểm chuẩn thao tác động DOMINO, thử nghiệm khả năng khái quát hóa không bắn cho các đối tượng chuyển động, cả SR (25,7% → 26,6%) và MS (39,1 → 39,5) đều cải thiện mặc dù hoàn toàn không có dữ liệu thao tác động trong quá trình đào tạo RL. Những kết quả này chỉ ra rằng việc tối ưu hóa thành công nhiệm vụ trong mô phỏng sẽ duy trì hiệu suất với sự chuyển giao tích cực nhẹ: chính sách học cách thực thi quyết đoán hơn và phục hồi sau các lỗi gập, những lợi ích tổng quát trên các cài đặt đánh giá.

5.2.4 Trạng thái điều hòa

Nhiều phương pháp học robot đưa ra chính sách về trạng thái cảm nhận bản thể rõ ràng (ví dụ: góc khớp) bên cạnh các quan sát trực quan, với giả định rằng việc biết cấu hình robot hiện tại sẽ giúp dự đoán hành động tiếp theo. Tuy nhiên, đầu vào cảm nhận bản thể cũng đưa ra các phụ thuộc theo phương án cụ thể có thể cản trở việc khái quát hóa theo nhiều phương án, vì các nền tảng khác nhau có không gian khớp và cấu trúc động học khác nhau. Chúng tôi kiểm tra xem liệu điều hòa trạng thái rõ ràng có mang lại lợi ích cho việc học hành động trong Qwen-VLA hay không và nếu có thì trạng thái nên được đưa vào đâu trong kiến trúc. Chúng tôi so sánh ba chiến lược trên RoboTwin-2.0:

- **Không có trạng thái.** Mô hình chỉ nhận được những quan sát trực quan và hướng dẫn ngôn ngữ. Không có thông tin cảm thụ bản quyền nào được cung cấp cho đường trục VLM hoặc bộ giải mã hành động DiT.

- **Trạng thái trong Lỗi nhắc VLM.** Các góc khớp được rời rạc hóa thành 256 ô trên mỗi chiều và được tuần tự hóa thành dấu nhắc ngôn ngữ, ví dụ: "state: [34, 128, 67, 200, 55, 12, 88] pick up the bowl". VLM xử lý mã thông báo trạng thái cùng với hình ảnh và hướng dẫn; DiT không nhận được đầu vào trạng thái bổ sung.
- **Trạng thái DiT.** Các góc khớp được truyền trực tiếp dưới dạng vectơ có giá trị liên tục đến bộ giải mã hành động DiT dưới dạng đầu vào điều hòa bổ sung, bỏ qua hoàn toàn VLM.

Bảng 12: Quá trình cắt bỏ điều hòa trạng thái trên RoboTwin-2.0 (tỷ lệ thành công, %).

Conditioning	RoboTwin-Easy	RoboTwin-Hard
No State	88.7	87.4
State in VLM Prompt	89.3	88.7
State in DiT	89.4	88.3

Như được trình bày trong Bảng 12, việc kết hợp trạng thái cảm thụ bản thân chỉ mang lại lợi ích cận biên bất kể chiến lược tiêm: tối đa +0,7 pp ở mức Dễ và +1,3 pp ở mức Khó so với đường cơ sở chỉ dành cho thị giác. Hai chiến lược chèn này thực hiện tương đương nhau ($\leq$ chênh lệch 0,4 pp), cho thấy rằng cả quá trình xử lý ngữ nghĩa của VLM lẫn điều hòa liên tục của DiT đều không mang lại lợi thế rõ ràng cho việc mã hóa thông tin góc khớp. Chúng tôi cho rằng tác động hạn chế của điều kiện trạng thái là do hai yếu tố. Đầu tiên, các quan sát trực quan ở nhiều chế độ xem đã cung cấp đầy đủ thông tin về cấu hình hiện tại của robot, đặc biệt đối với các nhiệm vụ mà bộ phận tác động cuối được hiển thị trong ít nhất một chế độ xem camera. Thứ hai, bộ giải mã hành động khớp luồng dự đoán các chuyển vị hành động tương đối thay vì các tư thế tuyệt đối, giúp giảm nhu cầu tham chiếu trạng thái hiện tại rõ ràng. Do những lợi ích hạn chế và độ phức tạp bổ sung của việc duy trì giao diện trạng thái dành riêng cho phương án trên nhiều nền tảng khác nhau, chúng tôi chọn không đưa điều kiện trạng thái vào khung mặc định của mình, giữ lời nhắc văn bản nhận biết phương án làm đầu vào duy nhất dành riêng cho nền tảng.

6 Kết luận

Chúng tôi đã trình bày **Qwen-VLA**, một mô hình hành động-ngôn ngữ-tầm nhìn thống nhất mở rộng xương sống ngôn ngữ-tầm nhìn Qwen từ nhận thức và lý luận đến tạo ra hành động thể hiện. Bằng cách xây dựng thao tác, điều hướng, mô hình hành động lấy bản chất làm trung tâm và dự đoán quỹ đạo trong khung dự đoán hành động và quỹ đạo chung, Qwen-VLA cho phép một mô hình duy nhất học hỏi từ dữ liệu được thể hiện không đồng nhất giữa các nhiệm vụ, môi trường và các phương án robot. Thông qua điều hòa kịp thời nhận biết phương án, bộ giải mã hành động khớp dòng dựa trên DiT, huấn luyện trước khớp quy mô lớn và huấn luyện sau SFT/RL, Qwen-VLA đạt được hiệu suất tổng quát mạnh mẽ trong khi vẫn duy trì tính linh hoạt trên các quy ước điều khiển khác nhau. Kết quả của chúng tôi cho thấy các mô hình VLA dựa trên ngôn ngữ cung cấp một con đường thực tế hướng tới trí thông minh được thể hiện bằng cách điều chỉnh nhận thức đa phương thức, hiểu hướng dẫn, các ràng buộc về phương án và các hành động thực thi. So với các mô hình thể giới lấy dự đoán làm trung tâm bằng hình ảnh, Qwen-VLA nhấn mạnh sự hiểu biết cơ bản về đa phương thức thành các hành động có thể được thực hiện bởi các tác nhân được thể hiện. Cùng với nhau, những kết quả này chỉ ra rằng các mô hình VLA có thể đóng vai trò là giao diện có thể thực hiện được giữa các mô hình nền tảng đa phương thức và các tác nhân được thể hiện, kết nối lý luận ngôn ngữ cấp cao với kiểm soát vật lý cấp thấp.

7 Hạn chế và công việc trong tương lai

Mặc dù có khả năng tổng quát, Qwen-VLA vẫn có một số hạn chế. Đầu tiên, dữ liệu hành động được thể hiện vẫn nhỏ hơn và kém đa dạng hơn nhiều so với dữ liệu huấn luyện trước ngôn ngữ thị giác, hạn chế tính mạnh mẽ đối với các đối tượng đuôi dài, môi trường, phương án và tương tác nhiều liên hệ. Thứ hai, đào tạo chung về hiểu ngôn ngữ tầm nhìn, điều hướng và tạo ra hành động mang lại sự cân bằng tối ưu hóa. Trong khi đào tạo theo định hướng hành động cải thiện việc học chính sách, nó có thể thụt lùi một cách khiêm tốn một số đánh giá ngôn ngữ tầm nhìn và điều hướng thuần túy, cho thấy nhu cầu cân bằng mục tiêu, chương trình giảng dạy dữ liệu và chuyên môn hóa mô-đun tốt hơn. Thứ ba, các đánh giá hiện tại chủ yếu vẫn mang tính ngắn hạn và dựa trên điểm chuẩn, khiến việc triển khai trong thế giới thực trong thời gian dài và dễ xảy ra thất bại là một thách thức mở.

Những hạn chế này thúc đẩy một số hướng đi trong tương lai. Mở rộng quy mô dữ liệu tương tác trong thế giới thực thông qua việc thu thập, mô phỏng tự động và chuyển từ mô phỏng sang thực sẽ rất quan trọng để cải thiện tính mạnh mẽ. Video có quy mô lớn của con người, từ cả góc nhìn tự nhiên và góc nhìn thứ ba, có thể cung cấp những thông tin sơ bộ về mặt vật lý và sự trừu tượng hóa về thời gian ngoài các màn trình diễn của robot. Các mô hình trong tương lai nên kết hợp việc lập kế hoạch dài hạn, trí nhớ phân đoạn và mô hình hóa thể giới, cho phép các tác nhân theo dõi trạng thái, phân tách nhiệm vụ, phục hồi sau thất bại và dự đoán hậu quả hành động. Cuối cùng, phản hồi vật lý phong phú hơn như lực, xúc giác,

và các tín hiệu cảm nhận bản thân, kết hợp với học tăng cường trên quy mô lớn trong mô phỏng và thế giới thực, có thể thu hẹp hơn nữa khoảng cách giữa sự hiểu biết thể hiện dựa trên ngôn ngữ và khả năng kiểm soát đáng tin cậy.

8 Đóng góp và Lời cảm ơn

Người đóng góp cốt lõi

Qiuyue Wang* Mingsheng Li* Jian Guan* Jinhui Ye Si Cheng Xie Yitao Liu Junhao Chen Zhixuan Liang
Jie Zhang Xintong Hu Xuhong Huang Pei Lin Junyang Lin Dayiheng Liu Shuai Bai[†] Jingren Chu

Người đóng góp

Jiazhao Zhang Haoqi Yuan Gengze Chu Hang Yin Ye Wang Yiyang Huang Zixing Lei Wujian Peng Delin
Chen Yingming Zheng Jingyang Fan Xianwei Zhuang Xin Chu Haoyang Li Anzhe Chen Tong Zhang Xuejing
Liu Yuchong Sun Ruizhe Chen Zhaohai Li Chenxu Lü Zhibo Yang Tao Yu Xionghui Chen

Lời cảm ơn

Chúng tôi cảm ơn Jun Huang, Jianlou Si, Chao Wang và Nana Jiang vì sự hỗ trợ mạnh mẽ của họ về môi trường mô phỏng và học tập tăng cường.

*Equal contribution. [†]Corresponding author.

AgIBot-World-Contributor, Qingwen Bu, Jisong Cai, Li Chen, et al. Thế giới Agibot colosso: Nền tảng thao tác quy mô lớn dành cho các hệ thống được thể hiện thông minh và có thể mở rộng, vào năm 2025. URL <https://arxiv.org/abs/2503.06669>.

Shuai Bai, Yuxuan Cai, Ruizhe Chen, Keqin Chen, Xionghui Chen, Zesen Cheng, Lianghao Deng, Wei Ding, Chang Gao, Chunjiang Ge, và những người khác. Báo cáo kỹ thuật Qwen3-vl. *bản in trước arXiv arXiv:2511.21631*, 2025a.

Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibao Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yuanzhi Zhu, Mingkun Yang, Zhaohai Li, Jianqiang Wan, Pengfei Wang, Wei Ding, Zheren Fu, Yiheng Xu, Jiabo Ye, Xi Zhang, Tianbao Xie, Zesen Cheng, Hang Zhang, Zhibo Yang, Haiyang Xu và Junyang Lin. Báo cáo kỹ thuật Qwen2.5-vl, 2025b.

Homanga Bharadhwaj, Jay Vakil, Mohit Sharma, Abhinav Gupta, Shubham Tulsiani và Vikash Kumar. Roboagent: Khái quát hóa và hiệu quả trong thao tác robot thông qua tăng cường ngữ nghĩa và phân chia hành động, 2023. URL <https://arxiv.org/abs/2309.01918>.

Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, và những người khác. π_0 : Mô hình luồng hành động-ngôn ngữ-tâm nhìn để điều khiển robot nói chung. *arXiv bản in trước arXiv:2410.24164*, 2024.

Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Manuel Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vưong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu và Ury Zhilinsky. $\pi_0.5$: Mô hình luồng hành động-ngôn ngữ-tâm nhìn để điều khiển robot nói chung. Báo cáo kỹ thuật, Trí tuệ vật lý, 2025.

Anthony Brohan, Yevgen Chebotar, Chelsea Finn, Karol Hausman, Alexander Herzog, Daniel Ho, Julian Ibarz, Alex Irpan, Eric Jang, Ryan Julian, và những người khác. RT-1: Máy biến áp robot để điều khiển thế giới thực ở quy mô lớn, 2022. URL <https://arxiv.org/abs/2212.06817>.

Xu Cao, Tong Zhou, Yunsheng Ma, Wenqian Ye, Can Cui, Kun Tang, Zhipeng Cao, Kaizhao Liang, Ziran Wang, James M Rehg, et al. Maplm: Tiêu chuẩn ngôn ngữ tầm nhìn quy mô lớn trong thế giới thực để hiểu bản đồ và cảnh giao thông. Trong *Kỷ yếu của hội nghị IEEE/CVF về thị giác máy tính và nhận dạng mẫu*, trang 21819–21830, 2024.

Kai Chen, Yanze Li, Wenhua Zhang, Yanxin Liu, Pengxiang Li, Ruiyuan Gao, Lanqing Hong, Meng Tian, Xinhai Zhao, Zhenguo Li, và những người khác. Tự động đánh giá các mô hình ngôn ngữ tầm nhìn lớn về các trường hợp góc của tự lái. Trong *Hội nghị mùa đông của IEEE/CVF về các ứng dụng của thị giác máy tính*, trang 7817–7826, 2025a.

Xinyi Chen, Yilun Chen, Yanwei Fu, Ning Gao, Jiaya Jia, Weiyang Jin, Hao Li, Yao Mu, Jiangmiao Pang, Yu Qiao, et al. Internv1a-m1: Khung hành động-ngôn ngữ-tâm nhìn được hướng dẫn theo không gian dành cho chính sách robot tổng quát. *arXiv preprint arXiv:2510.13778*, 2025b.

An-Chieh Cheng, Yandong Ji, Zhaojing Yang, Xueyan Zou, Jan Kautz, Erdem Biyik, Hongxu Yin, Sifei Liu và Xiaolong Wang. NaVILA: Mô hình hành động-ngôn ngữ-tâm nhìn của robot có chân để điều hướng. Trong *Robotics: Khoa học và Hệ thống (RSS)*, 2025.

Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake và Shuran Song. Chính sách khuếch tán: Học chính sách thị giác thông qua khuếch tán hành động. Trong *Robotics: Khoa học và Hệ thống (RSS)*, 2023.

Haohan Chi, Huan-an Gao, Ziming Liu, Jianing Liu, Chenyu Liu, Jinwei Li, Kaisen Yang, Yang Cheng Yu, Zeda Wang, Wenyi Li, et al. vla ngẫu hứng: Trọng lượng mở và dữ liệu mở để thúc đẩy các mô hình hành động-ngôn ngữ-tâm nhìn. Trong *Hội nghị thường niên về Bộ dữ liệu và điểm chuẩn của hệ thống xử lý thông tin thần kinh*, 2025.

Matei Ciocarlie, Corey Goldfeder và Peter Allen. Nắm bắt khéo léo thông qua eigengrasp: Một cách tiếp cận theo chiều thấp đối với một vấn đề có độ phức tạp cao. Trong *Robotics: Hội thảo khoa học và thao tác hệ thống - cảm nhận và thích ứng với thế giới thực*, 2007.

Cộng đồng StarVLA. Starvla: Một cơ sở mã giống như Lego để phát triển mô hình hành động-ngôn ngữ-tâm nhìn. *arXiv preprint arXiv:2604.05014*, 2026.

Charles Corbiere, Simon Roburin, Syrielle Montariol, Antoine Bosselut và Alexandre Alahi. Chuỗi suy nghĩ trực quan xen kẽ dựa trên truy xuất trong các tình huống lái xe trong thế giới thực. *arXiv bản in trước arXiv:2501.04671*, 2025.

Dima Damen, Hazel Doughty, Giovanni Maria Farinella, Sanja Fidler, Antonino Furnari, Evangelos Kazakos, Davide Moltisanti, Jonathan Munro, Toby Perrett, Will Price và Michael Wray. Thay đổi quy mô tầm nhìn lấy cái tôi làm trung tâm: Bộ sưu tập, quy trình và thách thức dành cho epic-kitchens-100. *Tạp chí Quốc tế về Thị giác Máy tính*, 130:33–55, 2022.

Thierry Deruyttere, Simon Vandenhende, Dusan Grujicic, Luc Van Gool và Marie Francine Moens. Talk2car: Kiểm soát chiếc xe tự lái của bạn. Trong *Kỷ yếu hội thảo về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên*, trang 2088–2098, 2019.

Karim Elmaaroufi, Liheng Lai, Justin Svegliato, Yutong Bai, Sanjit A Seshia và Matei Zaharia. Graid: Tăng cường lý luận không gian của vlms thông qua việc tạo dữ liệu có độ chính xác cao. *arXiv preprint arXiv:2510.22118*, 2025.

Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, Dustin Podell, Tim Dockhorn, Zion English, Kyle Lacey, Alex Goodwin, Yannik Marek và Robin Rombach. Biến áp dòng chính lưu mở rộng để tổng hợp hình ảnh có độ phân giải cao. Trong *Kỷ yếu của Hội nghị quốc tế lần thứ 41 về học máy (ICML)*, trang 12606–12633, 2024.

Hao-Shu Fang, Hongjie Fang, Zhenyu Tang, Jirong Liu, Chenxi Wang, Junbo Wang, Haoyi Zhu và Cewu Lu. Rh20t: Bộ dữ liệu robot toàn diện để học các kỹ năng đa dạng chỉ trong một lần, 2023. URL <https://arxiv.org/abs/2307.00595>.

Hàng Phương, Thượng Như Lý, Thư Hàn Vương, Huyền Dương Hi, Định Khang Lương, Hướng Bạch. Hướng tới thao tác robot có thể khái quát hóa trong môi trường động. *arXiv preprint arXiv:2603.15620*, 2026.

Jianwu Fang, Lei-lei Li, Junfei Chu, Junbin Xiao, Hongkai Yu, Chen Lv, Jianru Xue và Tat-Seng Chua. Sự hiểu biết về video tai nạn theo quan điểm cái tôi bắt cóc để có được nhận thức lái xe an toàn. Trong *Kỷ yếu của Hội nghị IEEE/CVF về Thị giác máy tính và Nhận dạng mẫu*, trang 22030–22040, 2024.

Zipeng Fu, Tony Z Zhao và Chelsea Finn. Aloha di động: Học thao tác di động hai tay với khả năng vận hành từ xa toàn cơ thể với chi phí thấp. *arXiv preprint arXiv:2401.02117*, 2024.

Kristen Grauman, Andrew Westbury, Eugene Byrne, Zachary Chavis, Antonino Furnari, Rohit Girdhar, Jackson Hamburger, Hao Jiang, Miao Liu, Xingyu Liu, và những người khác. Ego4d: Vòng quanh thế giới trong 3.000 giờ video lấy cái tôi làm trung tâm. Trong *Kỷ yếu của Hội nghị IEEE/CVF về Thị giác máy tính và Nhận dạng mẫu*, trang 18995–19012, 2022.

Yuhan Hao, Zhengning Li, Lei Sun, Weilong Wang, Naixin Yi, Sheng Song, Caihong Qin, Mofan Chu, Yifei Zhan và Xianpeng Lang. Driveaction: Điểm chuẩn để khám phá các quyết định lái xe giống con người trong các mô hình vla. *arXiv bản in trước arXiv:2506.05667*, 2025.

Ryan Hoque, Peide Huang, David J. Yoon, Mouli Sivapurapu và Jian Zhang. Egodex: Học cách thao tác khéo léo từ video quy mô lớn. Trong *Hội nghị quốc tế về đại diện học tập (ICLR)*, 2026.

Chengkai Hou, Kun Wu, Jiaming Liu, Zhengping Che, et al. RoboMIND 2.0: Tập dữ liệu thao tác di động hai phương thức, đa phương thức dành cho trí thông minh được thể hiện có thể khái quát hóa, năm 2025. URL <https://arxiv.org/abs/2512.24653>.

Xintong Hu, Xuhong Huang, Jinyu Zhang, Yutong Yao, Yuchong Sun, Qiuyue Wang, Mingsheng Li, Sichen Xie, Yitao Liu, Junhao Chen, Yixuan Chen, Yingming Zheng, Shuai Bai và Tao Yu. Finevla: Điều chỉnh hướng dẫn chi tiết cho các chính sách hành động-ngôn ngữ-tầm nhìn có thể ổn định, 2026. URL <https://arxiv.org/abs/2605.27284>.

Yuichi Inoue, Yuki Yada, Kotaro Tanahashi và Yu Yamaguchi. Nuscen-es-mqa: Đánh giá tích hợp chú thích và qa cho bộ dữ liệu lái xe tự động bằng cách sử dụng chú thích đánh dấu. Trong *Kỷ yếu của Hội nghị mùa đông IEEE/CVF về các ứng dụng của thị giác máy tính*, trang 930–938, 2024.

Trí tuệ Vật lý, Bo Ai, Ali Amin, Raichelle Aniceto, Ashwin Balakrishna, Greg Balke, Kevin Black, George Bokinsky, Shihao Cao, Thomas Charbonnier, và những người khác. $\pi_{0.7}$: một mô hình nền tảng robot tổng quát có thể điều khiển được với các khả năng mới nổi. *arXiv bản in trước arXiv:2604.15483*, 2026.

Eric Jang, Alex Irpan, Mohi Khansari, Daniel Kappler, Frederik Ebert, Corey Lynch, Sergey Levine và Chelsea Finn. Bc-z: Khái quát hóa nhiệm vụ không cần bản với phương pháp học bắt chước bằng robot, 2022. URL <https://arxiv.org/abs/2202.02005>.

Michael Janner, Yilun Du, Joshua Tenenbaum và Sergey Levine. Lập kế hoạch với sự khuếch tán để tổng hợp hành vi linh hoạt. Trong *Hội nghị quốc tế về học máy*, trang 9902–9915. PMLR, 2022.

Xiaosong Jia, Yuqian Shao, Zhenjie Yang, Qifeng Li, Zhiyuan Zhang và Junchi Yan. Bench2drive-vl: Điểm chuẩn cho lái xe tự động vòng kín với các mô hình ngôn ngữ tầm nhìn. *arXiv preprint arXiv:2604.01259*, 2026.

Bo Jiang, Shaoyu Chen, Ben Cheng Liao, Xingyu Zhang, Wei Yin, Qian Zhang, Chang Huang, Wenyu Liu và Xinggang Wang. Senna: Kết nối các mô hình ngôn ngữ tầm nhìn lớn và lái xe tự động từ đầu đến cuối. *arXiv preprint arXiv:2410.22313*, 2024.

Tao Jiang, Tianyuan Yuan, Yichen Liu, Chenhao Lu, và những người khác. Bộ dữ liệu thế giới mở Galaxea và mô hình VLA hệ thống kép G0, 2025. URL <https://arxiv.org/abs/2509.00576>.

Simar Kareer, Dhruv Patel, Ryan Punamiya, Pranay Mathur, Shuo Cheng, Chen Wang, Judy Hoffman và Danfei Xu. Egimimic: Mở rộng quy mô học tập bắt chước thông qua video lấy cái tôi làm trung tâm. Vào *Hội nghị quốc tế IEEE về Robot và tự động hóa (ICRA) năm 2025 (ICRA)*, trang 13226–13233. IEEE, 2025.

Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, và những người khác. DROID: Tập dữ liệu thao tác robot ngoài tự nhiên quy mô lớn, 2024. URL <https://arxiv.org/abs/2403.12945>.

Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan P Foster, Pannag R Sanketi, Quân Vương và những người khác. Openvla: Một mô hình hành động-ngôn ngữ-tầm nhìn nguồn mở. Trong *Hội nghị thường niên lần thứ 8 về học tập robot năm 2024*.

Moo Jin Kim, Chelsea Finn và Percy Liang. Tinh chỉnh các mô hình tầm nhìn-ngôn ngữ-hành động: Tối ưu hóa tốc độ và thành công. *arXiv preprint arXiv:2502.19645*, 2025.

Jacob Krantz, Erik Wijmans, Arjun Majundar, Dhruv Batra và Stefan Lee. Ngoài biểu đồ điều hướng: Điều hướng ngôn ngữ và hình ảnh trong môi trường liên tục. Trong *Hội nghị Châu Âu về Thị giác Máy tính (ECCV)*, 2020.

Alexander Ku, Peter Anderson, Roma Patel, Eugene Ie và Jason Baldridge. Phòng xuyên phòng: Điều hướng ngôn ngữ và tầm nhìn đa ngôn ngữ với nền tảng không gian thời gian dày đặc. Trong *Kỷ yếu của Hội nghị năm 2020 về các phương pháp thực nghiệm trong xử lý ngôn ngữ tự nhiên (EMNLP)*, trang 4392–4412, 2020.

Lin Li, Qihang Zhang, Yiming Luo, Shuai Yang, Ruilin Wang, Fei Han, Mingrui Yu, Zelin Gao, Nan Xue, Xing Zhu, et al. Mô hình hóa thế giới nhân quả để điều khiển robot. *arXiv preprint arXiv:2601.21998*, 2026a.

Qixiu Li, Yu Deng, Yaobo Liang, Lin Luo, Lei Zhou, Chengtang Yao, Lingqi Zeng, Zhiyuan Feng, Huizhi Liang, Sichen Xu, Yizhong Zhang, Xi Chen, Hao Chen, Lily Sun, Dong Chen, Jiaolong Yang và Baining Guo. Đào tạo trước mô hình hành động-ngôn ngữ-hình ảnh có thể mở rộng để thao tác bằng robot với các video hoạt động thực tế của con người. Trong *Hội nghị quốc tế của IEEE về Robot và tự động hóa (ICRA)*, 2026b.

Xuânlin Li, Kyle Hsu, Jiayuan Gu, Karl Pertsch, Oier Mees, Homer Rich Walke, Chuyuan Fu, Ishikaa Lunawat, Isabel Sieh, Sean Kirmani, Sergey Levine, Jiajun Wu, Chelsea Finn, Hao Su, Quan Vương và Ted Xiao. Đánh giá các chính sách thao tác robot trong thế giới thực trong mô phỏng. *arXiv bản in trước arXiv:2405.05941*, 2024.

Lý Vinh Khang, Kaixin Xiong, Xiangyu Guo, Fang Li, Sixu Yan, Gangwei Xu, Lijun Chu, Long Chen, Haiyang Sun, Bing Wang, et al. Recogdrive: Một khuôn khổ nhận thức được củng cố cho việc lái xe tự động từ đầu đến cuối. Trong *Hội nghị quốc tế về đại diện học tập*, 2026c.

Định Khang Lương, Trình Chương, Tiểu Bằng Húc, Kiến Trung Cư, Trần Bá Lạc, Hương Bạch. Cùng nấu ăn và dọn dẹp: Dạy các tác nhân hiện thân để thực hiện nhiệm vụ song song. Trong *Kỷ yếu Hội nghị AAAI về Trí tuệ nhân tạo*, tập 40, trang 18415–18424, 2026.

Zhixuan Liang, Yao Mu, Mingyu Ding, Fei Ni, Masayoshi Tomizuka và Ping Luo. Adaptdiffuser: các mô hình phổ biến như các nhà lập kế hoạch tự phát triển thích ứng. Trong *Kỷ yếu của Hội nghị quốc tế lần thứ 40 về Học máy*, trang 20725–20745, 2023.

Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel và Matt Le. Kết hợp dòng chảy cho mô hình tổng quát. Trong *Hội nghị quốc tế lần thứ 11 về đại diện học tập (ICLR)*, 2023.

Bo Liu, Yifeng Zhu, Chongkai Gao, Yifeng Feng, Qiang Liu, Yuke Zhu và Peter Stone. LIBERO: Chuyển giao kiến thức theo tiêu chuẩn cho việc học tập suốt đời của robot. *Những tiến bộ trong Hệ thống xử lý thông tin thần kinh (NeurIPS)*, 2023.

Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su và Jun Zhu. Rdt-1b: mô hình nền tảng khuếch tán cho thao tác bằng tay, 2025a. Địa chỉ <https://arxiv.org/abs/2410.07864>.

Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su và Jun Zhu. Rdt-1b: mô hình nền tảng khuếch tán cho thao tác bằng tay. Trong *Hội nghị quốc tế về đại diện học tập*, 2025b.

Hao Luo, Yichen Feng, Wanpeng Zhang, Sipeng Zheng, Ye Wang, Haoqi Yuan, Jiazheng Liu, Chaoyi Xu, Qin Jin và Zongqing Lu. Being-h0: Huấn luyện trước hành động-ngôn ngữ-thị giác từ các video con người quy mô lớn. *arXiv preprint arXiv:2507.15597*, 2025.

Hao Luo, Ye Wang, Wanpeng Zhang, Sipeng Zheng, Ziheng Xi, Chaoyi Xu, Haiweng Xu, Haoqi Yuan, Chi Zhang, Yiqing Wang, Yichen Feng và Zongqing Lu. Being-h0.5: Mở rộng quy mô học tập của robot lấy con người làm trung tâm để khái quát hóa đa phương án. *arXiv preprint arXiv:2601.12993*, 2026.

Ana-Maria Marcu, Long Chen, Jan Hünemann, Alice Karnsund, Benoît Hanotte, Prajwal Chidananda, Saurabh Nair, Vijay Badrinarayanan, Alex Kendall, Jamie Shotton, và những người khác. Lingoqa: Trả lời câu hỏi trực quan cho xe tự lái. Trong *Hội nghị Châu Âu về Thị giác Máy tính*, trang 252–269, 2024.

Mayank Mittal, Pascal Roth, James Tigue, Antoine Richard, Octi Zhang, Peter Du, Antonio Serrano-Muñoz, Xinjie Yao, René Zurbrugg, Nikita Rudin, Lukasz Wawrzyniak, Milad Rakhsha, Alain Denzler, Eric Heiden, Ales Borovicka, Ossama Ahmed, Ireteyayo Akinola, Abrar Anwar, Mark T. Carlson, Ji Yuan Feng, Animesh Garg, Renato Gasoto, Lionel Gulich, Yijie Guo, M. Gussert, Alex Hansen, Mihir Kulkarni, Chenran Li, Wei Liu, Viktor Makovychuk, Grzegorz Malczyk, Hammad Mazhar, Masoud Moghani, Adithavairavan Murali, Michael Noseworthy, Alexander Poddubny, Nathan Ratliff, Welf Rehberg, Clemens Schwarke, Ritvik Singh, James Latham Smith, Bingjie Tang, Ruchik Thaker, Matthew Trepte, Karl Van Wyk, Fangzhou Yu, Alex Millane, Vikram Ramasamy, Remo Steiner, Sangeeta Subramanian, Clemens Volk, CY Chen, Neel Jawale, Ashwin Varghese Kuruttukulam, Michael A. Lin, Ajay Mandlekar, Karsten Patzwaltd, John Welsh, Huihua Zhao, Fatima Anes, Jean-Francois Lafleche, Nicolas Moënné-Loccoz, Soowan Park, Rob Stepinski, Dirk Van Gelder, Chris Amevor, Jan Carius, Jumyung Chang, Anka He Chen, Pablo de Heras Ciechowski, Gilles Daviet, Mohammad Mohajerani, Julia von Muralt, Viktor Reutskyy, Michael Sauter, Simon Schirm, Eric L. Shi, Pierre Terdiman, Kenny Vilella, Tobias Widmer, Gordon Yeoman, Tiffany Chen, Grizan, Cathy Li, Lotus Li, Connor Smith, Rafael Wiltz, Kostas Alexis, Yan Chang, David Chu, Linxi "Jim" Fan, Farbod Farshidian, Ankur Handa, Spencer Huang, Marco Hutter, Yashraj Narang, Soha Pouya, Shiwei Sheng, Yuke Zhu, Miles Macklin, Adam Moravanszky, Philipp Reist, Yunrong Guo, David Hoeller và Gavriel State. Phòng thí nghiệm Isaac: Khung mô phỏng được tăng tốc bằng gpu cho việc học tập của robot đa phương thức. *arXiv preprint arXiv:2511.04831*, 2025. URL <https://arxiv.org/abs/2511.04831>.

Yao Mu, Tianxing Chen, Shijia Peng, Zhanxin Chen, Zeyu Gao, Yude Zou, Lunkai Lin, Zhiqiang Xie và Ping Luo. Robotwin: Điểm chuẩn robot hai tay với cặp song sinh kỹ thuật số tổng hợp (phiên bản đầu). Trong *Hội nghị Châu Âu về Thị giác Máy tính*, trang 264–273. Mùa xuân, 2024.

Soroush Nasiriany, Abhiram Maddukuri, Lance Zhang, Adeet Parikh, Aaron Lo, Abhishek Joshi, Ajay Mandlekar, and Yuke Zhu. RoboCasa: Large-scale simulation of everyday tasks for generalist robots. In *Robotics: Science and Systems (RSS)*, 2024.

NVIDIA, :, Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi "Jim" Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Zhenyu Jiang, Jan Kautz, Kaushil Kundalia, Lawrence Lao, Zhiqi Li, Zongyu Lin, Kevin Lin, Guilin Liu, Edith Llonet, Loic Magne, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Zu Wang, Jing Wang, Qi Wang, Jiannan Xiang, Yuqi Xie, Yinzheng Xu, Zhenjia Xu, Seonghyeon Ye, Zhiding Yu, Ao Zhang, Hao Zhang, Yizhou Zhao, Ruijie Zheng và Yuke Zhu. Gr00t n1: Mô hình nền tảng mở cho robot hình người tổng quát, 2025. URL <https://arxiv.org/abs/2503.14734>.

Abby O'Neill, Abdul Rehman, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, Ajinkya Jain, và những người khác. Phương án x mở: Bộ dữ liệu học tập robot và mô hình rt-x: Cộng tác phương án x mở 0. Vào 2024 *Hội nghị quốc tế của IEEE về Robot và tự động hóa (ICRA)*, 2024.

William Peebles và Saining Xie. Các mô hình khuếch tán có thể mở rộng bằng máy biến áp. Trong *Kỷ yếu của Hội nghị quốc tế IEEE/CVF về Thị giác máy tính (ICCV)*, trang 4195–4205, 2023.

Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quân Vương, Oier Mees, Chelsea Finn và Sergey Levine. Nhanh: Mã thông báo hành động hiệu quả cho các mô hình hành động-ngôn ngữ-tầm nhìn. *arXiv preprint arXiv:2501.09747*, 2025.

Ryan Punamiya, Simar Kareer, Zeyi Liu, Josh Citron, Ri-Zhao Qiu, Xiongyi Cai, Alexey Gavryushin, Jiaqi Chen, Davide Liconti, Lawrence Y. Zhu, và những người khác. Egoverse: Một tập dữ liệu về con người lấy cái tôi làm trung tâm để robot học tập từ khắp nơi trên thế giới. *arXiv preprint arXiv:2604.07607*, 2026.

Tianwen Qian, Jingjing Chen, Lâm Hải Zhuo, Yang Jiao và Yu-Gang Jiang. Nuscenes-qa: Tiêu chuẩn trả lời câu hỏi trực quan đa phương thức cho kịch bản lái xe tự động. Trong *Kỷ yếu Hội nghị AAAI về Trí tuệ nhân tạo*, tập 38, trang 4542–4550, 2024.

Javier Romero, Dimitrios Tzionas và Michael J Black. Bàn tay hiện thân: mô hình hóa và chụp bàn tay và cơ thể lại với nhau. *Giao dịch ACM trên đồ họa (TOG)*, 36(6):1–17, 2017.

Ropedia. Xperience-10m: Bộ dữ liệu đa phương thức lấy cái tôi làm trung tâm quy mô lớn về trải nghiệm của con người. <https://huggingface.co/datasets/ropedia-ai/xperience-10m>, 2026.

John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan và Pieter Abbeel. Điều khiển liên tục nhiều chiều sử dụng ước lượng lợi thế tổng quát. *arXiv preprint arXiv:1506.02438*, 2015.

John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford và Oleg Klimov. Các thuật toán tối ưu hóa chính sách gần nhất. *CoRR*, abs/1707.06347, 2017.

Chonghao Sima, Katrin Renz, Kashyap Chitta, Li Chen, Hanxue Zhang, Chengen Xie, Jens Beißwenger, Ping Luo, Andreas Geiger và Hongyang Li. Drivelm: Lái xe bằng biểu đồ trả lời câu hỏi trực quan. Trong *Hội nghị Châu Âu về thị giác máy tính*, trang 256–274, 2024.

Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon và Ben Poole. Mô hình tổng quát dựa trên điểm số thông qua các phương trình vi phân ngẫu nhiên. Trong *Hội nghị quốc tế về đại diện học tập*, 2021.

Balakumar Sundaralingam, Siva Kumar Sastry Hari, Adam Fishman, Caelan Garrett, Karl Van Wyk, Valts Blukis, Alexander Millane, Helen Oleynikova, Ankur Handa, Fabio Ramos, Nathan Ratliff và Dieter Fox. curobo: Hệ thống chuyển động robot có độ giật tối thiểu không va chạm song song, 2023. URL <https://arxiv.org/abs/2310.17274>.

Nhóm Robot Gemini, Saminda Abeyruwan, Joshua Ainslie, Jean-Baptiste Alayrac, Montserrat Gonzalez Arenas, Travis Armstrong, Ashwin Balakrishna, Robert Baruch, Maria Bauza, Michiel Blokzijl, và những người khác. Robot Gemini: Đưa ai vào thế giới vật chất. *arXiv in trước arXiv:2503.20020*, 2025.

Đội Qwen. Qwen3.5: Tăng tốc năng suất với các tác nhân đa phương thức gốc, tháng 2 năm 2026. URL <https://qwen.ai/blog?id=qwen3.5>.

Yang Tian, Yuyin Yang, Yiman Xie, Zetao Cai, Xu Shi, Ning Gao, Hangxu Liu, Xuekun Jiang, Zherui Qiu, Feng Yuan, Yaping Li, Ping Wang, Junhao Cai, Jia Zeng, Hao Dong và Jiangmiao Pang. Interndata-a1: Tiên phong về dữ liệu tổng hợp có độ chính xác cao cho chính sách tổng quát trước đào tạo, 2025. URL <https://arxiv.org/abs/2511.16651>.

Homer Walke, Kevin Black, Abraham Lee, Moo Jin Kim, Max Du, Chongyi Zheng, Tony Zhao, Philippe Hansen-Estruch, Quân Vương, Andre He, Vivek Myers, Kuan Fang, Chelsea Finn và Sergey Levine. Bridgedata v2: Tập dữ liệu về robot học tập trên quy mô lớn, năm 2024. URL <https://arxiv.org/abs/2308.12952>.

Peng Wang, Shuai Bai, Sinan Tan, Shijie Wang, Zhihao Fan, Jinze Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Yang Fan, Kai Dang, Mengfei Du, Tuyên Thành Ren, Rui Men, Dayiheng Liu, Chang Chu, Jingren Chu và Junyang Lin. Qwen2-vl: Nâng cao nhận thức của mô hình ngôn ngữ tầm nhìn về thế giới ở mọi độ phân giải. *arXiv:2409.12191*, 2024.

Shaoan Wang, Jiazha Zhang, Minghan Li, Jiahang Liu, Anqi Li, Kui Wu, Fangwei Zhong, Junzhi Yu, Zhizheng Zhang và He Wang. TrackVLA: Tính năng theo dõi trực quan hiện thực. *arXiv bản in trước arXiv:2505.23189*, 2025a.

Shihao Wang, Zhiding Yu, Xiaohui Jiang, Shiyi Lan, Min Shi, Nadine Chang, Jan Kautz, Ying Li và Jose M Alvarez. Omnidrive: Bộ dữ liệu ngôn ngữ tầm nhìn toàn diện dành cho việc lái xe tự động với lý luận phản thực tế. Trong *Kỷ yếu của hội nghị nhận dạng mẫu và thị giác máy tính*, trang 22442–22452, 2025b.

Yihao Wang, Pengxiang Ding, Lingxiao Li, Can Cui, Zirui Ge, Xinyang Tong, Wenxuan Song, Han Zhao, Wei Zhao, Pengxu Hou, et al. Bộ chuyển đổi VLa: Một mô hình hiệu quả cho mô hình hành động-ngôn ngữ-tầm nhìn quy mô nhỏ. Trong *Kỷ yếu hội nghị AAAI về trí tuệ nhân tạo*, tập 40, trang 18638–18646, 2026.

Meng Wei, Chenyang Wan, Xiqian Yu, Tai Wang, Yuqiang Yang, Xiaohan Mao, Chenming Zhu, Wenzhe Cai, Hanqing Wang, Yilun Chen, và những người khác. Streamvln: Truyền trực tuyến điều hướng ngôn ngữ và tầm nhìn thông qua mô hình ngữ cảnh tốc độ chậm. *arXiv bản in trước arXiv:2507.05240*, 2025.

Kun Wu, Chengkai Hou, Jiaming Liu, Zhengping Che, Xiaozhu Ju, Zhuqin Yang, Meng Li, Yinuo Zhao, Zhiyuan Xu, Quảng Dương, Shichao Fan, Tân Hoa Vương, Fei Liao, Zhen Zhao, Guanyu Li, Zhao Jin, Lechen Wang, Jilei Mao, Ning Liu, Pei Ren, Qiang Zhang, Yaoxu Lyu, Mengzhen Liu, He Jingyang, Yulin Luo, Zeyu Gao, Chenxuan Li, Chenyang Gu, Yankai Fu, Di Wu, Xingyu Wang, Sixiang Chen, Zhenyu Wang, Pengju An, Siyuan Qian, Shanghang Zhang và Jian Tang. RoboMIND: Điểm chuẩn về dữ liệu quy phạm trí tuệ đa phương án để thao tác với robot. Trong *Robotics: Khoa học và Hệ thống XXI*, RSS2025. Robotics: Tổ chức Khoa học và Hệ thống, tháng 6 năm 2025a. doi: 10.15607/rss.2025.xxi.152. Địa chỉ <http://dx.doi.org/10.15607/RSS.2025.XXI.152>.

Shihan Wu, XueThành Liu, Shaoxuan Xie, Pengwei Wang, và những người khác. RoboCOIN: Bộ sưu tập dữ liệu robot hai tay có nguồn mở để thao tác tích hợp, 2025b. Địa chỉ <https://arxiv.org/abs/2511.17441>.

Một mô hình nền tảng vla thực dụng. *arXiv in trước arXiv:2601.18692v1*, 2026.

Sichen Xie, Lingchen Meng, Zijie Diao, Haidong Cao, Zhiying Du, Shuyuan Tu, Jiaqi Leng, Qiuyue Wang, Mingsheng Li, Shuai Bai, Zuxuan Wu và Yu-Gang Jiang. Thống nhất hành động của robot trong khung camera, 2026. URL <https://arxiv.org/abs/2511.17001>.

Phòng thí nghiệm XLANG Giới thiệu roboinf: Một công cụ dữ liệu có thể mở rộng để thao tác với robot tổng quát. <https://xlang.ai/blog/roboinf>, tháng 5 năm 2026. Bài đăng trên blog.

Zhenhua Xu, Yujia Zhang, Enze Xie, Zhen Zhao, Yong Guo, Kwan-Yee K Wong, Zhenguo Li và Hengshuang Zhao. Drivegpt4: Lái xe tự động từ đầu đến cuối có thể giải thích được thông qua mô hình ngôn ngữ lớn. *Thư tự động hóa và robot của IEEE*, 9(10):8186–8193, 2024.

Yandan Yang, Shuang Zeng, Tong Lin, Xinyuan Chang, Dekang Qi, Junjin Xiao, Haoyun Liu, Ronghan Chen, Yuzhi Chen, Dongjie Huo, Feng Xiong, Xing Wei, Zhiheng Ma và Mu Xu. ABot-M0: Mô hình nền tảng VLa cho thao tác robot với học tập đa dạng hành động. *arXiv preprint arXiv:2602.11236*, 2026.

Chao Yu, Yuanqing Wang, Zhen Guo, Hao Lin, Si Xu, Hongzhi Zang, Quanlu Zhang, Yongji Wu, Chunyang Zhu, Junhao Hu, et al. Rlinf: Học tăng cường quy mô lớn linh hoạt và hiệu quả thông qua chuyển đổi luồng từ vĩ mô sang vi mô. *arXiv preprint arXiv:2509.15965*, 2025a.

Seungjun Yu, Seonho Lee, Namho Kim, Jaeyo Shin, Junsung Park, Wonjeong Ryu, Raehyuk Jung và Hyunjung Shim. Waymoqa: Tập dữ liệu trả lời câu hỏi trực quan nhiều góc nhìn nhằm đưa ra lý luận quan trọng về an toàn trong lái xe tự động. *arXiv preprint arXiv:2511.20022*, 2025b.

Haoqi Yuan, Bohan Chu, Yuhui Fu và Zongqing Lu. Sự nắm bắt khéo léo đa dạng với học tập tăng cường. Trong *Hội nghị quốc tế về đại diện học tập (ICLR)*, 2025.

Jianke Zhang, Xiaoyu Chen, Qiuyue Wang, Mingsheng Li, Yanjiang Guo, Yuchen Hu, Jiajun Zhang, Shuai Bai, Junyang Lin và Jianyu Chen. Vlm4vla: Xem lại các mô hình ngôn ngữ-tầm nhìn trong các mô hình ngôn ngữ-hành động. *arXiv preprint arXiv:2601.03309*, 2026.

Jiazhaoh Zhang, Kunyu Wang, Rongtao Xu, Gengze Chu, Yicong Hong, Xiaomeng Fang, Qi Wu, Zhizheng Zhang và He Wang. Navid: vlm dựa trên video lên kế hoạch cho bước tiếp theo cho việc điều hướng bằng hình ảnh và ngôn ngữ. *arXiv preprint arXiv:2402.15852*, 2024.

Mô hình nền tảng điều hướng thể hiện, 2025a. Địa chỉ <https://arxiv.org/abs/2509.12129>.

Jiazhaoh Zhang, Kunyu Wang, Shaoan Wang, Minghan Li, Haoran Liu, Songlin Wei, Zhongyuan Wang, Zhizheng Zhang và He Wang. Uni-NaVid: Mô hình hành động-ngôn ngữ-tầm nhìn dựa trên video để thống nhất các tác vụ điều hướng được thể hiện. *Robotics: Khoa học và Hệ thống*, 2025b.

Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, et al. X-vla: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. *arXiv preprint arXiv:2510.10274*, 2025.

Ruijie Zheng, Dantong Niu, Yuqi Xie, Jing Wang, Mengda Xu, Yunfan Jiang, Fernando Castañeda, Fengyuan Hu, You Liang Tan, Letian Fu, Trevor Darrell, Furong Huang, Yuke Zhu, Danfei Xu, and Linxi Fan. Egoscale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv:2602.16710*, 2026.

Yuchen Chu, Jiayu Tang, Xiaoyan Xiao, Yueyao Lin, Linkai Liu, Zipeng Guo, Hao Fei, Xiaobo Xia và Chao Gou. Ở đâu, cái gì, tại sao: Hướng tới dự đoán sự chú ý của người lái xe có thể giải thích được. Trong *Kỷ yếu của Hội nghị quốc tế IEEE/CVF về Thị giác máy tính*, trang 2675–2685, 2025.

Brianna Zitkovich, Tianhe Yu, Sichun Xu, Peng Xu, Ted Xiao, Fei Xia, Jialin Wu, Paul Wohlhart, Stefan Welker, Ayzaan Wahid, và những người khác. Rt-2: Các mô hình hành động-ngôn ngữ-tầm nhìn chuyển kiến thức web sang điều khiển robot. Trong *Hội nghị về học tập bằng robot*, 2023.